


UNIVERSIDAD TECNOLÓGICA DE PEREIRA
FACULTAD DE INGENIERIA INDUSTRIAL
MAESTRIA EN INVESTIGACION OPERATIVA Y ESTADISTICA

Asignatura: Simulación de Sistemas Dinámicos

MODULO
FUNDAMENTOS TEÓRICOS DE SIMULACIÓN DISCRETA



Presentado por:
José A. Soto Mejía

Pereira, Marzo-Abril 2011

UNIVERSIDAD TECNOLÓGICA DE PEREIRA
FACULTAD DE INGENIERÍA INDUSTRIAL
Maestría en Investigación Operativa y Estadística

FUNDAMENTOS TEÓRICOS
DE SIMULACIÓN DISCRETA

APUNTES DE CLASE
PROFESOR: José A. Soto Mejía

PROGRAMA:

OBJETIVO GENERAL:

Este curso pretende darle al estudiante una visión general de la simulación de sistemas discreto. Al finalizar el curso el estudiante podrá realizar sencillas simulaciones en las áreas de economía, teoría de colas, modelos industriales y procesos industriales.

CONTENIDO GENERAL:

1. Introducción. La simulación y la Investigación de Operaciones. Sobre el concepto y la definición de sistemas. El concepto de modelo en la teoría de sistemas. Qué es un modelo de simulación. Fundamentos racionales de la simulación. Proceso de planteamiento de modelos y simulación.
2. Muestreo Monte Carlo. Ilustración y análisis. Taller método Monte Carlo.
3. Números aleatorios uniformes. Método del cuadrado medio. Métodos basados en números congruentes. Método de congruencia multiplicativa. Tests.
4. Generadores de proceso. Técnicas para generar números aleatorios. Método de transformación inversa. Generación de procesos continuos, generación uniforme, exponencial negativa, normal. Generación de procesos discretos. Distribuciones empíricas. Taller generadores de proceso.
5. Algunos resultados prácticos relacionados con resultados estadísticos de la simulación. Estadísticas de llegadas (Llegadas cíclicas; Llegadas periódicas;

Llegadas iniciadas internamente). Estadísticas de los procesos. Flujos <Streams> de números aleatorios. Estadísticas de salida. Determinación del período de calentamiento (warm-up period). Número de Replicaciones. Inferencia estadística. Comparación y evaluación de alternativas. Técnicas de Reducción de varianza.

6. Terminología de simulación: Sistema y Estado del Sistema; Modelos de Eventos Discretos y Continuos; Modelos Estáticos y Dinámicos; Modelos de Ciclo Abierto y Ciclo Cerrado; Simulaciones de Estado Estable y Terminantes; Período de Calentamiento; Flujos y Semillas de Números Aleatorios; Corridas del Modelo y Replicaciones Independientes del Modelo.

BIBLIOGRAFÍA:

NAYLOR, Thomas H. Joseph L. Balintfy, Donald S. Burdick y Kong Chu. Técnicas de Simulación en Computadoras. México. Limusa, 1982.

BATEMAN, Robert, Charles HARRELL, y Otros. *System Improvement Using Simulation*. 1995. (Autores del paquete de Promodel).

“Simulación”. Sheldon M. Ross. Prentice Hall, México, 1999.

Goldratt, Eliyahu y Jeff Cox, La Meta. The North River Press Publishing Corporation, segunda edición, 1999.

“Simulación Métodos y Aplicaciones”. Rios, I. D.; Rios, I. S. Jiménez, M. J. Alfa Omega Grupo Editor, S.a de C. 2000.

“Simulación con ProModel- Casos de producción y logística”. Luis Ernesto Blanco Rivero, Ivan Darío Fajardo Piedrahita. Editorial Escuela Colombiana de Ingeniería, Mayo de 2001.

“Simulación y análisis de sistemas con ProModel”. Eduardo García Dunna, Heriberto García Reyes, Leopoldo Eduardo Cárdenas Barrón. Pearson Prentice Hall, Mexico, 2006.

“LABORATORIOS DE SIMULACION DISCRETA”. Jose Adalberto Soto Mejia; Juan Fernando Lopez Rendon. Postergraph S.A. Pereira, Enero 2010. ISBN: 978-958-44-6516-0.

Libros varios de Investigación de Operaciones que tengan capítulos de simulación:

PRAWDA, Juan. *Métodos y Modelos de Investigación de Operaciones. Vol. 2 Modelos Estocásticos*. Editorial Limusa, 1984.

K. DAVIS, Roscoe, Patrick G. McKeown. *Modelos Cuantitativos para Administración*. México. Iberoamérica, 1986. Cap. 14.

Hillier, Frederick S., Gerald J. Leberman. *Investigación de Operaciones*, 3rd edición, 1997.

Walpole, Ronald E. and Myers, Rymond H., *Probability and Statistics for Engineers and Scientists*, 2nd edition, New York, Macmillan Publishing Co., Inc., 1978.

Algunos libros con tratamiento matemático más depurado:

Law, Averill and W. David Kelton, *Simulation Modeling & Analysis*, 3rd edition, New York, McGraw Hill, Inc, 2000.

Banks, Jerry., John S. Carson., Barry L. Nelson., David M. Nicol, *Discrete event System Simulation*, Englewood Cliffs, N. J., Prentice-Hall, Inc., Third Edition, 2001.

Sitio WEB de interés:

Lea a cualquier momento los recientes “*Proceedings*” de la “*Winter Simulation Conference- WSC*”.

La WSC es una forma excelente de aprender acerca de lo último en aplicaciones y teoría de la simulación. Las memorias de la conferencia de varios años están disponibles “on line” en:

<http://www.informs-cs.org/wscpapers.html>

TABLA DE CONTENIDO

UNIDAD I.....	1
1.1 INTRODUCCIÓN: IMPORTANCIA DE LOS MODELOS	1
1.2 INTRODUCCIÓN-DEFINICIÓN DE SIMULACIÓN (Una de tantas).....	3
1.2.1 FUNDAMENTOS RACIONALES DE LA SIMULACIÓN.....	4
1.2.2 RAZONES PARA ESCOGER LA SIMULACIÓN POR COMPUTADORA.....	5
1.3 PROCESO DE PLANTEAMIENTO DE MODELOS Y SIMULACIÓN (Davis/McKeown).....	7
1.4 LA SIMULACIÓN Y LA INVESTIGACIÓN DE OPERACIONES	8
UNIDAD II.....	10
2.1 MUESTREO MONTE CARLO	10
2.1.1 ILUSTRACIÓN DEL PROCESO MONTE CARLO (Davis/McKeown).....	10
2.1.2 CASO DE LA EMPRESA MANUFACTURERA D.E.F. (Davis / MacKewon)	13
2.1.3 TALLER # 1 MÉTODO MONTE CARLO	18
2.1.4 TALLER # 2 MÉTODO MONTE CARLO (Shambling/Stevens)	18
UNIDAD III.....	20
3.1 NÚMEROS ALEATORIOS UNIFORMES (Prawda).....	20
3.1.1 Propiedades de los Números Aleatorios.....	20
3.2 NÚMEROS PSEUDO-ALEATORIOS	21
3.3 GENERACIÓN DE NÚMEROS PSEUDO-ALEATORIOS	24
3.3.1 MÉTODOS BASADOS EN NÚMEROS CONGRUENTES	25
3.3.2 OTROS MÉTODOS (método utilizado por el G.P.S.S)	30
3.4 TESTS ESTADÍSTICOS PARA NÚMEROS ALEATORIOS	34
3.4.1 Pruebas (tests) para uniformidad	35
3.4.2 Pruebas (tests) para independencia.....	35
3.5 Prueba de Kolmogorov-Smirnov (Prawda).....	37
3.6 Prueba de corridas hacia arriba y hacia abajo (Runs up and Runs down Test) (Prawda)	41
UNIDAD IV	45
4.1 GENERADORES DE PROCESO	45
4.2 TÉCNICAS PARA GENERAR NÚMEROS ALEATORIOS (con determinada distribución de probabilidad)	46
4.3 MÉTODO DE TRANSFORMACIÓN INVERSA (Davis / McKeown).....	46
4.3.1 Generador de procesos para la Distribución Uniforme entre a y b. Método de la transformación inversa. (Davis / McKeown).....	47

4.3.2	Generador de procesos para la Distribución Exponencial Negativa. Método de la transformación inversa. (Davis / McKeown).....	50
4.3.3	Generador de procesos para la Distribución Normal (Método especial)	52
4.4	MÉTODO DE COMPOSICIÓN	57
4.4.1	Distribución triangular (Método Composición).....	58
4.4.2	Generador de procesos para la Distribución Binomial. (Método de Aceptación y Rechazo). (Davis / McKeown).....	62
4.4.3	Generador de procesos para la Distribución Poisson. (Método de Aceptación y Rechazo). (Davis / McKeown).....	63
UNIDAD V		66
ENCONTRANDO LA DISTRIBUCIÓN CORRECTA		66
5.1	<i>¿Porqué usar Distribuciones Estándar?</i>	66
5.2	<i>Algunas Distribuciones Estándar</i>	68
<i>(Realizar práctica #13 con Stat::Fit, para analizar el efecto que el cambio en el valor de los parametros tiene sobre la forma de estas distribuciones)</i>		68
5.2.1	EXPONENCIAL	68
5.2.2	GAMMA	69
5.2.3	NORMAL.....	70
5.2.4	UNIFORME	70
5.2.5	WEIBULL.....	71
5.2.6	TRIANGULAR.....	71
5.2.7	LOGNORMAL.....	71
5.2.8	ERLANG.....	72
5.2.9	BETA	73
5.2.10	POISSON	74
5.2.11	BINOMIAL	74
5.2.12	UNIFORME DISCRETA.....	75
5.3	<i>Estimadores Sugeridos para parámetros de algunas distribuciones</i>	76
5.4	PRUEBAS DE BONDAD DE AJUSTE	78
5.4.1	Prueba Chi Cuadrada.....	80
UNIDAD VI		88
Algunos Aspectos Importantes en la Realización de Experimentos de Simulación		88
6.1	<i>Introducción.</i>	88
6.2	<i>Simulaciones Terminantes versus No Terminantes (de estado estable)</i>	90
6.3	<i>Corriendo simulaciones Terminantes</i>	91
6.4	<i>Corriendo simulaciones no Terminantes (o de estado estable)</i>	93
6.4.3	<i>Determinación de la longitud de la corrida de simulación</i>	96

6.5	<i>Comparando Sistemas Alternativos</i>	97
6.6	<i>Diseño Factorial</i>	98
6.7	<i>Uso de Flujos Aleatorios (Random Streams)</i>	99
UNIDAD VII.....		102
ALGUNOS ASPECTOS PRÁCTICOS RELACIONADOS CON ESTADÍSTICAS DE LA SIMULACIÓN		102
7.1	<i>Introducción</i>	102
7.2	<i>Aspectos Estadísticos</i>	103
7.2.1	Estadísticas de llegadas (Modelaje de llegadas)	103
7.2.2	Estadísticas de los procesos.....	106
7.2.3	Flujos <Streams> de números aleatorios.....	107
7.2.4	Estadísticas de salida.....	108
7.3	<i>Calculo del Período de calentamiento (warm-up period) para simulaciones de Estado Estable...</i>	111
7.4	<i>Número de Replicaciones</i>	115
7.5	<i>Inferencia Estadística</i>	118
7.5.1	Teorema Central del Límite.....	118
7.5.2	Comparando y Evaluando Alternativas	124
7.5.3	Técnicas para la Reducción de Varianza	129
7.5.4	Administrando las Replicaciones de Modelo y las Salidas.....	130
UNIDAD VIII		131
8.1	<i>TERMINOLOGÍA DE SIMULACIÓN (Traducido de Bateman)</i>	131
8.1.1	Sistema y Estado del Sistema	131
8.1.2	Modelos de Eventos Discretos y Continuos	131
8.1.3	Modelos Estáticos y Dinámicos.....	132
8.1.4	Modelos de Ciclo Abierto y Ciclo Cerrado	132
8.1.5	Simulaciones de Estado Estable y Terminantes.....	132
8.1.6	Período de Calentamiento.....	134
8.1.7	Flujos y Semillas de Números Aleatorios.....	134
8.1.8	Corridas del Modelo y Replicaciones Independientes del Modelo.....	135
UNIDAD IX		136
9.1	<i>SOBRE EL CONCEPTO Y LA DEFINICIÓN DE SISTEMAS</i>	137
9.2	<i>EL CONCEPTO DE MODELO EN LA TEORÍA DE SISTEMAS</i>	149

UNIDAD I

1.1 INTRODUCCIÓN: IMPORTANCIA DE LOS MODELOS

"Ninguna parte substancial del universo es tan simple de comprender y controlar sin el uso de la abstracción. La abstracción consiste en reemplazar la parte del universo bajo consideración por un modelo de estructura similar pero más simple." (Arthur Wiener)

INTRODUCCIÓN: MODELO (Davis/McKeown)

Modelo Mental.

El proceso de construcción de modelos es usado diariamente, tal vez sin darnos cuenta, en muchas de nuestras actividades diarias.

Considere, por ejemplo, el caso de un estudiante que desea hacer una presentación en clase utilizando ayudas audiovisuales. Este estudiante desea arreglar el mobiliario del aula de clase (sillas, mesas, proyectores, pantallas, cortinas, etc.). El objetivo es el de tener una distribución del aula atractiva pero también funcional para sus oyentes. Una alternativa es la de visualizar diferentes distribuciones del aula, y evaluar cada alternativa. Si lo hace así, el estudiante estará utilizando un modelo mental para su problema.

Otra alternativa para el estudiante del ejemplo anterior puede ser la de pedir ayuda a varios compañeros y físicamente disponer de los muebles del aula hasta que esté satisfecho del arreglo. Esta forma de proceder podría ser preferible, por alguna de las siguientes razones: El modelo mental no es lo suficiente nítido para manipularlo en la mente, o hay demasiadas cosas que se deben mantener mentalmente, o puede ser que el estudiante no tenga la suficiente habilidad mental de visualización.

Modelo a escala.

Aunque el estudiante considerado hace un momento puede hacer una especie de maqueta a escala del aula y los muebles requeridos, y físicamente colocar esa maqueta sobre una mesa y ensayar las diferentes distribuciones, este tipo de aproximación de modelos a escala se utiliza más ampliamente en problemas de mayor magnitud. Por ejemplo, considere el caso de un Ingeniero Industrial que está a cargo del diseño de la planta de una empresa manufacturera. Aquí, para el Ingeniero puede ser muy difícil visualizar un modelo mental de toda la fábrica, y el Ingeniero no puede darse el lujo de utilizar a todos los ope-

rarios para ensayar diferentes distribuciones físicas de las máquinas y puestos de trabajo, efectuando corridas de producción con cada distribución y luego comparar resultados. En este ejemplo, el Ingeniero Industrial podría utilizar un modelo a escala y evaluar diferentes alternativas.

Modelos Matemáticos.

El Ingeniero Industrial del ejemplo anterior también puede optar por el empleo de modelos matemáticos, particularmente si está seguro de que ya existen modelos de diseño de planta CRAFT (CRAFT es un acrónimo de Computerized Relative Allocation of Facilities Technique).

La construcción de modelos ha existido por muchos años, particularmente los modelos mentales y los modelos a escala, pero los modelos matemáticos son relativamente nuevos. La mayoría de los análisis o de las técnicas que utiliza la Ingeniería Industrial son conducidos utilizando modelos matemáticos. Dichos modelos han sido desarrollados usando símbolos matemáticos que representan los diferentes componentes del problema.

No todos los modelos matemáticos son complejos. Obviamente, en estos apuntes de clase de simulación no vamos a extendernos en la teoría expuesta en otros cursos de la Facultad. Pero sí queremos enfatizar el hecho de que la Ingeniería Industrial trabaja en el desarrollo de abstracciones para las relaciones entre las variables de un problema. Además, un poco más adelante, haremos una mirada global a la forma en que la Ingeniería Industrial aborda el problema general de modelación y los procesos de solución usados para identificar las soluciones a los modelos.

Veamos aquí, con una mirada global, la forma en que la Ingeniería Industrial aborda el problema general de la modelación y los procesos de solución usados para identificar las soluciones a los modelos:

Clasificación de los Modelos: Normativos vs. Descriptivos.

Un modelo descriptivo es aquel que representa una relación pero no indica ningún curso de acción. Por el contrario, el modelo normativo (llamado también modelo de optimización) debe indicar el curso de acción que debe tomarse para alcanzar el objetivo.

Los modelos descriptivos son útiles para predecir el comportamiento del sistema, pero no tienen la capacidad de identificar el «mejor» curso de acción para el administrador. La mayoría de los modelos estadísticos son descriptivos (por

ejemplo, un modelo de regresión indica la relación entre un variable dependiente y una o más variables independientes, pero este modelo no indica qué valores se deben tomar para las variables independientes).

Los modelos normativos pueden tener submodelos descriptivos, pero, como se dijo antes, se caracterizan porque permiten determinar el mejor (o el óptimo) curso de acción. Esto implica que al modelo se ha incorporado uno o varios objetivos, restricciones, variables y parámetros.

Clasificación de los Modelos: Determinísticos vs. Estocásticos.

En un modelo determinístico las relaciones funcionales, o sea los parámetros del modelo, son conocidos con certeza. Por ejemplo, se puede decir que un tractor recorre diez kilómetros en una hora. Pero si no estamos ciertos del parámetro, tenemos que introducir la incertidumbre, y decir, por ejemplo, que la probabilidad de que el tractor recorra diez kilómetros en una hora es de 0.75. En este caso se estará desarrollando un modelo estocástico.

Clasificación de los Modelos: Lineales vs. No-lineales.

Un modelo lineal es aquel en el cual las relaciones funcionales son tales que las variables dependientes son proporcionales a las variables independientes. Por otro lado, los modelos no-lineales emplean ecuaciones curvilíneas o no proporcionales.

Clasificación de los Modelos: Estáticos vs. Dinámicos.

Los modelos estáticos se definen para un punto fijo en el tiempo y asumen que las condiciones del modelo no cambian para el período del tiempo en el cual se quiere obtener una solución al modelo. Los modelos dinámicos se diferencian de los estáticos en que la acción óptima es determinada al examinar varios períodos de tiempo.

Clasificación de los Modelos: Simulación.

La simulación como se verá en este curso, es un proceso de modelación/experimentación usado para describir/analizar un problema dado.

1.2 INTRODUCCIÓN-DEFINICIÓN DE SIMULACIÓN (Una de tantas)

Proceso seguido para el desarrollo del modelo de un problema y para la estimación de medidas de la ejecución del problema por medio de experimentos de muestreo sobre el modelo (Davis/McKeown)

QUE ES UN MODELO DE SIMULACIÓN

Una técnica, que cada vez se utiliza más en la Investigación de Operaciones, para abstraer una situación o problema de la vida real en tal forma que dicha situación o problema pueda ser manipulado fuera de su contexto.

1.2.1 FUNDAMENTOS RACIONALES DE LA SIMULACIÓN

El fundamento racional para la utilización de la simulación en cualquier disciplina es la búsqueda constante del hombre por adquirir conocimientos relativos a la predicción del futuro.

El **método científico**, o filosofía científica actual, consiste en cuatro pasos bien definidos (Naylor):

1. Observación de un sistema físico.
2. Formulación de una hipótesis (puede ser un modelo matemático) que intente explicar las observaciones hechas al sistema.
3. Predicción del comportamiento del sistema, con base en la hipótesis formulada, mediante el uso de la deducción lógica o matemática, esto es, por la obtención de soluciones del modelo o modelos.
4. Realización de experimentos para probar la validez de las hipótesis o del modelo.

Nota: Algunas veces no resulta recomendable seguir los cuatro pasos descritos anteriormente en un sistema particular. Si este es el caso, la simulación es un sustituto satisfactorio del paso (o pasos) que causan dificultad en el procedimiento.

(Por esto, la simulación se ha convertido últimamente en una de las herramientas más usadas en la Investigación de Operaciones).

Podemos considerar las siguientes dificultades en cada uno de los cuatro pasos anteriores:

1. Puede ser imposible o extremadamente difícil - costoso el observar ciertos procedimientos en el mundo real (Por ello se utilizan, a vía de ejemplo, los vuelos simulados, pronósticos de ventas para los siguientes meses, estadísticas de las fallas de una máquina determinada, etc. En casos como éstos, la simulación ha mostrado ser un medio efectivo para generar datos numéricos que describan los procesos).
2. El sistema puede ser tan complejo que sea imposible describirlo en términos de un grupo de ecuaciones matemáticas, del cual se puedan obtener soluciones analíticas para ser usadas con propósitos predictivos (a vía de ejemplo, se puede mencionar la operación de una empresa, situaciones de canales múltiples de espera, etc.).
3. Aun cuando un modelo matemático logre formularse para describir algún sistema de interés, puede que no se obtenga una solución al modelo por medio de técnicas analíticas directas, por tanto tampoco se podrán realizar predicciones acerca del comportamiento futuro del sistema.
4. Puede resultar casi imposible o muy costoso realizar experimentos de validación física de los modelos matemáticos que describen el sistema.

1.2.2 RAZONES PARA ESCOGER LA SIMULACIÓN POR COMPUTADORA

Obviamente, la razón principal es la de tratar de vencer las dificultades antes mencionadas al implantar el método científico.

Hay otras razones adicionales (que no están muy separadas de la discusión previa): (Gould - Eppen / Schmidt)

1. La simulación hace posible estudiar y experimentar con las interacciones complejas que ocurren en el interior de un sistema dado.
2. A través de la simulación se pueden estudiar los efectos de ciertos cambios en la operación de un sistema.
3. La observación detallada del sistema que se está simulando conduce a un mejor entendimiento del mismo y proporciona sugerencias para mejorarlo.
4. La simulación puede ser usada como recurso pedagógico al enseñar los conocimientos básicos en el análisis teórico, en el análisis estadístico y en la toma de decisiones.

5. La experiencia que se adquiere al diseñar un modelo de simulación en computadoras puede ser más valiosa que la simulación en sí misma. El conocimiento que se obtiene al diseñar un estudio de simulación sugiere, frecuentemente, cambios en el sistema en cuestión. Los efectos de estos cambios pueden probarse, entonces, a través de la simulación (ver razón # 2) antes de implantarlos en el sistema real.
6. La simulación de sistemas complejos puede producir un valioso y profundo conocimiento acerca de cuáles variables son más importantes que otras en el sistema, y cómo ellas obran entre sí (Ver razón # 1).
7. La simulación puede emplearse para experimentar con situaciones nuevas acerca de las cuales tenemos muy poca o ninguna información con el objeto de estar preparados para alguna eventualidad (Ver razones # 2 y 5).
8. La simulación puede servir como una prueba de *pre-servicio* para ensayar nuevas políticas y reglas de decisión en la operación de un sistema, antes de tomar el riesgo de experimentar con el sistema real. (Ver razones # 2, 5 y 7).
9. Algunas veces las simulaciones son valiosas, ya que proporcionan alguna forma conveniente de dividir un sistema en subsistemas, cualquiera de los cuales puede ser modelado por un analista o un equipo de expertos en el área.
10. Para ciertos tipos de problemas estocásticos la secuencia de los eventos puede ser muy importante, pues la información de los valores esperados puede no ser suficiente para describir el proceso (no se incluye aquí la secuencia). En estos casos, los métodos de Monte Carlo pueden constituir la única forma satisfactoria de obtener la información requerida.
11. Las simulaciones de Monte Carlo pueden realizarse para verificar soluciones analíticas.
12. La simulación permite estudiar los sistemas dinámicos, ya sea en tiempo real, comprimido o expandido.
13. Cuando se presentan nuevos componentes de un sistema, la simulación puede emplearse para ayudar a descubrir los obstáculos (prever) y otros problemas que resulten de la operación del sistema (Ver razones # 2, 5, 7 y 8).

14. La simulación convierte a los especialistas en técnicos generales. Se obliga a los analistas a hacer una apreciación y a entender todos los aspectos del sistema, con el resultado de que las conclusiones sean menos susceptibles a la parcialidad por inclinaciones particulares, y menos susceptibles de volverse impracticables dentro de la configuración del sistema.

1.3 PROCESO DE PLANTEAMIENTO DE MODELOS Y SIMULACIÓN (Davis/McKeown)

Etapas:

1. IDENTIFICACIÓN DEL PROBLEMA

Implica la recopilación de datos para describir las diferentes variables de entrada, la identificación de los límites o cotas del sistema, la definición de los componentes del problema y sus inter-relaciones.

2. PLANTEAMIENTO DEL MODELO

Corresponde a la construcción del modelo de simulación y a la definición de los procesos estadísticos (diseño experimental) que se utilizarán para aplicar el modelo. Dado que la simulación implica llevar a cabo experimentos muestrales en un modelo del sistema del mundo real, los resultados que se obtienen son observaciones muestrales o estadísticas muestrales.

El objetivo del análisis estadístico es asegurar que el problema se aborda en forma adecuada desde el punto de vista estadístico, es decir, que el número de condiciones y casos del modelo que se examina sea suficiente para obtener inferencias estadísticas válidas a partir de los resultados.

3. VALIDACIÓN

Aquí se debe asegurar que las entradas al modelo de simulación sean adecuadas y que el modelo responda a esas entradas de manera similar al problema real. Si un modelo determinado no simula en forma adecuada la respuesta del sistema real resultará necesario volver a examinar las dos primeras etapas (identificación del problema y planteamiento del modelo) con el objeto de determinar los factores o relaciones que no se hayan considerado.

4. PROCESO DE SIMULACIÓN MISMO

Una vez que el modelo ha sido validado puede comenzar el proceso de simulación. Este proceso involucra (1) la generación de entradas al sistema, (2) ejecutar el modelo y (3) obtener datos simulados.

En un proceso de simulación, es necesario estar alerta a dos circunstancias:

- Para un conjunto dado de condiciones debemos estar seguros de tener un adecuado número de experimentos muestrales (iteraciones en la simulación). Cada iteración en la simulación es análoga a una sola observación, por lo tanto, correr n iteraciones es análogo a sacar una muestra de tamaño n . En la terminología estadística, la media de una muestra ($\bar{y}$) sirve para hacer inferencias con respecto a la media de la población (μ) sólo si emplea un tamaño de muestra adecuado.

Para hacer inferencias referentes al funcionamiento del mundo real, se deben analizar diferentes condiciones y parámetros del modelo.

1.4 LA SIMULACIÓN Y LA INVESTIGACIÓN DE OPERACIONES

La simulación se diferencia significativamente de otras técnicas de modelado de la Investigación de Operaciones, en las cuales el esfuerzo se realiza en la formulación y desarrollo de modelos matemáticos y la solución analítica matemática de los modelos (Esas soluciones, en la mayoría de los casos, se presentan en la forma de algoritmos que conducen a soluciones “óptimas”)

La simulación no hace énfasis en ningún algoritmo particular. En lugar de ser un proceso normativo es un proceso descriptivo.

Generalmente, el proceso de simulación involucra la recolección de datos que describen las entradas, los factores operativos, la inter-relación de los factores (variables) y otros componentes del problema que está siendo estudiado.

La salida de un modelo de simulación se presenta en forma de indicadores (o descriptores) de ejecución.

Utilizando el modelo se pueden explorar las características del problema.

Aunque la simulación es descriptiva por naturaleza, rutinas de búsqueda se incluyen en los modelos de simulación para llegar a soluciones cercanas a la óptima. Se utiliza la expresión «cercana a la óptima» debido a que la solución

puede ser óptima en términos del modelo definido, pero esto no garantiza que la solución sea un óptimo global (Por tanto, se dice que la optimalidad en simulación es una aproximación de la optimalidad que se obtendría en programación matemática).

En simulación no se requieren muchas de las consideraciones que son necesarias para el planteamiento de modelos teóricos y su solución analítica; por ello es posible estudiar sistemas más grandes y complejos. En muchas ocasiones, la simulación es el único medio viable para el análisis de sistemas complejos.

UNIDAD II

2.1 MUESTREO MONTE CARLO

El origen de los métodos modernos de simulación proviene de lo que se conoce como Muestreo Monte Carlo, técnica que fue utilizada en primer lugar por J. von Newman y luego se popularizó entre otros investigadores, junto con los equipos militares de Investigación de Operaciones durante la segunda guerra mundial (Davis MacKewon).

A finales de 1.940, von Newman y Ulman utilizaron el término Monte Carlo para referirse a una técnica matemática que usaban entonces para resolver ciertos problemas de protección nuclear que eran, ó demasiado costosos para resolverse experimentalmente ó demasiado complicados para ser tratados analíticamente. El análisis Monte Carlo involucra la solución de un problema matemático no probabilístico mediante la solución de un proceso estocástico cuyos momentos o distribuciones de probabilidad satisficían las relaciones matemáticas del problema no probabilístico (Naylor).

El término Monte Carlo se refiere a un proceso que se utiliza en forma aleatoria para elegir valores muestrales a partir de una distribución probabilística. Después, esos valores muestrales se utilizan como entradas o valores operativos para un modelo de simulación. Por ello, el muestreo Monte Carlo no es simulación sino que es, más bien, un procedimiento o método que se utiliza con modelos probabilísticos de simulación (Davis MacKewon).

El método Monte Carlo es el elemento básico de cualquier experimento de simulación porque, en esencia, es el proceso de muestreo asociado con la simulación. Por fortuna, el muestreo de valores aleatorios a partir de distribuciones de probabilidad puede lograrse a través de generadores de proceso (se verán en la Unidad IV) a diferencia del procedimiento de búsqueda en tablas asociado con el método de Monte Carlo tradicional.

2.1.1 ILUSTRACIÓN DEL PROCESO MONTE CARLO (Davis/McKeown)

Suponga que se quiere simular las toneladas de basura que se recogen en un día específico. Siempre debe conocerse el comportamiento de lo que se va a simular: En este caso, se sabe que algunos días se recolectan 10 toneladas, otros días 20 toneladas, ... , otros 70 toneladas, y lo que se va a simular es

un día cualquiera, por lo tanto se requiere conocer la distribución de probabilidad.

Suponga que la distribución de probabilidad está dada por:

Toneladas de basura recolectadas por día	Probabilidad
-----	-----
10	0.10
20	0.22
30	0.25
40	0.20
50	0.12
60	0.07
70	0.04

Para comenzar el proceso, es necesario elaborar una distribución probabilística acumulada. Es decir, necesitamos conocer la probabilidad de que las toneladas de basura recogidas en un día determinado (variable aleatoria discreta en este caso) sean menos que, o igual a un valor determinado. Esto puede lograrse con la siguiente tabla:


Toneladas de basura Recolectadas por día (d)	p(d)	P(recolección $\leq d$)	Intervalo para los números aleatorios
10	0.10	0.10	0.00 ... 0.09
20	0.22	0.32	0.10 ... 0.31
30	0.25	0.57	0.32 ... 0.56
40	0.20	0.77	0.57 ... 0.76
50	0.12	0.89	0.77 ... 0.88
60	0.07	0.96	0.89 ... 0.95
70	0.04	1.00	0.96 ... 0.99

Dado que para cualquier distribución probabilística acumulada las probabilidades caen en el intervalo $[0, 1]$, es posible generar una ocurrencia aleatoria correspondiente a una distribución probabilística específica, seleccionando un número al azar entre cero (0) y uno (1), encontrando el intervalo de distribución acumulada dentro del cual cae el número aleatorio e identificando el valor asociado de la variable aleatoria en consideración.

Para ilustrar la forma como esto se realiza, es posible elaborar una curva de distribución acumulada de los datos (ver página siguiente):

Observe que la longitud de la línea vertical en cada uno de los escalones corresponde al valor de la probabilidad para cada nivel de recolección de basura (por ej. para el nivel de recolección de 20 toneladas la línea vertical mide 0.22).

Si se genera al azar un número entre 0 y 1 (éste puede leerse en una tabla, como la que aparece al final de esta sección, obtenerse de una calculadora que tenga funciones de números aleatorios o bien calcularse de forma matemática como lo veremos más adelante), entonces al determinar la ubicación del número generado aleatoriamente en el eje vertical se obtiene un valor muestral asociado para ese nivel de recolección. Por ejemplo, suponga que generamos el número aleatorio 0.4764, el nivel de recolección asociado sería 30 toneladas de basura para ese día. Cada generación de un número aleatorio se entiende como un experimento de muestreo. Si repitiésemos este proceso de muestreo un gran número de veces (iteraciones), esperaríamos obtener un nivel de recolección de 30 toneladas el 25% de las veces. Por ello, los valores simulados con esta metodología para un número grande de iteraciones corresponderían a la distribución original estadística de la recolección de basura.



El muestreo a partir de una distribución probabilística utilizando el método de Monte Carlo es bastante simple una vez que se ha elaborado la curva (distribución)

bución) probabilística acumulada. Sin embargo, para aceptar que el proceso es correcto desde el punto de vista estadístico, debemos asegurarnos de que los números aleatorios tengan en realidad una distribución aleatoria uniforme entre 0 y 1 (este asunto será tratado en la sección 3.4 y 3.6). Para llevar a cabo una simulación manual puede utilizarse una tabla de números aleatorios. Los números aleatorios generados por computadora se basan en procedimientos matemáticos más que en tablas (Davis / MacKewon).

Nota: Observe la última columna de la tabla anterior. Se puede utilizar con el mismo efecto de la curva de distribución acumulada.

A fin de ilustrar manualmente el proceso de la simulación en general, pero haciendo hincapié en los aspectos de control de tiempos de la simulación se analiza en seguida, a vía de ejemplo, un caso particular.

2.1.2 CASO DE LA EMPRESA MANUFACTURERA D.E.F. (Davis / MacKewon)

Los Ingenieros Industriales de la Empresa Manufacturera D.E.F. han observado que el tiempo muerto de la maquinaria en el área de producción 1) ocasiona considerables pérdidas de producción, 2) aumenta los pedidos atrasados que no se han satisfecho y 3) hace que se pierdan oportunidades de ventas.

Estos ingenieros opinan que es posible reducir en forma significativa el problema utilizando un número adecuado de personal de mantenimiento.

El salario por hora (incluyendo prestaciones) para el personal de mantenimiento es de \$ 4.000. Los ingenieros consideran que se pierden \$ 15.000 por hora cuando una máquina no está en operación; esta cifra incluye las utilidades que se pierden así como también el costo del tiempo muerto de los operarios de las máquinas (que son diferentes del personal de mantenimiento).

Se quiere entonces determinar el número óptimo de personal de mantenimiento. Es decir, la empresa necesita saber en qué punto el costo del personal de mantenimiento (\$ 4.000 por hora) equivale a los costos esperados por el tiempo muerto de los operarios de las máquinas y las utilidades que se pierden (\$ 15.000 por hora).

El gerente de producción de la empresa ha recopilado datos con respecto al tiempo que transcurre entre fallas de las máquinas, así:

Tiempo entre fallas (minutos)	Frecuencia de ocurrencia
-----	-----
15	7
16	14
17	15
18	28
19	36
20	27
21	15
22	8

	150

No se han recopilado datos con respecto al tiempo que el personal de mantenimiento invierte en reparar una máquina; sin embargo, el gerente proporcionó una estimación aproximada de los tiempos de servicio y de sus probabilidades asociadas, así:

Tiempo de servicio (minutos)	Probabilidad
-----	-----
5 - 15	0.05
15 - 25	0.25
25 - 35	0.40
35 - 45	0.25
45 - 55	0.05

La siguiente tabla muestra la distribución acumulada de los tiempos entre fallas de las máquinas:

Tiempo entre fallas (min) (f)	p(f)	P(tiempo entre fallas $\leq f$)	Intervalo para los números aleatorios
15	0.0467	0.0467	0.0000 ... 0.0466
16	0.0933	0.1400	0.0467 ... 0.1399
17	0.1000	0.2400	0.1400 ... 0.2399
18	0.1867	0.4267	0.2400 ... 0.4266

19	0.2400	0.6667	0.4267 ... 0.6666
20	0.1800	0.8467	0.6667 ... 0.8466
21	0.1000	0.9467	0.8467 ... 0.9466
22	0.0533	1.0000	0.9467 ... 0.9999

Observe que al elaborar esta tabla fue necesario calcular la probabilidad del tiempo entre fallas antes de obtener la probabilidad acumulada. Esto se llevó a cabo dividiendo cada frecuencia de ocurrencia entre el número total de observaciones (150). Se incluye también la columna denominada “Intervalo para los números aleatorios”, la que se utilizará para evitar el dibujo de las curvas de distribución acumulada.

Similarmente, se construye la siguiente tabla para la distribución probabilística acumulada del tiempo de servicio de reparación de las máquinas:

Tiempo de servicio (min) t		p(t)	P(tiempo de servicio ≤ t)	Intervalo para los números aleatorios
5 - 15	10	0.05	0.05	0.0000 ... 0.0499
15 - 25	20	0.25	0.30	0.0500 ... 0.2999
25 - 35	30	0.40	0.70	0.3000 ... 0.6999
35 - 45	40	0.25	0.95	0.7000 ... 0.9499
45 - 55	50	0.05	1.00	0.9500 ... 0.9999

Note que en el tiempo de servicio se han registrado dos columnas: la primera corresponde al intervalo del enunciado del problema, y la segunda al punto medio de cada intervalo, valor que será utilizado en la simulación (suponemos una distribución uniforme dentro de cada intervalo).

Se inicia la simulación suponiendo que el día de trabajo comienza a las 8:00 a.m. La simulación terminará al final de un día de trabajo de 8 horas (se corre la simulación hasta las 4 p.m., suponiendo que no existe tiempo libre para el almuerzo).

Cuando ocurre una falla se comienza el servicio de mantenimiento de inmediato si hay disponible una persona de mantenimiento; si no lo está, la máquina pasa a una línea de espera.

Se dará servicio a las máquinas que esperan en la línea sobre la base de que la primera que llega es la primera que se atiende.

Se recopilan datos sobre las características operativas del sistema (sobre los tiempos que las máquinas están en la fila, el número de máquinas que están en la línea de espera y la cantidad de tiempo que cada persona está desocupada), luego se utilizan estas estadísticas para calcular el costo total.

A continuación se presenta los resultados de la simulación cuando existe disponible para mantenimiento un solo empleado.

Con un solo empleado de mantenimiento: (Ver tabla de la página siguiente)

El primer número aleatorio para generar el tiempo en que ocurre la primera falla es 0.6279. Luego el tiempo que pasa hasta la primera falla es de 19 minutos. Por tanto, la primera falla ocurre a las 8:19 a.m. Dado que el trabajador de mantenimiento llegó a trabajar a las 8:00 a.m. se le asigna de inmediato para que empiece el mantenimiento a la máquina descompuesta. Para determinar el tiempo que le llevará dar servicio a la máquina se genera un número aleatorio para el servicio, el cual es 0.4446 que corresponde a un servicio de 30 minutos. Por ello, el servicio para la primera máquina descompuesta se termina a las 8:49 a.m. Dado que el trabajador de mantenimiento tuvo que esperar hasta las 8:19 a.m. antes de que ocurriera la primera falla, el tiempo muerto para este trabajador es de 19 minutos. Y dado que la primera máquina descompuesta no pasó a la línea de espera antes de que se le diera servicio, el operario de la máquina no incurrió en tiempo muerto (Nota: Sí hay un tiempo perdido de este operario, correspondiente al tiempo que dura el mantenimiento, pero este tiempo está en función de la falla y no del servicio de mantenimiento y nosotros, ahora, estamos interesados es en analizar el número adecuado de personas en mantenimiento que incide sobre las pérdidas debido al tiempo de máquinas dañadas); el tiempo muerto en el que estamos interesados es el que pierde el operador por estar esperando el servicio).

Ya que se procesó la primera falla, se continúa con la segunda. El correspondiente número aleatorio para la siguiente falla es 0.8234, que equivale a 20 minutos. Puesto que la primera falla ocurrió a las 8:19, la segunda falla ocurre a las 8:39 a.m. El trabajador de mantenimiento aún está dando servicio a la primera máquina, por lo que la segunda máquina debe pasar a la línea de espera. Hay 10 minutos muertos para el operario de la máquina por causa de esta espera, ya que el servicio de mantenimiento para esta segunda máquina sólo puede comenzar a las 8:49 a.m. (cuando termina el servicio a la primera máquina descompuesta). La longitud de la línea de espera es 1 (última columna de la tabla).

UNIDAD II Muestreo Montecarlo

Falla No.	# aleatorio para la siguiente falla	Tiempo que pasa hasta la siguiente falla (min)	Tiempo de ocurrencia de la falla	Se inicia el servicio	# aleatorio para el servicio	Tiempo de servicio (min)	Termina el servicio	Tiempo muerto del personal de mantenimiento (ocioso)	Tiempo muerto del operario de la máquina	Número de máquinas que esperan servicio
1	0.6279	19	8:19	8:19	0.4446	30	8:49	19	--	--
2	0.8234	20	8:39	8:49	0.6427	30	9:19	--	10	1
3	0.5273	19	8:58	9:19	0.5902	30	9:49	--	21	1
4	0.1820	17	9:15	9:49	0.0318	10	9:59	--	34	2
5	0.6383	19	9:34	9:59	0.5901	30	10:29	--	25	2
6	0.1471	17	9:51	10:29	0.3044	30	10:59	--	38	2
7	0.3208	18	10:09	10:59	0.1699	20	11:19	--	50	2
8	0.8224	20	10:29	11:19	0.5783	30	11:49	--	50	2
9	0.6331	19	10:48	11:49	0.8764	40	12:29	--	61	3
10	0.5482	19	11:07	12:29	0.2112	20	12:49	--	82	3
Sumas		187				270			371	19

Hacia el momento en que ocurre la novena falla, la longitud de la línea de espera ha aumentado a tres y la novena máquina espera 61 minutos antes de que se le comience a dar servicio. Dado que es evidente que la línea de espera continuará aumentando si se tiene un trabajador de mantenimiento, se dan por terminados los cálculos en la décima falla.

2.1.3 TALLER # 1 MÉTODO MONTE CARLO

Hacer simulación para dos trabajadores de mantenimiento. Calcular costos, etc.

2.1.4 TALLER # 2 MÉTODO MONTE CARLO (Shambling/Stevens)

Se supone que la demanda diaria de un artículo particular puede expresarse mediante la siguiente distribución:

<u>Demanda</u>	<u>Probabilidad</u>
0	0.05
1	0.10
2	0.15
3	0.30
4	0.25
5	0.15

Se desea generar un patrón de demanda para 10 días. Utilice intervalos para números aleatorios desde 00 hasta 99. Utilice los siguientes números aleatorios: 14, 74, 24, 87, 07, 45, 26, 66, 26, 94.

TABLA DE NÚMEROS ALEATORIOS (Escaneada de Davis / McKeown)

4764	6279	4446	5582	1634	2396	7984	0892	6049	7488
8416	8234	6427	4959	7344	5582	8579	1652	8767	2934
9434	5273	5902	1824	2809	7556	2486	2963	2006	7914
3420	1820	0318	7041	0746	7468	0788	2913	5730	1305
6827	6383	5901	3555	3049	0858	8872	3181	0495	5501
8521	1471	3044	9717	6203	4840	8645	9348	3101	7983
1129	3208	1699	5571	2923	0382	0032	5459	4610	5684
5806	8224	5783	4674	6696	1011	6599	7695	4470	1598
9285	6331	8764	8461	4031	8934	7259	7712	8980	6963
6955	5482	2161	1838	2875	9525	9769	8136	9966	6852
5937	3445	3694	1834	3496	4466	4629	9659	5169	3131
8044	4611	6072	1084	8306	6117	8550	2526	3276	4537
2219	3193	8224	6791	4229	0579	8448	6988	7886	3739
5570	6273	1455	3007	9751	8758	8610	1781	8456	4518
5496	4841	1443	6085	8950	5867	1830	7652	3884	1657
5054	7303	6255	7005	2068	3442	8084	8559	1254	2478
0661	8875	6251	9846	7295	4338	5145	2204	3691	8096
7321	7051	1108	0625	3440	6284	4179	4339	3666	1786
1799	1989	5595	5457	5435	1938	4324	6299	9208	3997
4934	4071	1456	4076	3090	4586	2596	3397	3189	3251
8262	8374	4637	1581	2275	7185	8938	1194	1403	1840
9586	7055	6472	0928	4832	5912	2768	7070	3751	1718
1882	0684	0933	4112	7413	2027	4233	9662	6926	2455
9670	1291	4890	7457	7666	3246	4877	4168	1609	3896
2039	5973	9776	0099	0272	5058	7182	7786	5649	8697
8416	4676	2229	7245	0700	4369	0390	6289	2870	7244
5670	5432	2966	6749	6488	8453	1751	7768	4356	3516
1198	0414	0140	5503	9564	1048	8107	2043	0830	5920
5263	5133	4011	7164	2389	0693	8934	2723	1078	2653
0385	9999	7544	3593	9120	1661	7054	2791	1173	8148
5169	8408	1074	4192	4800	5589	8279	9855	7618	5088
4031	8123	0927	9697	5585	7698	1450	6706	3222	3469
3457	1531	7016	2007	9172	9358	0468	4212	2238	7065
3859	3643	4141	4584	4035	2295	9716	7871	1234	1723
7228	1267	4020	3840	9324	4281	9163	4899	2737	2626
1165	5407	3768	0190	0135	5534	7293	7472	0754	1557
5089	9780	2195	6766	8383	4123	3447	7244	1091	3490
5544	0016	3828	6315	6349	2892	6764	4509	0942	1833
0840	4942	1475	3908	4765	8715	0892	5274	9646	7686
1186	4425	3216	5570	5255	8678	8967	7269	4330	4904
7678	1351	6002	2999	4725	2305	6893	2079	0195	5658
1892	2323	3188	7864	3646	7732	7501	9132	3081	2445
3382	4579	1513	7065	5765	7341	3386	9137	4236	9718
8149	5468	6474	0654	0441	9946	2749	7297	5046	0704
3519	2481	8907	7830	7936	0624	6938	9750	7356	7141

UNIDAD III

3.1 NÚMEROS ALEATORIOS UNIFORMES (*Prawda*)

Los números aleatorios uniformes se utilizan para introducir el comportamiento estocástico en el sistema bajo estudio. Estos números pueden encontrarse en tablas o generarse en una calculadora, o en una computadora. Para los fines de simulación manual, las tablas son más que suficientes. Si se trata de simular por computadora, las tablas son imprácticas y se requiere de un proceso de autogeneración.

Los números aleatorios son un ingrediente básico en la simulación de casi todos los sistemas discretos. En esta sección se describe la generación de números aleatorios uniformemente distribuidos. Recordemos primero las propiedades de los números aleatorios.

3.1.1 Propiedades de los Números Aleatorios.

Una secuencia de números aleatorios $R_1, R_2, \dots$, debe tener dos importantes propiedades estadísticas: uniformidad e independencia. Cada número aleatorio R_i , es un valor muestral extraído de una distribución uniforme continua entre cero y uno. Es decir su función de densidad de probabilidad esta dada por

$$f(x) = \begin{cases} 1, \dots & \text{para } 0 \leq x \leq 1 \\ 0, \dots & \text{para } \dots \text{otros} \end{cases}$$

$$E(x) = \int_0^x f(x) dx$$

$$V(x) = E(x - E(x))^2 = E(x^2) - [E(x)]^2$$

El valor esperado de cada R_i , está dado por:

$$E(R) = \int_0^1 x dx = \frac{x^2}{2} \Big|_0^1 = \frac{1}{2};$$

y la varianza está dada por:

$$V(R) = \int_0^1 x^2 dx - [E(R)]^2 = \frac{x^3}{3} \Big|_0^1 - \left(\frac{1}{2}\right)^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12};$$

Tarea: Obtenga el valor esperado y la varianza para una variable uniformemente distribuida entre a y b.

Algunas consecuencias de las propiedades de uniformidad e independencia son las siguientes:

- Si el intervalo (0, 1), se divide en n clases, o sub-intervalos de igual longitud, el número esperado de observaciones en cada intervalo es N/n (*que es la frecuencia teórica esperada en un subintervalo*), donde N es el número total de observaciones.
- La probabilidad de observar un valor, en un intervalo en particular es independiente de los valores previamente extraídos.

Los números generados en un computador no son totalmente aleatorios, porque se obtienen de fórmulas preestablecidas que cumplen con una serie de pruebas estadísticas de aleatoriedad. Por esta razón, a estos números se los ha llamado pseudo-aleatorios.

La mayoría de los métodos para generar números aleatorios son iterativos, donde un número pseudo-aleatorio se genera del anterior.

El período del método es el número de generaciones que se debe esperar hasta repetir la secuencia. Es deseable hacer este período lo mayor posible.

Desde el punto de vista de la simulación es más deseable emplear números pseudo-aleatorios que números aleatorios “puros” (los generados mediante procesos físicos estocásticos). Así, el modelo de simulación es más fácil de validar, ya que la secuencia de números puede ser repetida.

3.2 NÚMEROS PSEUDO-ALEATORIOS

Hay varias maneras de producir números, los cuales resultan aleatorios, aunque de hecho son generados por un conjunto de reglas que no son muy complejas. Estos números así generados son llamados pseudo-aleatorios.

Hablando estrictamente, un número aleatorio existe como realización de un proceso estocástico. El proceso de generar variables aleatorias, es entonces idéntico

al proceso de crear, construir, correr, y recoger los datos muestrales de ciertos procesos físicos estocásticos. Hay generadores de números aleatorios electrónicos, mecánicos, radioactivos y otros. Los generadores físicos están libres de muchos de los problemas encontrados en las tablas, como por ejemplo, no necesitan de memoria extra y el rango de los números es ilimitado. Pero como son realmente aleatorios, no pueden reproducirse a voluntad, a menos que se guarden en un archivo especial, pero entonces estaríamos de regreso a las tablas. Es difícil “chequear” la calidad de los números generados, son más lentos que los generados por las computadoras, pero aún se utilizan los generadores físicos conectados a sistemas automáticos de control (y por supuesto en los juegos públicos de *chance*).

El término pseudo-aleatorio ha sido definido por Lehmer D. A (1951) (ver referencia mas adelante) como:

“Una noción vaga que encierra la idea de una sucesión en la cual cada término es *impredecible* para la persona ajena al problema, cuyos dígitos se someten a cierto número de pruebas tradicionales a los estadísticos y depende en cierta forma del uso que se dará a la sucesión”.

La principal objeción (Tocher, 1954) a esta solución radica en los aspectos un tanto filosóficos respecto a que una sucesión de dígitos, generados mediante una regla puramente *determinística*, resulta la *antítesis* directa de una sucesión aleatoria.

Sin embargo, esta objeción puede superarse, al menos parcialmente al tomar el punto de vista un tanto pragmático de que una sucesión puede considerarse aleatoria, si satisface un cierto conjunto de pruebas estadísticas de aleatoriedad, previamente determinadas. Desde éste punto de vista, el método para generar una sucesión es totalmente independiente (irrelevante).

La salida de un generador de números pseudo-aleatorios es siempre una, y la misma, para los mismos datos de entrada. *El uso de números pseudo-aleatorios para simulaciones de procesos estocásticos en una computadora es una contradicción en si misma*. Porqué entonces, se utilizan con tanta frecuencia los números pseudo-aleatorios?. La respuesta no es simple. Un modelo de simulación extrae del sistema real características importantes. *No es obligatorio tener una mejor serie de números aleatorios que la que el sistema real requiera*. En otras palabras no hay necesidad del mejor generador de números aleatorios disponible, *solo* del

generador más apropiado considerando el sistema y el problema que se tenga entre manos.

Los números aleatorios no son una meta en si mismos, sino una herramienta conveniente para resolver cierta clase de problemas. Si números aleatorios *reales* son difíciles de usar (ya mencionamos antes algunas desventajas, como la no reproducibilidad), porqué, entonces no tomar una serie de números que sea fácil de calcular, pero que “*parezcan*” como números realmente aleatorios (que cumplan con las características de aleatoriedad e independencia).

Los números pseudo-aleatorios surgen entonces como un compromiso aceptable entre el ambiente computacional y las necesidades de simulación, como un método general de resolver problemas. La idea es entonces, generar una serie de números aleatorios que puedan aplicarse para resolver problemas concretos y no importa realmente como se conforma la serie (secuencia), si ella pasa una cierta serie de pruebas estadísticas.

Hay ventajas claras, cuando se usan números pseudo-aleatorios, como por ejemplo la flexibilidad. Para un nuevo proceso estocástico solo los datos de entrada (los parámetros y la semilla del generador) deben cambiarse y no el generador mismo. Una vez, está el generador certificado, puede ser utilizado con diferentes datos de entrada produciendo números aleatorios independientes.

Inventar técnicas que parecen generar números aleatorios es fácil, inventar técnicas que realmente produzcan secuencias de números aleatorios uniformemente distribuidos e independientes es increíblemente difícil.

Existen **criterios matemáticos** para evaluar la calidad de un método de generación, por ejemplo:

- Distribución uniforme sobre un intervalo dado, (el intervalo $[0, 1]$ es suficiente para comenzar.
- Los números aleatorios deben ser independientes, es decir no debe existir correlación entre los números producidos.
- El ciclo debe ser tan largo como sea posible. Hay solo una determinada cantidad de números diferentes que puede ser representada en un computador. Tarde que temprano los números pseudo-aleatorios comienzan a repetirse. El tamaño de la secuencia a partir de la cual la secuencia empieza a repetirse se llama período. Por lo tanto, se desea que el período sea lo suficientemente grande, para evitar que los números aleatorios se repitan durante una corrida dada de simulación.

- La serie de números aleatorios debe ser estable, es decir su distribución no debe cambiar con el tiempo.

Desde el punto de vista de implementación (**criterio de implementación**), el método debe tener las virtudes de ser:

- Rápido en ejecución.
- Económico en términos de ejecución. Lo anterior se refiere a la eficiencia computacional, ya que un estudio típico de simulación, requerirá la generación de un volumen grande de números, el generador debe ser rápido y no ocupar excesiva memoria.
- Fácil de usar dentro de un programa.
- Reproducible. Esta propiedad es de vital importancia, ya que permite identificar el efecto de un cambio y aislarlo del efecto que podría dar otra secuencia de números aleatorios.

Casi todos los algoritmos prácticos para generar secuencias de números pseudo-aleatorios son dados a través de la siguiente formula recursiva:

$$r_{i+1} = f(r_i), \dots \text{donde } i = 0, 1, 2, \dots, n$$

Donde el número inicial r_0 , se conoce como semilla y debe ser definido con anterioridad. La escogencia de la función $f(r_i)$, en la ecuación anterior debe hacerse de tal manera que los criterios matemáticos y virtudes, antes enunciados, sean satisfechos.

3.3 GENERACIÓN DE NÚMEROS PSEUDO-ALEATORIOS

Para introducir los conceptos sobre los cuales se basa la generación de números pseudo aleatorios, vamos inicialmente a presentar el método del cuadrado medio. Posteriormente será presentado el método congruencial multiplicativo, en el cual se basan la mayoría de los generadores modernos de números pseudo aleatorios.

MÉTODO DEL CUADRADO MEDIO de Metropolis-Newman (Davis/McKeown)

Propuesto en 1.946 por J. von Newman. Este método funciona utilizando como el siguiente número aleatorio el cuadrado de los dígitos de la mitad del número aleatorio anterior. Específicamente, el método opera como sigue:

1. Seleccione un número aleatorio (arbitrario cualquiera) de n dígitos. (En la terminología de computadoras se conoce como la semilla del generador de números aleatorios).

2. Eleve al cuadrado el número del paso precedente y agregue ceros al lado derecho, si se necesitan, para producir un número de $2n$ dígitos.
3. El nuevo número aleatorio se determina seleccionando los n dígitos de la mitad del número obtenido en el paso 2.
4. Repita los pasos 2 y 3 para obtener números aleatorios adicionales.

Para mostrar el método del cuadrado medio, asumamos que deseamos generar números aleatorios de cuatro dígitos, y que la semilla es 2173. Elevando al cuadrado a 2173 tenemos 4721929, como sólo tiene 7 dígitos, agregar un cero a la derecha, y tenemos 47219290, por tanto el nuevo número aleatorio es 2192. Si elevamos al cuadrado 2192 tenemos 4804864, al agregar un cero tenemos 48048640 y por tanto el siguiente número aleatorio será 0486. Utilizando el mismo procedimiento el cuarto número aleatorio será 6196.

Como se notó en nuestra simulación manual, algunas veces se requieren números aleatorios entre cero (0) y uno (1). Con el método del cuadrado medio basta con colocar un punto decimal a la izquierda. Por ejemplo, los primeros cuatro números aleatorios serían: .2173, .2192, .0486, .3619.

En la práctica se ha encontrado que los números aleatorios generados con el método del cuadrado medio tienden a tener un período muy corto antes de que ocurra la repetición. Además, en muchos casos, se vio que no pasaban los tests diseñados para chequear la aleatoriedad.

3.3.1 MÉTODOS BASADOS EN NÚMEROS CONGRUENTES

La mayoría de los generadores modernos de números aleatorios están basados en números congruentes. A continuación se dan algunas definiciones que se necesitan en la presentación de los métodos de congruencia para la generación de números pseudo aleatorios, a saber, a) números congruentes y b) residuos.

Algunas Definiciones Básicas

Números Congruentes.


Supóngase que se da un número positivo, m , el cual se llama *modulo*. Se dice que los enteros a y b , son congruentes en modulo m , si $(a-b)$ es algún múltiplo entero

de m (o en otras palabras, si $(a-b)$ es divisible por m sin ningún residuo).

Esto es si existe algún entero k al que:

$$(a-b) = km$$

Otra forma de expresar la anterior relación:



$a = km + b$, en la cual a juega el papel de dividendo, m de divisor, k de cociente y b de residuo, (o en otra forma $b = a - km$)

La relación $(a-b) = km$, se escribe generalmente como:

$a \equiv b \pmod{m}$, donde el símbolo, $\equiv$, denota *congruencia*, y la expresión completa debe leerse como: a es congruente con b en módulo m .

Por claridad, vea el siguiente ejemplo:

Supóngase un valor dado $m=8$. Las siguientes parejas de enteros son congruentes en modulo 8.

(8, 0), porque $8-0 = 8 = 1*8$, con $k=1$;
 (11, 3), porque $11-3 = 8 = 1*8$, con $k=1$;
 (35, 3), porque $35-3 = 32 = 4*8$, con $k=4$.

Estas relaciones de congruencia se expresan como:

$8 \equiv 0 \pmod{8}$; que se lee 8 es congruente con 0 en modulo 8.
 $11 \equiv 3 \pmod{8}$; que se lee 11 es congruente con 3 en modulo 8.
 $35 \equiv 3 \pmod{8}$; que se lee 35 es congruente con 3 en modulo 8.

Como obtener entonces un número b que sea congruente con a en módulo m ?. La forma más fácil es dividir a por el modulo m , y tomar el residuo como b , número congruente entonces con a en modulo m . Por ejemplo, que número sería congruente con $a = 425$ en modulo $m = 90$?. Dividiendo 425 entre 90 tenemos un cociente de 4 con un residuo de 25. Este residuo $b = 25$ es congruente con $a = 425$ en modulo $m = 90$.

Finalmente, definamos *residuos*, antes de entrar en el método para generar números aleatorios uniformemente distribuidos.

Residuos

Para un entero a , el menor entero r no negativo que es congruente con a en modulo m , se llama *residuo* en modulo m . Así, usando la forma como se expresan los números congruentes tenemos:

$$r \equiv a \bmod m, \text{ con } 0 \leq r < m$$

Siendo r , estrictamente menor a m , nunca se generará un número igual a m , ya

que el número generado es igual a $\frac{r_{i+1}}{m}$.

Así, para dado a , existen muchos otros números que son congruentes con a en modulo m . Sin embargo, solo hay **uno no negativo menor a m** que es el residuo. Por ejemplo, determinar el correspondiente residuo de $a=13$ en modulo $m=8$. El residuo de $a=13$ en modulo $m=8$ (recuerde, se llama residuo el menor entero no negativo que es congruente con a en modulo m), es $r=5$, puesto que 5 y 13 son congruentes en modulo, $m=8$ ($5 \equiv 13 \bmod 8$). El número 13, tiene 8 números congruentes distintos, (ya que el rango de sus valores va de 0 a $m-1$), siendo el menor de ellos el número 5, el cual se constituye en el residuo.

Método de Congruencia Multiplicativo

Aquí se discute un generador de números aleatorios muy popular basado en el uso de los residuos de potencia. Este método también se conoce con el nombre de Método de Congruencia Multiplicativo.

La función de residuos es muy simple:

$$r_{i+1} = br_i \pmod{m}, \text{ con } i = 0, 1, 2, \dots$$

O en los términos de residuos, r_{i+1} , es el residuo de $r_i * b$, en módulo m . (r_{i+1} , es el menor entero no negativo que es congruente con $r_i * b$ en modulo m). Esta función es conocida como el generador multiplicativo de Lehmer (inicialmente propuesto por Lehmer¹ en 1951).

Este método congruencial produce una secuencia de enteros, $r_1, r_2, \dots$ entre cero y $m-1$, de acuerdo con la relación de recurrencia anterior. Así, el número máximo de números que se produce en la secuencia es m , y además el mayor valor generado siempre será menor a m , recuerde que: $r \equiv a \pmod{m}$, con $0 \leq r < m$.

Siempre, podemos dividir r_{i+1} por m , siendo el resultado $\frac{r_{i+1}}{m}$, una variable aleatoria uniforme R , en el intervalo $[0,1]$.

Reglas del Método Congruencial Multiplicativo

Una no acertada escogencia de los parámetros en el método congruencial multiplicativo hace que el período sea corto. Por ejemplo, analice el caso con $m=90$, $B=10$ y semilla $r_0=10$, para que note que comienza a ciclar el valor generado. Así, que es necesario escoger bien los parámetros.

La ecuación $r_{i+1} = br_i \pmod{m}$, es fácil de calcular y efectivamente genera números aleatorios, dado que m , r_0 , y b , sean escogidos con cuidado, es decir de acuerdo con ciertas reglas para que la secuencia de $\{r_{i+1}\}$, presente un comportamiento aleatorio aceptable.

Veamos algunas de las reglas:

- 1) El valor inicial r_0 , (frecuentemente llamado semilla) puede ser arbitrario (pero no mayor a m).
- 2) El modulo m debe ser escogido tan grande como sea posible con el objeto de maximizar el período de la secuencia de los números aleatorios. La escogencia de m esta usualmente determinada por el tamaño de la palabra

¹ LEHMER, D. H [1951], *Proceedings of the Second Symposium on Large Scale Digital Computing Machinery*, Harvard University Press, Cambridge, MA.

del computador. Se escoge $m = 2^{p-1}$, cuando el método se implementa en un computador digital, con p – números de bits por palabra. El máximo entero que puede expresarse en un computador de p bits por palabra es 2^{p-1} :

$$I_{\max} = 2^0 + 2^1 + 2^2 + 2^3 + \dots + 2^{(p-1)-1} = \sum_{i=0}^{p-2} 2^i = 2^{p-1}$$

Entonces, esta escogencia esta forzada por la estructura interna del hardware del computador. Es de especial importancia que la división por modulo sea calculada exactamente sin errores de redondeo (m debe ser el mayor número primo menor a 2^{p-1} ; para la aritmética de 16 bits ésta condición implica que $m < 32768$, tales números primos pueden ser: 32749, 32719, 32717, 32713, 32707, como también muchos otros.

3) El multiplicador b , debe elegirse de tal manera que la correlación entre los $\{r_i\}$ sucesivos sea minimizada. Esto se puede conseguir si se satisfacen las siguientes condiciones que mejoran la calidad del generador:

- b , debe escogerse cerca de $2^{\frac{p}{2}}$, para asegurar baja correlación.
- b , debe ser de la forma $8j \pm 3$, o $8j \pm 5$, donde j es un entero positivo.
- b , debería ser mayor a $\sqrt{m}$, preferiblemente mayor que $m/100$, pero menor a $\lceil m - \sqrt{m} \rceil$.

Así que m controla el período, y b , busca minimizar las correlaciones entre r_i sucesivos.

Nótese que diferentes semillas, r_0 , pueden usarse para generar secuencias diferentes de números aleatorios, aun cuando el modulo m , y el multiplicador b , permanezcan constantes.

Cuando los valores m , b y r_0 , se escogen de acuerdo con los criterios anteriores, la secuencia resultante de números aleatorios tendrá un período igual a $m/4$, esto es el número, de números aleatorios repetidos en la secuencia es $m/4$.

Vea el siguiente ejemplo. Determine el conjunto de valores apropiados m , b y r_0 , para un generador de números aleatorios usando el método congruencial multiplicativo, en un computador que tiene $p=12$ bits por palabra.

El valor de m , es entonces: $m = 2^{p-1} = 2^{12-1} = 2048$.

Sea $b = 67$, ya que este valor satisface:

- b , debe ser cerca de $2^{\frac{p}{2}}$ ($67 \approx 2^{\frac{12}{2}} = 2^6 = 64$)
- b , debe ser de la forma $8j \pm 3$, o $8j \pm 5$, ya que $8*8 \pm 3 = 67$, con $j = 8$. Donde j es un número positivo.
- Finalmente, el valor arbitrario de la semilla $r_0 = 129$, ya que es un valor entero positivo impar menor que m .

Si se aplica la ecuación recursiva, $r_{i+1} = br_i \pmod{m}$, (con $i = 0, 1, 2, \dots$), se obtiene la siguiente secuencia:

$$r_1 \equiv 67 * 129 \pmod{2048} = 451 = r_1,$$

$$r_2 \equiv 67 * 451 \pmod{2048} = 1545 = r_2$$

$$r_3 \equiv 67 * 1545 \pmod{2048} = 1115 = r_3$$

Y así sucesivamente se generan los $m/4 = 2048/4 = 512$, números aleatorios no repetidos de esta secuencia. Después de r_{512} , la secuencia empieza a repetirse y aparecerá $r_{513} = 451$, igual a r_1 , $r_{514} = 1545$, igual a r_2 , y así sucesivamente.

La prueba fundamental del método congruencial multiplicativo, como para cualquier esquema de generación, esta en analizar que tan bien los números generados, $r_1, r_2, \dots$, reproducen las características de uniformidad e independencia

3.3.2 OTROS MÉTODOS (método utilizado por el G.P.S.S)

La cuestión de la generación de números aleatorios, y los chequeos a que deben ser sometidos para estar seguros de que en realidad son números aleatorios es lo suficientemente amplia y compleja para ser sujeto de un libro completo. En cambio, muchos investigadores han gastado bastante tiempo y esfuerzo diseñando algoritmos de generación de números aleatorios y aplicando tests estadísticos para asegurarse de su efectividad.

En muchos casos, el analista de un modelo de simulación simplemente toma las funciones generadoras que ofrecen los fabricantes de computadoras. Desafortunadamente, hay un gran riesgo al utilizar el generador disponible sin un chequeo previo de su confiabilidad. No todos los generadores de números aleatorios son buenos.

De todas maneras, en esta sección se va a considerar un posible algoritmo para esta generación.

MÉTODO UTILIZADO POR EL G.P.S.S. (Schriber)

El lenguaje G.P.S.S. será comentado más ampliamente en otra unidad.

Por ahora, vamos a mirar el algoritmo utilizado por este lenguaje. El algoritmo en sí es muy simple. Asumamos que el objetivo es generar números aleatorios de cuatro dígitos distribuidos uniformemente sobre el intervalo 0.0000 y 0.9999, inclusive. Para hacer esto, el algoritmo utiliza dos números enteros impares, cada uno conteniendo hasta cuatro dígitos. El primero de estos números, que se llamará semilla, nunca cambia de valor. El segundo de estos números, que se llamará multiplicador, cambia en su valor cada vez que el algoritmo se utilice para generar el siguiente número aleatorio.

Cuando se necesita un nuevo número aleatorio, el primer paso del algoritmo es multiplicar la semilla por el multiplicador. Esto resulta (por lo general) en un número de ocho dígitos. Este nuevo número se utilizará para tanto para suministrar un nuevo valor para el multiplicador (anticipándose a la próxima utilización del algoritmo) como para suministrar el número aleatorio deseado. En particular, los cuatro dígitos de la derecha serán utilizados para el nuevo valor del multiplicador, y los cuatro dígitos de la mitad serán usados como el número aleatorio deseado (colocando el punto decimal en su lugar correspondiente).

Consideremos un ejemplo numérico para este algoritmo. Escojamos 3329 como semilla y 8107 como multiplicador inicial. Analice cuidadosamente la siguiente tabla para entender la lógica del algoritmo. La inspección de esta tabla debe conducir a la conclusión de que es imposible para el algoritmo generar un número menor que .0000 ni mayor que .9999.

Multiplicador	Producto de 8 dígitos	Número aleatorio resultante
8107	26988203	.9882
8203	27307787	.3077
7787	25922923	.9229
2923	9730667	.7306
667	2220443	.2204
443	1474747	.4747
4747	15802763	.8027
2763	9198027	.1980

8027

etc.

Ahora consideremos otro ejemplo numérico de este algoritmo, que utiliza 5167 como semilla y 8081 como multiplicador inicial. El resumen se presenta en la siguiente tabla. De esta tabla es conveniente considerar que en el quinto paso del algoritmo el valor del multiplicador es uno (1).

Multiplicador	Producto de 8 dígitos	Número aleatorio resultante
8081	41754527	.7545
4527	23391009	.3910
1009	5213503	.2135
3503	18100001	.1000
1	5167	.0051
5167	26697889	.6978
etc.		

Esto no tiene problema, pero trae a la mente la pregunta de “¿qué pasaría si el multiplicador llega a valer cero?” (Según el diseño del algoritmo, el producto de la semilla por el multiplicador sería cero, por lo tanto el número aleatorio sería .0000, y de ahí en adelante todos los números aleatorios generados serían cero). Precisamente, para evitar esta posibilidad, tanto la semilla como el multiplicador deben ser números impares. El producto de dos números impares es a la vez un número impar. Por tanto, la parte derecha del producto nunca podrá ser cero, lo que significa que el multiplicador nunca tomará el valor de cero.

Ahora, para analizar otra característica de los generadores, tomemos un tercer ejemplo. Aquí se utilizará a 1235 como semilla y 625 como multiplicador inicial. El resumen está en la siguiente tabla.

Multiplicador	Producto de 8 dígitos	Número aleatorio resultante
625	771875	.7718
1875	2315625	.3156
5625	6946875	.9468
6875	8490625	.4906
625	771875	.7718
1875	2315625	.3156
5625	6946875	.9468
etc.		

Estos tres ejemplos tratan de mostrar el concepto de “reproducibilidad” de los números aleatorios. Tan pronto como se han escogido tanto la semilla como el multiplicador inicial, la secuencia de números aleatorios está completamente determinada. Por esto se dice que los números generados no son realmente aleatorios, se les llama pseudo-aleatorios.

La reproducibilidad de la secuencia de los números aleatorios no es una mala cosa. Esta propiedad de reproducibilidad hace posible reproducir la secuencia precisa de los eventos que ocurren cuando se ejecuta un experimento de simulación. Esto significa que configuraciones alternativas del sistema (por ejemplo un simple cambio de parámetros) pueden ser estudiadas bajo idénticos conjuntos de condiciones experimentales.

El último ejemplo repite el número aleatorio en el quinto paso. El número de números aleatorios producidos antes de que la secuencia vuelva a repetirse se llama “período” (o “longitud”) del generador. Un generador de números aleatorios que tenga un período de 5.000 puede considerarse adecuado para propósitos de experimentación real. Sin embargo, es fácil incrementar este período utilizando una semilla y un multiplicador de más de cuatro dígitos.

El lenguaje de simulación GPSS de la IBM utiliza ocho generadores de números aleatorios, que tienen lógicas similares a la estudiada aquí. Las diferencias esenciales son:

1. El algoritmo de nuestro ejemplo utiliza como semillas y multiplicadores iniciales números enteros impares entre 1 y 9999, inclusive. En el esquema del lenguaje GPSS pueden variar entre 1 y 2.147.483.647, inclusive.
2. Cada generador tiene ocho semillas a su disposición. Los valores de estas semillas son:

1.909'996.635	37'584.381	1.964'463.183
1.235'671.459	1.480'745.561	442'596.621
2.030'226.625		340'029.185
3. Naturalmente, según los ejemplos estudiados, este algoritmo únicamente requiere la utilización de una semilla. Sin embargo, GPSS escoge al azar una de las semillas antes de la generación de los números aleatorios.
4. Supongamos que uno de los ocho generadores se llama para producir un número aleatorio. Primero, el valor corriente de su multiplicador se multiplica por una de las semillas (escogida al azar). El producto resultante se usa para tres propósitos:

- La mitad derecha del producto se convierte en el siguiente valor del multiplicador de ese generador.
 - Una porción interior del producto se usará como el número aleatorio.
 - Otra porción interior del producto se usará para determinar aleatoriamente cuál de las ocho semillas deberá escogerse la próxima vez que un número aleatorio deba ser producido por el generador.
5. GPSS usa internamente el sistema binario, no el sistema decimal que se utilizó en nuestros ejemplos numéricos.
6. Finalmente, GPSS obliga a cualquiera de los ocho generadores a usar la semilla 37'584.381 la primera vez que se requiera un número aleatorio. Sin embargo, da opción al analista para que introduzca cualquier valor como multiplicador inicial para cada generador, con la condición de que sea un número entero, impar, con máximo cinco dígitos. Si el analista decide no utilizar esta opción, GPSS obliga a cada uno de los ocho generadores a utilizar como multiplicador inicial el número 37. (Esto implica que si el analista no suministra los multiplicadores iniciales, cada generador producirá la misma secuencia de números aleatorios debido a que la semilla inicial es la misma, y a que, debido al procedimiento explicado, la segunda semilla, así sea escogida aleatoriamente, utilizará el mismo criterio de selección para cada generador).

3.4 TESTS ESTADÍSTICOS PARA NÚMEROS ALEATORIOS

Las propiedades deseables de los números aleatorios son la uniformidad y la independencia. Para asegurar que estas propiedades deseables se están satisfaciendo una serie de pruebas (tests) deben ser adelantadas.

Hay **test empíricos**, los cuales son aplicados a la secuencia de números realmente producida por el generador.

Hay **test teóricos**, los cuales evalúan la escogencia de los parámetros b , m , de las ecuaciones de recurrencia ($r_{i+1} = br_i \pmod{m}$) sin realmente generar ningún número, siendo el mas común el test espectral².

² Ver pagina 425 del libro de Kelton citado en la bibliografía.

Los **tests empíricos** pueden ser clasificados en dos categorías de acuerdo con la propiedad a ser evaluada: Pruebas para **uniformidad** y pruebas para **independencia**.

Los números pseudoaleatorios necesitan satisfacer dos criterios (criterio de uniformidad y criterio de independencia):

1. Deben seleccionarse de una distribución uniforme en el intervalo cerrado $[0,1]$.
2. El orden de su secuencia debe ser aleatorio.

Para probar (1) existen una serie de pruebas estadísticas como la *Kolmogorov-Smirnov* y la *ji-cuadrada*. Para (2) se utilizan otras pruebas estadísticas, como la de *Corrida*.

3.4.1 Pruebas (tests) para uniformidad

Una prueba básica que debe siempre ser realizada para validar un nuevo generador es el test de Uniformidad. Existen disponibles dos métodos diferentes:

1. El test de Kolmogorov-Smirnov, y
2. El Chi Cuadrado

Ambos pruebas comparan el grado de acuerdo entre la distribución del conjunto de datos generados y la distribución uniforme teorica (por eso son conocidos como Tests de Frecuencias).

3.4.2 Pruebas (tests) para independencia

1. Runs Tests (Pruebas de Corridas). Hay varios tipos de pruebas:
 - a. Test de Corridas hacia arriba y corridas hacia abajo. El número de corridas hacia arriba y hacia abajo para una distribución uniforme es una variable aleatoria con un valor esperado y una varianza que teóricamente puede ser calculado. Para una $N > 20$, el número de corridas sigue una distribución aproximadamente normal y puede construirse un estadístico que sigue una distribución normal. Esta aproximación es usada para testar la independencia de los números generados (ver mas adelante sección 3.6).

- b. Test de Corridas por encima y por debajo de la media. El test anterior (Corridas hacia arriba y hacia abajo), no es suficiente para asegurar la independencia de un grupo de números. Podría darse el caso en un conjunto de 40 números que pasen el test anterior, donde los 20 primeros números estén por encima de la media, y los siguientes 20 por debajo de ella. Para un número de corridas por encima y por debajo de la media, para una distribución uniforme, se tienen un valor esperado y una varianza que teóricamente puede ser calculado. Puede formarse un estadístico que sigue una distribución aproximadamente normal. Esta aproximación es usada para testar la independencia de los números generados.
 - c. Longitud de las corridas. Se puede dar el caso, en un conjunto de números en el cual por ejemplo, en una secuencia se tengan dos números por encima de la media seguidos por dos números por debajo de la media. El test b, anterior, no detectaría éste problema de falta de independencia. Debe esperarse que en números aleatorios independientes longitudes de corrida diferentes a dos ocurran. El valor esperado del número de corridas de determinada longitud para una variable aleatoria uniforme puede ser calculado analíticamente y comparado con las observadas usando una prueba Chi-Cuadrado como estadístico de prueba.
- 2. Test de Autocorrelación. Puede darse el caso de que en determinadas posiciones de la secuencia de números (por ejemplo en la 5ª, 10ª, 15ª posición, ó cada 5 números) se encuentren siempre números grandes. Pero esto está indicando que los números en la secuencia podrían estar relacionados (o tener solo números pequeños en determinadas posiciones, o ellos en esas posiciones estar alternado de pequeños a grandes). En esta prueba se construye un estadístico de autocorrelaciones que sigue una distribución aproximadamente normal que sirve como estadístico de prueba
 - 3. Test Gap. Esta prueba es usada para determinar el intervalo entre las recurrencias del mismo dígito. La distribución de probabilidad teórica para un número ordenado de dígitos es calculada y comparada con los datos con las frecuencias observadas mediante el test de Kolmogorov-Smirnov.
 - 4. Test de Poker. Esta prueba de independencia está basada en la frecuencia con la cual ciertos números se repiten en una serie de números. La probabilidad para la ocurrencia de cada caso puede calcularse teóricamente y

comparada con las frecuencias observadas mediante la prueba Chi-Cuadrado.

A continuación se explican e ilustran dos técnicas no paramétricas (Kolmogorov-Smirnov y Corrida).

3.5 Prueba de Kolmogorov-Smirnov (*Prawda*)

Esta prueba sirve para verificar o negar la hipótesis nula de que un conjunto de observaciones provienen de una determinada distribución (en nuestro actual caso, los datos provienen de una distribución uniforme entre 0 y 1). La estadística D que se utiliza en esta prueba es una medida de la diferencia máxima absoluta observada entre la distribución empírica (dada por las observaciones) y la teórica supuesta. La estadística D es obviamente una variable aleatoria.

$$D = \text{Máx } |F_n(X_i) - X_i|, \quad 0 \leq X_i \leq 1$$

A continuación se detalla cómo se utiliza esta prueba para verificar o negar que un conjunto de números pseudoaleatorios tiene una distribución uniforme en un intervalo cerrado $[0,1]$. Naturalmente, los mismos pasos son aplicables a cualquier otra distribución teórica.

Paso 1:

Se formula la hipótesis, H_0 de que los números provienen de una distribución uniforme en el intervalo cerrado $[0,1]$.

Paso 2:

Se selecciona una muestra de tamaño n de números pseudoaleatorios generados por ejemplo por un generador congruencial multiplicativo. (Knuth, The Art of Computer Programming, recomienda $n=1000$). Sea X_i el valor del i -ésimo número (del número que se encuentra en la posición i -ésima).

Paso 3:

Calcule la distribución **acumulada empírica** de la siguiente manera:

3.1. Ordene los valores de la secuencia empírica (por ejemplo la generado por el método congruencial multiplicativo), tal que $X_i \leq X_{i+1}$ para toda i . **¡Observe que ésta secuencia ordenada al ir creciendo entre 0 y 0.99 configura empíricamente una distribución acumulada³ i .**

Calcule la distribución **acumulada teórica** (para una variable uniformemente distribuida entre 0 y 1) de la siguiente manera:

3.2 Haga: $F_n(X_i) = i/n$, $i=1,2,\dots,n$. y $F_n(0) = 0$. i , denota la posición de la observación generada.

Teóricamente la probabilidad de cada valor de una variable aleatoria discreta, uniformemente distribuida entre 0 y 1 es igual a $1/n$. Luego la probabilidad acumulada hasta un valor X_i , va a depender de la posición i de ese valor y va a ser igual a $F_n(X_i) = i/n$. Es decir acumula $1/n$, tantas veces como posiciones existan hasta X_i .

Paso 4:

Evalúe la estadística de Kolmogorov-Smirnov, D , a partir de

$$D = \text{Máx } |F_n(X_i) - X_i|, \quad 0 \leq X_i \leq 1$$

Paso 5:

Consulte la tabla de límites aceptables para la prueba de Kolmogorov-Smirnov, para un tamaño de muestra n y un determinado nivel de riesgo α (Vea mas adelante la tabla de límites de aceptación para el test de Kolmogorov Smirnov, mas). Si D es menor o igual a este número se acepta H_0 ; de otra manera se rechaza H_0 .

Ejemplo:

De una tabla de números aleatorios se eligen los siguientes 50 (divididos entre 100 para que su valor oscile entre 0 y 1).

0.10 0.97 0.70 0.13 0.34

³ La definición de una distribución acumulada empírica par valores uniformemente distribuidos entre 0 y 1, según Banks (ver referencia bibliográfica), pag 266, es: $S_n(x) = R_1, R_2, \dots, R_n$. Es decir la probabilidad acumulada hasta el valor x es la posición n de ese número en la secuencia ordenada.

UNIDAD III Números Aleatorios Uniformes, Generación de números aleatorios y Pruebas de Aleatoriedad

0.37	0.04	0.64	0.74	0.24
0.08	0.68	0.19	0.09	0.23
0.99	0.02	0.09	0.70	0.38
0.12	0.99	0.80	0.36	0.64
0.66	0.74	0.34	0.94	0.36
0.31	0.10	0.45	0.82	0.35
0.85	0.77	0.02	0.65	0.68
0.63	0.32	0.05	0.74	0.90
0.73	0.42	0.03	0.64	0.35

Paso 1: Se desea probar la hipótesis H_0 : Proviene de una distribución uniforme en $[0,1]$, a un nivel de significancia del 90 %.

Paso 2: Se selecciona una muestra de tamaño n de números pseudo-aleatorios.

0.10	0.97	0.70	0.13	0.34
0.37	0.04	0.64	0.74	0.24
0.08	0.68	0.19	0.09	0.23
0.99	0.02	0.09	0.70	0.38
0.12	0.99	0.80	0.36	0.64
0.66	0.74	0.34	0.94	0.36
0.31	0.10	0.45	0.82	0.35
0.85	0.77	0.02	0.65	0.68
0.63	0.32	0.05	0.74	0.90
0.73	0.42	0.03	0.64	0.35

Paso 3:

3.1. Se arregla la tabla anterior para que se cumpla la condición $X_i \leq X_{i+1}$ para toda posición i .

1	0.02	11	0.12	21	0.35	31	0.64	41	0.74
2	0.02	12	0.13	22	0.36	32	0.65	42	0.77
3	0.03	13	0.19	23	0.36	33	0.66	43	0.80
4	0.04	14	0.23	24	0.37	34	0.68	44	0.82
5	0.05	15	0.24	25	0.38	35	0.68	45	0.85
6	0.08	16	0.31	26	0.42	36	0.70	46	0.90
7	0.09	17	0.32	27	0.45	37	0.70	47	0.94
8	0.09	18	0.34	28	0.63	38	0.73	48	0.97
9	0.10	19	0.34	29	0.64	39	0.74	49	0.99
10	0.10	20	0.35	30	0.64	40	0.74	50	0.99

3.2 Si, $i=1$, entonces, $F_n(X_1) = 1/50 = 0.02$,
Se construye $F_n(X_i)$ para toda posición i , siendo $n = 50$.

$F_n(0.00)=0.00$	$F_n(0.12)=0.22$	$F_n(0.35)=0.42$	$F_n(0.64)=0.62$	$F_n(0.74)=0.82$
$F_n(0.02)=0.04$	$F_n(0.13)=0.24$	$F_n(0.36)=0.46$	$F_n(0.65)=0.64$	$F_n(0.77)=0.84$
$F_n(0.03)=0.06$	$F_n(0.19)=0.26$	$F_n(0.37)=0.48$	$F_n(0.66)=0.66$	$F_n(0.80)=0.86$
$F_n(0.04)=0.08$	$F_n(0.23)=0.28$	$F_n(0.38)=0.50$	$F_n(0.68)=0.70$	$F_n(0.82)=0.88$
$F_n(0.05)=0.10$	$F_n(0.24)=0.30$	$F_n(0.42)=0.52$	$F_n(0.70)=0.74$	$F_n(0.85)=0.90$
$F_n(0.08)=0.12$	$F_n(0.31)=0.32$	$F_n(0.45)=0.54$	$F_n(0.73)=0.76$	$F_n(0.90)=0.92$
$F_n(0.09)=0.16$	$F_n(0.32)=0.34$	$F_n(0.63)=0.56$		$F_n(0.94)=0.94$
$F_n(0.10)=0.20$	$F_n(0.34)=0.38$			$F_n(0.97)=0.96$
				$F_n(0.99)=1.00$

Paso 4: Se evalúa : $D = \text{Máx} | F_n(X_i) - X_i | = 0.12$

Es decir, se busca la mayor de las desviaciones en valor absoluto, para lo cual se deben calcular todas las desviaciones entre los valores de probabilidad acumula teórica y los valores de probabilidad acumulada empírica.

El valor D máximo ocurre para $F_n(0.38)$, que esta en la posición $n=25$, es decir con una probabilidad acumulada teórica de $0.02 * 25 = 0.50$

Paso 5: Para un nivel de significancia del 90 % y una muestra de 50 números se tiene de la tabla Kolmogorov-Smirnov de fin de sección un valor de 0.172

Como $D = 0.12 < 0.172$ se acepta H_0 , o sea, los números sí provienen de una distribución uniforme en el intervalo cerrado $[0,1]$.

TABLA DE LÍMITES DE ACEPTACIÓN PARA EL TEST DE KOLMOGOROV-SMIRNOV.

(Tomado del texto PROBABILITY AND STATISTICAL INFERENCE
Autores: Robert V. Hogg y Elliot A. Tanis)

n	$\alpha = 0.20$	$\alpha = 0.10$	$\alpha = 0.05$	$\alpha = 0.01$
1	0.90	0.95	0.98	0.99
2	0.68	0.78	0.84	0.93
3	0.56	0.64	0.71	0.83
4	0.49	0.56	0.62	0.73
5	0.45	0.51	0.56	0.67
6	0.41	0.47	0.52	0.62
7	0.38	0.44	0.49	0.58
8	0.36	0.41	0.46	0.54
9	0.34	0.39	0.43	0.51
10	0.32	0.37	0.41	0.49

11	0.31	0.35	0.39	0.47
12	0.30	0.34	0.38	0.45
13	0.28	0.32	0.36	0.43
14	0.27	0.31	0.35	0.42
15	0.27	0.30	0.34	0.40
16	0.26	0.30	0.33	0.39
17	0.25	0.29	0.32	0.38
18	0.24	0.28	0.31	0.37
19	0.24	0.27	0.30	0.36
20	0.23	0.26	0.29	0.35
25	0.21	0.24	0.26	0.32
30	0.19	0.22	0.24	0.29
35	0.18	0.21	0.23	0.27
40	0.17	0.19	0.21	0.25
45	0.16	0.18	0.20	0.24

n	$\frac{1.07}{\sqrt{n}}$	$\frac{1.22}{\sqrt{n}}$	$\frac{1.36}{\sqrt{n}}$	$\frac{1.63}{\sqrt{n}}$
> 45				

Nota: podría también probarse la misma hipótesis de que los 50 números del ejemplo analizado provienen de una distribución uniforme entre 0 y 1, mediante una prueba de ajuste Chi cuadrado, como se presentará en la sección 5.4.1

3.6 Prueba de corridas hacia arriba y hacia abajo (Runs up and Runs down Test) (Prawda)

Una corrida se define como un conjunto de números que aparecen ordenados en forma monótonamente creciente o decreciente. Por ejemplo: 03, 23, 57, 92, 99 contiene una sola corrida, mientras que 03, 99, 23, 50, 92, 57 contiene cuatro corridas (03, 99), (99, 23), (23, 50, 92), (92, 57).

Si se utiliza el signo “+” para identificar que el número que aparece a la derecha de otro es mayor, o - si es menor, se tiene que:

$$03, 10, 23, 57, 92, 99 \Rightarrow +, +, +, +, +$$

mientras que

$$03, 99, 23, 50, 92, 57 \Rightarrow +, -, +, +, -$$

Esta prueba analiza el arreglo de los números de una secuencia para probar la hipótesis sobre independencia, y se basa en el supuesto que el número de corridas es una variable aleatoria. Se ha demostrado que si una secuencia tiene más de 20 números, el número de corridas es una variable aleatoria distribuida normalmente con media y varianza conocida.

La prueba se realiza de la siguiente manera:

Paso 1:

Se formula la hipótesis H_0 : La secuencia de números es aleatoriamente independiente

Paso 2:

Se selecciona una muestra de tamaño n ($n > 20$).

Paso 3:

Se definen con los signos + y - las posibles corridas.

Paso 4:

Se define a la estadística r , que es una variable aleatoria definida como el número de corridas.

Paso 5:

Si $n > 20$ y H_0 es verdadera (la secuencia de números es aleatoria e independiente), entonces r se aproxima a una distribución normal con media

$$E(r) = \frac{1}{3}(2n - 1)$$

y varianza

$$Var(r) = \frac{1}{90}(16n - 29)$$

Paso 6:

Se acepta H_0 , a un nivel de riesgo α , si

$$\frac{\alpha}{2} \leq Z \left(\frac{r - E(r)}{\sqrt{Var(r)}} \right) \leq 1 - \frac{\alpha}{2}$$

donde $Z(\cdot)$ está tabulada en la distribución normal estandar (recuerde su curso de estadística), así:

$$Z(a) = \int_{-\infty}^a \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \quad \text{O sea, el área acumulada hasta el valor } a.$$

Ejemplo:

Se tiene la siguiente secuencia de números pseudoaleatorios (note que se han agregado los signos + y - para identificar las corridas).

10	37	08	99	12	66	31	85	63	73
+	-	+	-	+	-	+	-	+	-
32	04	68	02	99	74	10	77	32	42
-	+	-	+	-	+	-	+	-	+
76	64	19	09	80	34	45	02	05	03
-	-	-	+	-	+	-	+	-	+
13	74	09	70	36	76	82	64	74	64
+	-	+	-	+	+	-	+	-	-
34	24	23	38	64	36	35	68	90	35
-	-	+	+	-	-	+	+	-	

Aquí, $n = 50$. Observando la tabla se tiene que $r = 36$. Entonces:

$$E(r) = \frac{1}{3}(2n - 1) = \frac{1}{3}(100 - 1) = 33$$

$$Var(r) = \frac{1}{90}(16n - 29) = \frac{1}{90}(800 - 29) = 8.57$$

$$\frac{r - E(r)}{\sqrt{Var(r)}} = \frac{36 - 33}{\sqrt{8.57}} = 1.02 \rightarrow \text{valor de la variable que sigue una distri-}$$

bución normal estandarizada.

De unas tablas de distribución normal se calcula el valor de probabilidad acumulada hasta $z = 1.02$, así se tiene:

$$Z(1.02) = 0.8461$$

Por lo que para un nivel de significancia, por ejemplo del 10 %, tenemos:

$$\frac{\alpha}{2} \leq Z(1.02) \leq 1 - \frac{\alpha}{2}$$
$$0.05 \leq 0.8461 \leq 0.95$$

Por lo que se acepta la hipótesis H_0 : La secuencia de números es independiente.

Nota_1:

Otra forma de tomar la decisión para un nivel de significancia del 10 %, es comparar el valor $z = 1.02$ obtenido con los valores críticos para un nivel de riesgo $\alpha/2 = 0.05$, que es de $Z_{\text{critico}} = 1.645$. Así, $-1.645 \leq \mathbf{1.02} \leq 1.645$. Por lo que se acepta la hipótesis H_0 : La secuencia de números es independiente.

Nota_2:

Para efectos de facilitar la comparación de las pruebas de hipótesis adelantadas para **uniformidad** de datos (estadístico de prueba: Kolmogorov-Smirnov), **independencia** de datos (estadístico de prueba: número de corridas) con la de ajuste **exponencial** de datos (estadístico de prueba: chi cuadrado), se recomienda pasar a revisar la sección 5.4.1 de la **unidad V** y hacer la prueba de bondad de ajuste Chi cuadrado para probar la hipótesis de que una secuencia de datos, allí dada, sigue una distribución exponencial.

UNIDAD IV

4.1 GENERADORES DE PROCESO

Como se pudo observar en la Unidad II (Monte Carlo), el manejo manual de una simulación no es práctico, aún para problemas de tamaño reducido. Sin embargo, computarizar (automatizar) el proceso requiere algo más que una traducción literal de los procedimientos manuales ya descritos.

Para elaborar un modelo de simulación eficiente se requiere:

- Un procedimiento automático para generar números aleatorios uniformes.
- Un procedimiento para generar variables aleatorias que correspondan a distribuciones probabilísticas teóricas.

El primer requisito se analizó detalladamente en la unidad anterior.

El segundo requisito puede, en otras palabras, enunciarse como “un procedimiento para generar observaciones muestrales que correspondan a distribuciones probabilísticas teóricas (tales como Binomial, Poisson, Exponencial, Normal, etc.)”.

Al procedimiento para generar las observaciones muestrales de una distribución específica de probabilidad se denomina **Generador de Proceso**.

En este punto es bueno recordar el concepto estadístico de variables aleatorias discretas y continuas. Una variable aleatoria discreta es aquella que sólo puede tomar determinados valores dentro de un intervalo, y una variable aleatoria continua es aquella que puede tomar cualquier valor dentro de un intervalo.

En teoría, los tiempos (entre llegadas, de servicios, etc.) pueden tomar cualquier valor, o sea, se comportan como una variable aleatoria continua.

Es posible aproximar una variable continua como si fuera discreta (por ejemplo, suponer que los tiempos sólo se miden al nivel del minuto). Pero dado que estas ocurrencias representan en esencia variables aleatorias continuas, debe utilizarse una distribución continua en el análisis. Una de las ventajas de utilizar

distribuciones continuas es que es posible determinar una ecuación matemática de forma cerrada que puede servir como generador de proceso.

4.2 TÉCNICAS PARA GENERAR NÚMEROS ALEATORIOS (con determinada distribución de probabilidad)

Se tienen varios métodos básicos para generar los valores de variables aleatorias a partir de las distribuciones de probabilidad:

- El método de la transformación inversa.
- El método de composición.
- El método de aceptación y rechazo
- El método de convolución
- Algunos métodos especiales

4.3 MÉTODO DE TRANSFORMACIÓN INVERSA (Davis / McKeown)

Este método requiere definir una función de la variable aleatoria X , que se va a generar, $F(X)$, llamada Función de distribución acumulativa de X , la cual denota la probabilidad de que la variable aleatoria X tome un valor menor o igual a x .

Recordemos de nuestra discusión del método Monte Carlo, los datos se presentaban como una distribución de probabilidad para la variable aleatoria, de la cual se desarrollaba una distribución acumulada de probabilidad. Para desarrollar un generador de procesos trabajaremos con estos mismos factores, pero en forma matemática. Estos factores se conocen con los nombres de función de densidad de probabilidad $f(x)$ y función de densidad acumulada $F(x)$. La primera también se llama función de probabilidad y la segunda función acumulada.

GENERACIÓN DE PROCESOS CONTINUOS (Davis / McKeown)

Para demostrar cómo es la forma en que se obtiene un generador de procesos mediante el método de transformación inversa para algunas distribuciones continuas, examinaremos las distribuciones uniforme y exponencial negativa (este

método también puede ser utilizado para obtener generados de algunas variables discretas. Para algunas variables continuas como la normal, este método no puede utilizarse por lo que se presentará un método especial para la generación de variables normalmente distribuidas.

4.3.1 Generador de procesos para la Distribución Uniforme entre a y b . Método de la transformación inversa. (Davis / McKeown)

Para la distribución uniforme, la función de densidad de probabilidad se define como sigue:


$$f(x) = \frac{1}{b-a} \quad \text{para} \quad a \leq x \leq b$$

Con valor esperado y varianza dado por las siguientes formulas, estos dos resultados los debió haber obtenido en la seccion3.1.1

$$E(x) = \frac{a+b}{2};$$

$$V(x) = \frac{(b-a)^2}{12}$$

Gráficamente,
 $f(x)$



Función de densidad de probabilidad para la distribución uniforme.

Note que todos los valores entre a y b tienen densidades iguales a $1/(b-a)$. Si recordamos cuando se obtuvo la distribución acumulada para los ejemplos de Monte Carlo, las probabilidades se sumaron a partir de la distribución original de probabilidades. Este mismo proceso se utiliza para calcular la función de densidad acumulada, sólo que ahora necesitamos utilizar el cálculo integral que estamos trabajando con datos continuos. El procedimiento envuelve la integración de la función de densidad de probabilidad en el rango de valores.

Esto se hace así:

$$F(x) = \int_a^x f(x)dx \quad a \leq x \leq b$$

Reemplazando $f(x) = 1/(b-a)$ se tiene,

$$F(x) = \int_a^x \frac{1}{b-a} dx$$

$$F(x) = \frac{1}{b-a} \int_a^x dx$$

$$F(x) = \frac{1}{b-a} [x]_a^x$$


$$F(x) = \frac{1}{b-a} [x - a]$$

Por tanto,

$$F(x) = \frac{x-a}{b-a}$$

Esta es la función de densidad acumulada
para la distribución uniforme entre a y b.

Graficamente,



En el procedimiento de muestreo por el método Monte Carlo, se obtenía una muestra de la distribución de probabilidad acumulada siguiendo tres pasos: **Primero**, se generaba un número aleatorio uniformemente distribuido entre 0 y 1, **segundo** se identificaba en el eje vertical (probabilidad acumulada) y, **tercero**, se seleccionaba el correspondiente valor de la variable x en el eje horizontal.

Matemáticamente, el mismo proceso se utiliza para desarrollar el generador de procesos. Esta técnica se conoce con el nombre **Transformación Inversa**.

O sea, el procedimiento establece que hay que igualar la variable aleatoria uniforme R (donde R está entre cero y uno) a $F(x)$ y resolver para x .

Este procedimiento se ejecuta para cualquier distribución. En el caso en que estamos, la distribución uniforme, se trabaja así:

$$R = F(x) = \frac{x - a}{b - a}$$

Resolviendo para x tenemos:

$$R(b - a) = x - a$$

O sea que,

$x = a + R(b - a)$	Esta ecuación es el generador de procesos para la distribución uniforme entre a y b .
--------------------	---

Con este generador podemos generar variables uniformemente distribuidas en el intervalo $[a, b]$ simplemente identificando los valores de a y b , generando un número aleatorio (R), y reemplazando en la ecuación.

Por ejemplo, para tomar una muestra aleatoria de una distribución uniforme entre 10 y 20, con el número aleatorio .6134, tendríamos la observación 16.134 ($x = 10 + 0.6134(20 - 10)$).

Tomar muestras desde una distribución uniforme es bastante simple, una vez que se tiene el generador de procesos. Este beneficio no es único de la distribución uniforme, sino que se aplica a todas las distribuciones continuas que

tengan en forma explícita una un función de distribución acumulada, $F(x)$, y que esta ultima tenga a su vez inversa.

4.3.2 Generador de procesos para la Distribución Exponencial Negativa. Método de la transformación inversa. (Davis / McKeown)

Debería recordarse que en muchas situaciones de líneas de espera, la distribución del tiempo de servicio es la distribución exponencial negativa. Un generador de procesos para esta distribución también puede ser desarrollado usando la técnica de la transformación inversa.

La función de densidad de probabilidad para la distribución exponencial negativa se define matemáticamente como sigue:

$$f(x) = \mu e^{-\mu x} \quad \text{para } 0 \leq x \leq \infty$$

$$E(x) = \frac{1}{\mu}$$

$$V(x) = \frac{1}{\mu^2}$$

Tarea: obtenga estos dos resultados

donde μ es la tasa de servicio promedio, o sea el número promedio de unidades atendidas por intervalo de tiempo, {numero de unidades/tiempo}.

Para desarrollar un generador de procesos, primero debemos calcular la función de densidad acumulada, así:

$$F(x) = \int_0^x f(x) dx$$

$$F(x) = \int_0^x \mu e^{-\mu x} dx$$

$$F(x) = [-e^{-\mu x}]_0^x$$

$$F(x) = [-e^{-\mu x}] - [-e^0]$$

$$F(x) = -e^{-\mu x} + 1$$

$F(x) = 1 - e^{-\mu x}$	Esta es la función de densidad acumulada para la distribución exponencial negativa.
-------------------------	---

Enseguida, la igualamos a la variable aleatoria R (donde R está entre 0 y 1), así:

$$R = F(x) = 1 - e^{-\mu x}$$

O sea que,

$$e^{-\mu x} = 1 - R$$

Tomando logaritmos naturales en ambos lados de la ecuación tenemos:

$$\ln(e^{-\mu x}) = \ln(1 - R)$$

de donde,

$$-\mu x = \ln(1 - R)$$

Por tanto,

$$x = (-1/\mu) \ln(1 - R)$$

Puesto que la variable aleatoria R es simétrica y uniformemente distribuida entre 0 y 1, la distribución de probabilidad para (1 - R) es equivalente a la de R; O sea, que podemos reemplazar (1 - R) por R.

Tenemos, por último,

$x = (-1/\mu) \ln R$	Esta ecuación es el generador de procesos para la distribución exponencial negativa .
----------------------	---

Con este generador podremos obtener valores muestrales para el tiempo de servicio, dado que se conozca la tasa de servicio promedio μ y un valor uniforme aleatorio R.

Por ejemplo, si el número promedio de unidades atendidas por intervalo de tiempo, μ , para una operación dada, es 6 unidades por hora, y se ha generado a 0.5 como el número aleatorio uniforme, R , entonces el valor muestral para el tiempo de servicio será,

$$x = \left(\frac{-1}{6 \text{ unidades/hora}} \right) \times [\ln(.5)]$$

$$x = (-1/6)(-0.693) \text{ horas}$$

$$x = (-60/6)(-0.693) \text{ minutos}$$

$$x = 6.93 \text{ minutos}$$

4.3.3 Generador de procesos para la Distribución Normal (Método especial) ⁴

(Tomado de Técnicas de Simulación en Computadoras, Thomas H. Taylor; Joseph L. Balintfy; Donald S. Burdick, Kong Chu, Editorial Limusa, 1982, pags 109 a 112)

La distribución normal basa su utilidad en el teorema del límite central. Este teorema postula que, la distribución de probabilidad de la suma de N valores de variables aleatorias X_i independientes pero idénticamente distribuidas, con medias respectivas μ_i y varianzas σ_i^2 se aproxima asintóticamente a una distribución normal, a mediada que N se hace muy grande, y que dicha distribución tiene como media y varianza respectivamente, a

$$\mu = \sum_{i=1}^N \mu_i$$

$$\sigma^2 = \sum_{i=1}^N \sigma_i^2$$

⁴ El método que se presenta en ésta sección para generar valores normalmente distribuidos no es exacto, pero su sencillez conceptual lo hace apropiado como ejemplo básico para la obtención de muestras de una variable aleatoria normal y para la comprobación empírica sencilla del teorema del límite central. Su aplicación práctica es muy reducida ya que existen otros métodos exactos de mayor eficacia como el método de Box Muller (1958) y el método polar de Marsaglia y Bray (1964).

En consecuencia, el teorema del límite central permite el empleo de distribuciones normales para representar medidas globales (basada en medidas aditivas-suma de varios efectos) operadas sobre los efectos de causas aditivas distribuidas en forma independiente, sin importar la distribución de probabilidad a que obedezcan las causas individuales.

Si la variable aleatoria X tiene una función de densidad $f(x)$ dada como

$$f(x) = \frac{1}{\sigma_x \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x - \mu_x}{\sigma_x} \right)^2}, \quad -\infty \leq x \leq \infty$$

entonces se dice que X tiene una distribución normal o Gaussiana, con parámetros μ_x y σ_x .

Si los parámetros de la distribución normal tienen los valores $\mu_x = 0$ y $\sigma_x = 1$, la función de distribución recibirá el nombre de distribución normal estándar, con función de densidad

$$f(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2} z^2}, \quad -\infty \leq z \leq \infty$$

Cualquier distribución normal puede convertirse a la forma estándar mediante la substitución:

$$z = \frac{x - \mu_x}{\sigma_x} \quad (A)$$

La función de distribución acumulativa $F(X)$ o $F(z)$ **no existe** en forma explícita; sin embargo, esta última se encuentra totalmente tabulada en cualquier libro sobre estadística. El valor esperado y la varianza de la distribución normal no estándar están dados por:

$$E(X) = \mu_x$$

$$V(X) = \sigma_x^2$$

Existen varios métodos para generar en una computadora, valores de variable aleatoria distribuidos en forma normal. A continuación se presenta el procedimiento llamado del límite central.

A fin de simular una distribución normal con media μ_x y varianza σ_x^2 dadas, se debe proponer la siguiente interpretación matemática del teorema del límite central. Si, $r_1, r_2, \dots, r_N$, representan variables aleatorias independientes, cada una de las cuales posee **la misma distribución** de probabilidad caracterizada por

$$E(r_i) = \theta \dots y \dots Var(r_i) = \sigma^2, \text{ entonces}$$

$$\lim_{N \rightarrow \infty} P \left[a < \frac{\sum_{i=1}^N r_i - N\theta}{\sqrt{N}\sigma} < b \right] = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{1}{2}(z)^2} dz,$$

La anterior expresión simplemente establece que la probabilidad de que la variable aleatoria, $\sum_{i=1}^N r_i$, ya estandarizada, este entre los valores a y b es igual a la integral entre a y b de la función de densidad normal estándar (es decir sigue una distribución normal). Además que esto es cierto cuando el número, N, de valores sumados es grande (mas precisamente cuando tiende a infinito).

Donde

$$E\left(\sum_{i=1}^N r_i\right) = N\theta, \quad Var\left(\sum_{i=1}^N r_i\right) = N\sigma^2, \text{ y}$$

$$z = \frac{\sum_{i=1}^N r_i - N\theta}{\sigma\sqrt{N}}$$

Tanto de la definición de la distribución normal estándar como de la ecuación de sustitución (A), se sigue que z es un valor de variable aleatoria con distribución normal estándar.

El procedimiento para simular valores normales utilizando computadoras requiere el uso de la suma de K valores de variable aleatoria distribuidos uniformemente; esto es, la suma de $r_1, r_2, \dots, r_N$, con cada r_i , definida en el intervalo $0 < r_i < 1$. Aplicando la convención rotacional de la forma matemática del teorema del límite central, así como nuestros conocimientos previos de la distribución uniforme, encontramos que:

$$\theta = \frac{a+b}{2} = \frac{0+1}{2} = \frac{1}{2},$$

$$\sigma = \frac{b-a}{\sqrt{12}} = \frac{1}{\sqrt{12}};$$

$$z = \frac{\sum_{i=1}^k r_i - K/2}{\sqrt{\frac{K}{12}}}$$

Pero por definición, z es un valor de variable aleatoria con distribución normal estándar que se puede escribir en la forma sugerida por la ecuación (A), donde, x, es un valor de variable aleatoria distribuido en forma normal que se va a simular, con media μ_x y varianza σ_x^2 . Igualando la dos ecuaciones tenemos:

$$\frac{x - \mu_x}{\sigma_x} = \frac{\sum_{i=1}^k r_i - K/2}{\sqrt{\frac{K}{12}}}, \text{ y resolviendo para } x, \text{ se tiene que:}$$

$$x = \sigma_x \left(\frac{12}{k} \right)^{1/2} \left(\sum_{i=1}^K r_i - \frac{K}{2} \right) + \mu_x \quad (B)$$

Por lo tanto, mediante esta ecuación podemos proporcionar una formulación muy simple para generar valores de variable aleatoria normalmente distribuidos, con media igual a μ_x y varianza σ_x^2 . Para generar un solo valor de x (un valor de variable aleatoria con distribución normal) bastará con sumar K números aleatorios definidos en el intervalo de 0 a 1. Substituyendo el valor de esta suma en la ecua-

ción (B), así como también los valores de μ_x y de σ_x , para la distribución deseada, encontraremos que se ha determinado un valor particular de x . Ciertamente este procedimiento debe repetirse tantas veces como valores de variable aleatoria normalmente distribuidos se requieran.

El valor de K que debe aplicarse a las formulas usualmente se determina al establecer las condiciones de balance entre la eficiencia de computo y la precisión. Al considerar la convergencia asintótica implicada por el procedimiento del limite central, sería preferible que K corresponda a un número muy grande. Considerando el tiempo que comprende la generación de K valores uniformes por cada valor de la variable aleatoria normal sería preferible que K estuviese asociado con un número muy chico. En la práctica de simulación se recomienda una $K=10$ como el menor valor deseable. Sin embargo, con $K=12$ se logra una cierta ventaja computacional, ya que en la ecuación (B) se puede evitar una multiplicación constante. No obstante, este valor de K trunca la distribución a los límites $+6$ y además se ha encontrado que no es confiable para valores de x mayores que tres de las desviaciones estándar. Con el fin de obtener mayor precisión se deben considerar valores mayores de K (del orden de $K=24$), de acuerdo con la llamada técnica de aproximación de Teichroew. La aproximación de Teichroew mejora la precisión de las probabilidades de los eventos extremos, obtenida con los procedimientos del limite central con $k=12$ deberemos calcular el valor de:

$$y = \frac{\left(\sum_{i=1}^{12} r_i - 6 \right)}{4}$$

y el siguiente polinomio servirá para obtener el valor de la variable z distribuida normalmente:

$z = a_1 y + a_3 y^3 + a_5 y^5 + a_7 y^7 + a_9 y^9$, donde los parámetros tienen valores $a_1 = 3.94, a_2 = 0.25, a_3 = 0.076, , , , , ,$

Por ejemplo:

Supongamos, para alguna variable particular: $K = 12, \mu = 3, \sigma = 1.2$ y los 12 números aleatorios .10, .37, .08, .99, .12, .66, .31, .85, .63, .73, .98, .11

Entonces, x es

$$x = 1,2 \left(\frac{12}{12} \right)^{\frac{1}{2}} \left(5,93 - \frac{12}{2} \right) + 3$$

$$x = 1,2(5,93 - 6) + 3 = 2,916$$

El valor 2,916 se usa como valor de x en la simulación. Cuando se requiere el siguiente valor de x , se generan 12 nuevos números aleatorios y se calcula un nuevo valor de x .

OTRAS DISTRIBUCIONES CONTINUAS

Aunque no se verán aquí, se remite al estudiante a libros específicos de estadística para analizar otras distribuciones teóricas continuas. En este curso sólo tratamos las más utilizadas en simulación (uniforme, exponencial negativa y normal).

4.4 MÉTODO DE COMPOSICIÓN

Mediante este método la distribución de probabilidad $f(x)$ se expresa como una mezcla de varias distribuciones de probabilidad $f_i(x)$ seleccionadas adecuadamente.


El procedimiento para la selección de las $f_i(x)$ se basa en el objetivo de minimizar el tiempo de computación requerido para la generación de valores de la variable aleatoria analizada.

Los pasos requeridos para la aplicación de este método en la simulación de variables aleatorias no-uniformes son los siguientes:

1. Dividir la distribución de probabilidad original en sub-áreas.
2. Definir una distribución de probabilidad para cada sub-área.
3. Expresar la distribución de probabilidad original en la forma siguiente:

$$f(x) = A_1 f_1(x) + A_2 f_2(x) + \dots + A_n f_n(x) \text{ y } \sum A_i = 1$$


4. Obtener la distribución acumulada de las áreas.



5. Generar dos números uniformes R1 y R2.
6. Seleccionar la distribución de probabilidad $f_i(x)$ con la cual se va a simular el valor de x . La selección de esta distribución se obtiene al aplicar el método de la transformada inversa, en el cual el eje Y está representado por la distribución acumulada de las áreas, y el eje X por las distribuciones $f_i(x)$. Para esta selección se utiliza el número uniforme R1.
7. Utilizar el número uniforme R2 para simular por el método de la transformada inversa o algún otro procedimiento especial, números al azar que sigan la distribución de probabilidad $f_i(x)$ seleccionada en el paso anterior.


4.4.1 Distribución triangular (Método Composición).

Se desea generar números al azar que sigan la siguiente distribución de probabilidad:



Siguiendo los pasos descritos previamente, la generación de números aleatorios que sigan esta distribución triangular, puede ser resumida en los siguientes pasos:

1. La distribución original, se va a dividir en dos áreas, tal como se muestra en la figura siguiente




$$A_1 = \frac{b-a}{c-a}$$

$$A_2 = \frac{c-b}{c-a}$$

Evidentemente $A_1 + A_2 = 1$

2. En seguida se determinan las distribuciones de probabilidad y distribución acumulada de las áreas definidas en el paso anterior:




$$f_1(x) = \frac{2}{(b-a)(c-a)}(x-a)$$

$$F_1(x) = \frac{(x-a)^2}{(b-a)(c-a)}$$

Tarea: obtenga estos dos resultados

Para la segunda parte de la función de densidad tenemos:



$$f_2(x) = \frac{2}{(c-b)(c-a)}(c-x)$$

$$F_2(x) = 1 - \frac{(c-x)^2}{(c-b)(c-a)}$$


Tarea: obtenga estos dos resultados, muy en particular el segundo, $F_2(x)$

3. Posteriormente la distribución de probabilidad original se expresa como:

$$f(x) = \frac{(b-a)}{(c-a)} \left(\frac{2}{(b-a)(c-a)} (x-a) \right) + \frac{(c-b)}{(c-a)} \left(\frac{2}{(c-b)(c-a)} (c-x) \right)$$

$$f(x) = \frac{2}{(c-a)^2} (x-a) + \frac{2}{(c-a)^2} (c-x)$$

4. Con las áreas y distribuciones $f_i(x)$ definidas en los pasos anteriores, la distribución acumulada de las áreas sería:



5. Generar dos números uniformes R1 y R2.

6. Es $R1 < \frac{(b-a)}{(c-a)}$? Si la respuesta es afirmativa, entonces se simulan valores de la distribución $f_1(x)$. Como?, igualando R1 a la función acumulada de $f_1(x)$, como sigue:

$$\frac{(x-a)^2}{(b-a)(c-a)} = R1$$

$$x = a + \sqrt{R1(b-a)(c-a)}$$

7. Si la respuesta es negativa, entonces se simulan los valores de la distribución $f_2(x)$ a partir de la siguiente ecuación, en la cual se igual R2 a la función acumulada de $f_2(x)$, y luego se despeja, x, como sigue:

$$1 - (c - x)^2 / (c - b)(c - a) = R2$$

8. Repetir los pasos anteriores tantas veces como se deseen generar valores de la variable triangular.

GENERACIÓN DE PROCESOS DISCRETOS (Davis / McKeown)

Similarmente al caso continuo, existen muchas distribuciones teóricas discretas, pero las más frecuentemente utilizadas en modelos de simulación son la Binomial y la de Poisson, a las cuales limitaremos nuestra discusión.

Generadores de Procesos pueden, indudablemente, ser desarrollados para distribuciones discretas de probabilidad usando el método de transformación inversa. Sin embargo, una aproximación más simple es emplear el proceso de conteo conocido como **método de Aceptación y Rechazo** que se ilustra a continuación construyendo generadores para las variables binomial y de Poisson.

4.4.2 Generador de procesos para la Distribución Binomial. (Método de Aceptación y Rechazo). (Davis / McKeown)

La función de probabilidad para la distribución Binomial se expresa como sigue:

$$p(x) = \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}$$

Donde,


n = número de ensayos independientes (tamaño de la muestra)
 p = probabilidad de éxito en un ensayo
 x = variable aleatoria que representa el número de éxitos en n ensayos

Tarea: Interpretar bien la diferencia entre el p como parámetro de la binomial y la $P(x=1)$ en n ensayos. Suponga el caso, de $p=0.7$ de éxito en un examen. Cual es la probabilidad de $x=1$ en $n=8$ estudiantes ¿intuitivamente mayor a 0.7 o menor?

Construcción del generador

Dados los parámetros n y p , el generador de procesos Binomial simplemente envuelve el muestrear n veces y contar el número de éxitos, x .

En cada ensayo, un variable aleatoria uniforme, R , se genera y se compara con la probabilidad de éxito, p . Si la variable aleatoria R es menor que p , el ensayo es etiquetado como un **éxito**, y se lleva a un contador de éxitos. Si $R \geq p$, el ensayo es un fracaso. Después de n ensayos, el número total de éxitos es el valor de la variable aleatoria para la distribución Binomial.



Numero de ensa- yo	Ri , valor unifor- me entre 0 y 1	Fracaso	Exito
1	0.7	1	0
2	0.2	0	1
.		0	1
.		0	1
.		1	0
.		1	0
.		1	0
.		1	0
.		0	1
n	0.6	1	0
		¿????	¿????
		Total fracasos	Total exitos

4.4.3 Generador de procesos para la Distribución Poisson. (Método de Aceptación y Rechazo). (Davis / McKeown)

Es bien conocido que la distribución de Poisson se usa en el análisis de líneas de espera (teoría de colas). En estos casos (que son de alto interés en la simulación), los datos se recogen en la forma de **número de llegadas por período de tiempo**, y así se adaptan al modelo teórico de la distribución de Poisson.

La función de probabilidad para la distribución Poisson se expresa como sigue:

$$p(x) = \frac{(\lambda T)^x e^{-\lambda T}}{x!}$$

Donde,

λT = número promedio de llegadas por período de tiempo T

x = es la variable a generar, como número de llegadas en el intervalo de tiempo

Para generar variables aleatorias tipo Poisson se podría utilizar la relación anterior en conjunto con el proceso de transformación inversa, pero el método que se muestra a continuación es más sencillo y más directo.

En los análisis de líneas de espera, se ha notado las relaciones duales entre las distribuciones exponencial negativa y Poisson. Específicamente se ha notado que sí el **número de llegadas por período de tiempo** puede ser descrito por la distribución Poisson, entonces el tiempo entre llegadas puede ser descrito por la distribución exponencial negativa.


Para desarrollar un generador de procesos para la distribución Poisson, podemos tomar ventaja de esta relación. Basta con simular, simplemente, los tiempos de llegadas usando el generador de procesos exponencial negativo, $x = -(1/\mu) \ln(1 - R)$, (descrito en la sección 4.3.2) y contar el número de llegadas que ocurren en el período de tiempo (T).

El método de composición para generar muestras aleatorias que sigan la distribución Poisson se describe a continuación:

1. Identificar la longitud del período de tiempo T . Inicializar con cero el contador “número de llegadas”, n , y el contador “tiempo entre llegadas”, t .
2. Generar el tiempo entre llegadas para una llegada usando el generador de procesos exponencial negativo.
3. Agregue el tiempo entre llegadas del paso 2 al contador t . Agregue 1 al contador n .
4. Si $t > T$ en el paso 3, entonces omita la última llegada, reste 1 de n y vaya al paso 5, de lo contrario vaya al paso 2.
5. El valor de n es el valor de la variable aleatoria para la distribución Poisson.

Para mayor claridad observe el siguiente esquema:

$$x_i = -(1/\mu) \ln (1 - R_i),$$



UNIDAD V

ENCONTRANDO LA DISTRIBUCIÓN CORRECTA (Traducido de Bateman)

5.1 ¿Porqué usar Distribuciones Estándar?

Las distribuciones estándar se usan para representar distribuciones de datos empíricos debido a que ellas ayudan a nivelar las irregularidades de los datos que pueden existir debido a valores ausentes durante el período de recolección de datos. Los valores no observados durante la recolección de datos pueden ser tenidos en cuenta por el uso de distribuciones estándar representativas de los datos observados.

Frecuentemente los datos empíricos se recogen en cortos intervalos de tiempo. Puede que valores extremos (valores de las colas de la distribución) no ocurran durante estos intervalos. Suponga, por ejemplo, que se sabe que los tiempos entre llegadas de los clientes de un banco varían entre 0 y 60 minutos. Se registra la llegada de los clientes en un período de dos semanas, pero no son observados tiempos entre llegadas superiores a 20 minutos. Valores aleatorios observados solamente para los datos observados no producirán valores superiores a 20 minutos. La exclusión de estos valores del análisis puede influenciar significativamente en las respuestas de ejecución.

El uso de una distribución estándar sobre otra es totalmente dependiente de los datos empíricos que está representando o del tipo de proceso estocástico que está siendo modelado (cuando no hay datos disponibles). Los paquetes de software que hay disponibles pueden analizar rápidamente los datos empíricos que se dispongan y sugerir las distribuciones estándar más apropiadas. Un ejemplo ampliamente usado es el Stat::Fit de ProModel. Este software tiene la capacidad de analizar rápidamente los datos de entrada y ejecutar varias pruebas estadísticas para identificar la distribución estándar que mejor se aproxima a los datos. Uno de estas pruebas de “bondad de ajuste” se describe posteriormente con detalle más tarde en esta sección. Aunque las distribuciones definidas por el usuario pueden también ser creadas si los datos empíricos no se ajustan a ninguna distribución estándar, estas distribuciones pueden requerir pasos adicionales de cómputo para cada valor generado, y se requerirá de más tiempo de proceso.

Hay cuatro pasos importantes en el desarrollo de un modelo útil de los datos de entrada para un modelo de simulación:

1. La recolección de los datos del sistema real de interés.
2. la Identificación de una distribución de probabilidad para representar el proceso de entrada. Cuando existen datos disponibles, este paso típicamente comienza con el desarrollo de una distribución de frecuencia o histograma de los datos. Basados en la distribución de frecuencia y en el conocimiento estructural del proceso, se escoge una familia de distribuciones. Afortunadamente, varias de las distribuciones conocidas a menudo proporcionan una buena aproximación, en la práctica.
3. La escogencia de los parámetros que determinan una instancia específica de la familia de distribuciones. Cuando existen datos disponibles, estos parámetros deben ser estimados a partir de los datos.
4. La evaluación de la distribución escogida y los parámetros asociados mediante una prueba de "*Bondad de Ajuste*". La bondad del ajuste puede ser evaluada informalmente, vía métodos gráficos (Q-Q Plots), o formalmente a través de pruebas estadísticas. Los *tests* Chi Cuadrado y Kolmogorov-Smirnov son patrones como pruebas de bondad de ajuste. Si no se está satisfecho con la aproximación a los datos de la distribución escogida, entonces el analista debe retornar al paso #2, escoger una familia diferente de distribuciones, y repetir el procedimiento. Si varias iteraciones de este procedimiento no conducen a un buen ajuste entre la forma de la distribución asumida y los datos recolectados, entonces una forma empírica de la distribución debe ser usada.

Aunque actualmente existe software para adelantar los pasos 2,3 y 4, es importante entender lo que el software hace, para que pueda ser usado apropiadamente.

Seleccionando una familia de distribuciones (adelantar práctica #13 con Stat::Fit)

El propósito al preparar un histograma es inferir una conocida función de densidad de probabilidad. Una familia de distribuciones es seleccionada con base en la forma del histograma y en lo que pueda inferirse del contexto que está siendo investigado.

Suponga que una distribución exponencial fue asumida, pero que se encuentra que no ajusta bien los datos. El siguiente paso sería examinar donde está ocurriendo la falta de ajuste. Si la falta de ajuste está en una de las colas de la distribución, talvez una Gamma o Weibull se ajustarían mejor a los datos.

Literalmente, cientos de distribuciones de probabilidad han sido creadas, muchas de ellas con algún proceso físico específico en mente. Una ayuda para seleccionar las distribuciones es usar, como guía, las bases físicas de la distribución.


5.2 Algunas Distribuciones Estándar

(Realizar práctica #13 con Stat::Fit, para analizar el efecto que el cambio en el valor de los parámetros tiene sobre la forma de estas distribuciones)

Las distribuciones de probabilidad estándar usualmente se perciben en términos de las formas producidas por sus funciones de densidad de probabilidad. Por ejemplo, la curva que tiene forma de campana es el gráfico que típicamente se ha asociado a la distribución normal. Muchas funciones de densidad de probabilidad tienen parámetros que controlan sus características de forma y escala. Dos de los más comunes son el parámetro α (alfa) para definir la forma de la distribución (*Shape value*) y el parámetro β (beta) para definir los valores escala (*Scale value*) en el rango de la distribución. Las medias y las varianzas de estas distribuciones se definen en términos de los parámetros α y β .

En simulación se usan frecuentemente varias distribuciones estándar continuas de probabilidad. Estas son la Exponencial, Gamma, Normal, Uniforme, Weibull, Triangular, Lognormal, Erlang y Beta. La comprensión de las características claves y los usos típicos de estas distribuciones puede ayudar a los constructores de modelos a reconocer las distribuciones representativas de los datos empíricos y a sugerir distribuciones apropiadas cuando no existan datos históricos. Enseguida se muestran las distribuciones más comunes y algunos de sus usos típicos.

5.2.1 EXPONENCIAL



Algunas veces se la conoce como Exponencial Negativa, esta distribución tiene un uso muy amplio en los sistemas de colas. Se utiliza para generar valores aleatorios para los tiempos entre llegadas de los clientes a un sistema. El término “clientes” cubre un número infinito de posibilidades, variando desde paquetes que llegan a un almacén hasta solicitudes de trabajos a un sistema de cómputo. Otras aplicaciones posibles son el tiempo para completar una tarea y el tiempo de falla de un componente electrónico.

En la formulación de la distribución exponencial presentada en la sección 4.3.2, como $f(x) = \mu e^{-\mu x}$, μ es la tasa de servicio promedio, o sea el **número promedio** de unidades atendidas por intervalo de tiempo {numero de unidades/tiempo}. Mientras que β , es el **tiempo promedio** entre llegadas.

Así,

$$E(x) = \frac{1}{\mu} = \beta$$

$$V(x) = \frac{1}{\mu^2} = \beta^2$$


Tarea: obtenga estos dos resultados

Parámetros de especificación: El valor medio β ó $1/\mu$, y la semilla de números aleatorios

5.2.2 GAMMA

Una distribución extremadamente flexible usada para modelar variables aleatorias no negativas. El valor inicial de la Gamma puede ser movido a la izquierda del cero con solo agregar una constante.

$$f(x) = \frac{\beta^{-\alpha} x^{\alpha-1} e^{-x/\beta}}{\Gamma(\alpha)}$$




La distribución Gamma puede usarse para representar el tiempo necesario para completar una tarea o un grupo de tareas. Suponga que una distribución Exponencial con media de 1.2 horas describe el tiempo para completar una tarea dada. La distribución Gamma podría ser empleada para generar valores que representen el tiempo total requerido para completar n ejecuciones independientes de esa tarea. El valor α sería igual a n para este escenario.

En la distribución gamma el valor α es real. Cuando el valor α se restringe a valores enteros obtenemos la distribución Erlang (ver sección 5.2.8). Además si α se hace igual a 1 obtenemos una distribución exponencial.

Parámetros de especificación: Valor α real, Valor β , La semilla de números aleatorios.

5.2.3 NORMAL

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-\mu)^2/2\sigma^2}$$




La distribución Normal es a menudo utilizada para medir varios tipos de error. Las operaciones de recepción/inspección frecuentemente requieren el uso de instrumentos calibrados para medir las dimensiones de varios componentes. Se ha asumido que las medidas reveladas por un instrumento están normalmente distribuidas alrededor de las verdaderas dimensiones del componente. Una distribución Normal podría utilizarse para representar las lecturas obtenidas en cada medida individual.

Parámetros de especificación: Valor medio, Desviación estándar, Semilla de Números aleatorios.

5.2.4 UNIFORME

$$f(x) = \frac{1}{b-a}$$




Una distribución Uniforme en el rango de cero a uno es la base para la generación de valores para distribuciones estándares de probabilidad. También puede ser utilizada para generar valores aleatorios para algoritmos personalizados. Otra aplicación común es la de representar la duración del tiempo de una tarea cuando se tiene solamente una mínima información sobre los tiempos actuales. Algunas veces se supone adecuadamente que el tiempo para completar una tarea varía aleatoriamente u constantemente entre dos valores. Dadas estas condiciones, la distribución Uniforme es una estimación preliminar buena para la duración de un ciclo de tiempo.

Parámetros de especificación: Valor medio, Mitad del rango, Semilla de números aleatorios.

5.2.5 WEIBULL

$$f(x) = \alpha \beta^{-\alpha} x^{\alpha-1} e^{-(x/\beta)^\alpha}$$




Asuntos de confiabilidad a menudo son representados con una distribución Weibull. Puede usarse para generar valores para tiempo de falla de una pieza de un equipo o el promedio de la vida de un componente electrónico. El tiempo para completar una tarea también puede ser reflejado por esta distribución. Si α se hace igual a 1 la distribución Weibull se convierte en una exponencial.

Parámetros de especificación: Valor α , Valor β , Semilla de números aleatorios.

5.2.6 TRIANGULAR

$$f(x) = \frac{2(x-a)}{(b-a)(c-a)} \text{ for } a \leq x \leq c$$

$$f(x) = \frac{2(b-x)}{(b-a)(b-c)} \text{ for } c \leq x \leq b$$




Una distribución triangular es particularmente útil para situaciones donde únicamente se conocen tres datos acerca de una tarea. Si se le pregunta a un operario de una línea de producción cuánto tiempo le lleva ejecutar una operación probablemente responderá: "La mayoría de las veces es y, pero puede variar desde x hasta z". El valor mínimo (x), la moda (y) y el máximo (z) pueden entonces ser usados como los parámetros requeridos para definir una distribución triangular.

Parámetros de especificación: Valor mínimo, Valor modal, valor máximo, Semilla de números aleatorios.

5.2.7 LOGNORMAL

$$f(x) = \frac{1}{2\pi\sigma^2} e^{-(\ln x - \mu)^2 / 2\sigma^2}$$




Una distribución Lognormal puede utilizarse para representar el tiempo de ejecución de una tarea. Un ejemplo puede ser el tiempo de ciclo para completar un carrusel de una operación de almacenaje/entrega en un sistema de almacén automatizado. Los valores para los parámetros de esta distribución generalmente son calculados a partir de los logaritmos naturales de los datos empíricos. Dadas estas condiciones, los valores generados desde una distribución Lognormal deben ser expresados en términos de los logaritmos naturales de los valores aleatorios deseados. Si esto es cierto, entonces los valores generados deben ser convertidos a valores no logarítmicos para obtener la variación aleatoria que será representativa de los datos empíricos.

Parámetros de especificación: Valor medio, Desviación estándar, Semilla de números aleatorios.

5.2.8 ERLANG

Modela procesos que pueden ser vistos como la suma de varios procesos exponencialmente distribuidos; por ejemplo, una red de computadoras falla cuando una computadora y mas dos computadoras que sirven de "back up" fallan, y cada una de ellas tiene un tiempo de fallas exponencialmente distribuido. La función de distribución Erlang es un caso particular de la Gamma.

$$f(x) = \frac{(\mu k)^k}{(k-1)!} x^{k-1} e^{-\mu k x}$$




La distribución Erlang es un caso especial de la distribución Gamma que es utilizada frecuentemente en los sistemas de colas para representar distribuciones de tiempos de servicio para varias tareas. El valor del parámetro k es equivalente al parámetro α de la distribución Gamma, pero los valores de k son ahora restringidos a valores enteros mayores que cero. Esta distribución llega a ser una distribución exponencial cuando $k=1$. Una variable Erlang como la suma de k variables aleatorias exponenciales puede obtenerse por el método de convolución.

Suponga que una operación consiste en la ejecución de una sola tarea 10 veces, y el tiempo para completar cada tarea se describe con una distribución exponencial con media de 2. Dadas estas circunstancias, el tiempo para completar la operación completa puede ser representado por una distribución Erlang con una media de 20 (calculada como 2×10) y un parámetro $k=10$.

Parámetros de especificación: Valor medio, Valor k , Semilla de números aleatorios.

5.2.9 BETA

$$f(x) = \frac{x^{\alpha_1 - 1} (1 - x)^{\alpha_2 - 1}}{B(\alpha_1, \alpha_2)}$$



Para definir la distribución Beta se necesitan dos parámetros, α_1 y α_2 . La variación de sus valores producirá una variedad de diferentes formas de la distribución. Los valores generados desde una distribución Beta variarán entre cero y uno. Por esta razón, es particularmente útil para la representación de fenómenos pertenecientes a proporciones. La proporción de artículos defectuosos encontrados en un lote dado podría ser descrita por esta distribución. La distribución Beta también es usada para representar el tiempo requerido para completar una actividad, cuando sólo se sabe muy poco (o nada) de la duración de la actividad.


Parámetros de especificación: Valor α_1 , Valor α_2 , Semilla de números aleatorios.

Algunas distribuciones Discretas

Las distribuciones discretas también son usadas en modelos de simulación. Son empleadas cuando los valores x para la variable aleatoria son enteros. Las tres distribuciones discretas más populares son la Poisson, Binomial y Uniforme discreta. Las distribuciones discretas se incluyen normalmente en un modelo como Distribuciones definidas por el usuario.

5.2.10 POISSON

$$p(x) = \frac{e^{-\lambda} \lambda^x}{x!}$$



La distribución Poisson es asociada usualmente con las tasas de llegada. Esta distribución refleja la probabilidad asociada con un número finito de éxitos (llegadas) que toman lugar en un intervalo de tiempo de llegadas o en un área específica. Para cada valor entero de una variable aleatoria X solamente hay una probabilidad de ocurrencia.


En modelos de colas, la tasa de llegadas de los clientes a un sistema se conoce como un proceso de llegadas Poisson. Esto implica que los tiempos entre llegadas de los clientes están distribuidos exponencialmente. El número de llamadas telefónicas que llegan a un conmutador cada hora puede ser representado por una distribución de Poisson. El parámetro λ refleja la tasa de llegadas promedio por hora. Los valores generados por esta distribución serán valores enteros mayores que o iguales a cero.

Parámetros de especificación: Valor medio (λ), Semilla de números aleatorios.

5.2.11 BINOMIAL

Modela el número de éxitos en n ensayos, cuando los ensayos son independientes y tienen una probabilidad, p , de éxito común. Por ejemplo, el número de *chips* defectuosos encontrados en un lote de n *chips*.

$$p(x) = \binom{n}{x} p^x q^{n-x}$$



Considere un experimento que puede producir dos posibles resultados: éxito o fracaso. “ p ” denota la probabilidad de éxito y “ q ” denota la probabilidad de fracaso ($q=1-p$). Si la probabilidad de éxito permanece constante en cada repetición independiente del experimento, entonces el número de éxitos en n ensayos indepen-

dientes pueden ser descritos por una distribución Binomial. El número de artículos defectuosos en un lote de tamaño n puede ser representado por esta distribución. Los valores aleatorios producidos reflejarán el número de defectuosos por lote.

Parámetros de especificación: Valor n , Valor p , Semilla de números aleatorios.

5.2.12 UNIFORME DISCRETA

$$p(x) = \frac{1}{(b - a) + 1}$$


Suponga un sistema automatizado de almacenaje y entrega consistente en seis carruseles individuales, donde las partes están distribuidas uniformemente entre ellos. Una distribución Uniforme Discreta con valores de uno a seis debería ser usada para determinar el carrusel en el cual una parte dada está almacenada. Cada valor de la variable aleatoria X (carrusel el cual una parte está almacenada) tendrá un valor entero dentro de ese rango.

Parámetros de especificación: Mínimo valor (a), Máximo valor (b), Semilla de números aleatorios.

Literalmente, cientos de distribuciones de probabilidad han sido creadas, muchas de ellas con algún proceso físico específico en mente. Una ayuda para seleccionar las distribuciones es usar, como guía, las bases físicas de la distribución.

En conclusión no ignore las características físicas del proceso cuando seleccione una distribución de probabilidad. Es el proceso naturalmente acotado o no lo es?. Este conocimiento que no depende de los datos, puede ayudar a limitar el número de familias de distribuciones a partir de la cual seleccionar.

Mantenga presente, No existe una “verdadera” distribución para las entradas de un proceso estocástico. El modelo de entradas es una aproximación de la realidad, y la meta es entonces obtener una aproxima-

ción que conduzca a resultados útiles, a partir del experimento de simulación.

5.3 Estimadores Sugeridos para parámetros de algunas distribuciones

Las estimaciones numéricas de los parámetros de la distribución son necesarias para reducir la familia de las distribuciones a una distribución específica y probar la hipótesis resultante. La siguiente Tabla 5.1, contiene los estimadores para las distribuciones que con más frecuencia se utilizan en simulación. Los estimadores presentados son los estimadores de **Máxima Verosimilitud**, basados en los datos muestrales.

El método de **máxima verosimilitud** suele generar estimadores insesgados de mínima varianza. **Este método selecciona como estimadores aquellos valores de los parámetros que maximizan la función de verosimilitud (la función de densidad conjunta) de la muestra observada.**

Nota: Debe recordarse que un parámetro es una constante desconocida, y que el estimador es una variable estadística ó una variable aleatoria ya que depende de los valores muestrales. Para distinguir entre ambos, si decimos por ejemplo, que un parámetro esta siendo denotado por α , entonces el estimador será denotado con la misma letra y un acento circunflejo encima de ella, $\hat{\alpha}$

Tabla 5.1. Estimadores máximo verosímil de algunas distribuciones de probabilidad

Distribución	Parámetros	Estimador(es)
Poisson	λ	$\hat{\lambda} = \bar{x} = \sum \frac{x_i}{n}$
Exponencial	β μ	$\hat{\beta} = \bar{x} = \sum \frac{x_i}{n}$ $\hat{\mu} = \sum \frac{n}{x_i}$
Gamma	α, β	$\ln \hat{\beta} + \Psi(\hat{\alpha}) = \frac{\sum_{i=1}^n \ln X_i}{n}, y, \hat{\alpha}\hat{\beta} = \bar{X}$ Deben satisfacerse ambas ecuaciones, lasque pueden resolverse numéricamente; $\Psi(\hat{\alpha})$, es la

		función Digamma = $\frac{\Gamma^1(\hat{\alpha})}{\Gamma(\hat{\alpha})}$
Uniforme	a, b	$\hat{a} = \min X_i, \hat{b} = \max X_i; 1 \leq i \leq n$
Weibull	α, β	$\frac{\sum_{i=1}^n X_i^{\hat{\alpha}} \ln X_i}{\sum_{i=1}^n X_i^{\hat{\alpha}}} - \frac{1}{\hat{\alpha}} = \frac{\sum_{i=1}^n \ln X_i}{n};$ $\hat{\beta} = \left(\frac{\sum_{i=1}^n X_i^{\hat{\alpha}}}{n} \right)^{1/\hat{\alpha}}$ Deben satisfacerse ambas ecuaciones, la primera puede resolverse numéricamente para $\hat{\alpha}$, por el método de Newton, y la segunda da directamente $\hat{\beta}$
Lognormal	$\mu; \sigma^2$	$\hat{\mu} = \frac{\sum_{i=1}^n \ln X_i}{n}; \hat{\sigma} = \left[\frac{\sum_{i=1}^n (\ln X_i - \hat{\mu})^2}{n} \right]^{1/2}$
Normal	$\mu; \sigma^2$	$\hat{\mu} = \bar{X}; \hat{\sigma} = \left[\frac{n-1}{n} S^2(n) \right]^{1/2}$
Beta	$\alpha_1 > 0; \alpha_2 > 0$	Las siguientes ecuaciones deben satisfacerse y pueden ser resueltas numéricamente $\Psi(\hat{\alpha}_1) - \Psi(\hat{\alpha}_1 + \hat{\alpha}_2) = \ln G_1$ $\Psi(\hat{\alpha}_2) - \Psi(\hat{\alpha}_1 + \hat{\alpha}_2) = \ln G_2$ $\Psi(\hat{\alpha})$, es la función Digamma = $\frac{\Gamma^1(\hat{\alpha})}{\Gamma(\hat{\alpha})}$ $G_1 = \left(\prod_{i=1}^n X_i \right)^{1/n}; G_2 = \left[\prod_{i=1}^n (1 - X_i) \right]^{1/n}$

Tabla 5.1. Estimadores para las distribuciones más a menudo usadas en simulación

Tarea: Encuentre mediante el método de máxima verosimilitud:

- El estimador del parámetro μ (tasa de llegadas) ó β (promedio del tiempo entre llegadas) de la función de densidad exponencial.
- Los estimadores de los parámetros de la función de densidad normal

5.4 PRUEBAS DE BONDAD DE AJUSTE

(Realizar **práctica #13** con Stat::Fit, sobre pruebas de bondad de ajuste).

El primer paso en el análisis de los datos para determinar su distribución usualmente es la construcción de un histograma de frecuencias relativas. La forma de esta gráfica puede mostrar inmediatamente que una o más distribuciones estándar parecen ajustarse a los datos. Sin importar si se utiliza un software de análisis de datos o si se realizan los cálculos manualmente, el modelador debe asegurarse de que la distribución seleccionada ofrece la mejor representación posible.

Las pruebas de bondad de ajuste proveen una guía útil para evaluar la “correctitud” de un potencial modelo de entrada. Sin embargo, ya que no existe una solo distribución correcta en una aplicación real, no se debe ser esclavo del veredicto de tales pruebas (tests). Es muy importante entender el efecto del tamaño de la muestra. Si solo tenemos disponibles pocos datos, entonces una prueba de bondad de ajuste difícilmente rechazará alguna de las distribuciones candidatas, pero si se tienen disponibles una gran cantidad de datos, entonces la prueba de bondad de ajuste probablemente rechazará a todas las distribuciones candidatas.

De tal manera que, el no rechazar una distribución candidata debe ser tomado como un elemento de evidencia a favor de aquella escogencia, mientras que el rechazo de un modelo de entrada es solo una evidencia en contra de la escogencia.

Ajuste de Curvas

Escoger la distribución correcta es una tarea difícil, esto sin mencionar la tarea de escoger los parámetros correctos de la distribución. Generalmente se lleva a cabo con software de ajuste de curvas.

Los mejores Ajustes (“Best Fits”) y los P-Valores

Para aplicar un *Test* de Bondad de Ajuste, un nivel de significancia debe ser escogido. Recuerde que el *nivel de significancia es la probabilidad de falsamente rechazar la hipótesis nula* (H_0 = las variables aleatorias siguen la distribución de probabilidad asumida en la hipótesis) cuando ella es cierta (llamada también error

tipo I, error que se comete al rechazar la hipótesis nula siendo ella cierta). Los niveles tradicionales de significancia usados son 0.1, 0.05 y 0.01. Antes de la actual disponibilidad de los computadores, el tener un conjunto pequeño de valores estándar hizo posible producir tablas para valores críticos útiles (0.1, 0.05 y 0.01). Hoy, la mayoría del software estadístico calcula los *valores críticos que se necesitan*, envés de tenerlos guardados en tablas de archivo. Así, que si el analista prefiere un nivel de significancia digamos del 0.07, entonces lo puede escoger.

Sin embargo, muchos de los actuales paquetes de software, envés de requerir un nivel de significancia pre-especificado, calculan el *valor-p* (*p-value*) para la prueba estadística. El **valor-p**, es el **nivel de significancia** al cual **se rechazaría la hipótesis nula**, H_0 , para el valor dado del estadístico de prueba. Por lo tanto, un **valor-p grande**, tiende a indicarnos un **buen ajuste** (es decir tendríamos que aceptar una probabilidad grande de error tipo I, para poder rechazar la hipótesis), mientras un **valor-p pequeño**, sugiere un **ajuste pobre** (para aceptar la hipótesis tendríamos que aceptar casi ningún riesgo).

Los p-valores pueden ser vistos como una medida de ajuste, con valores grandes siendo mejores. Esto sugiere, que podríamos calcular el estadístico de prueba para cada distribución a ser ajustada, y luego escoger la distribución que produzca el mayor valor-p. Muchos paquetes de software incluyen la opción de “*el mejor ajuste*”, con la cual el software recomienda al usuario el modelo de entradas, basado en la evaluación de todos los modelos factibles. En esos casos, algún resumen de medidas de ajuste, como la del valor-p, es usado para ordenar las distribuciones potenciales.

Lo anterior no es un enfoque errado, pero debe tenerse en mente lo siguiente:

1. El software no conoce nada acerca de las bases físicas de los datos y la información puede sugerir familias de distribuciones que son apropiadas.
2. Recuerde que tanto la distribución Erlang como la Exponencial son casos particulares de la distribución Gamma, mientras que la exponencial también es un caso especial de la distribución Weibull. Los procedimientos automatizados de “*el mejor ajuste*”, tienden a escoger las distribuciones mas flexibles (Gamma y Weibull) con mayor preferencia que la Erlang y la Exponencial, dada que su flexibilidad extra les permite un mayor acuerdo con los datos y con el resumen de las mejores medidas de ajuste. ***Pero, un acuerdo cercano con los datos, puede no siempre conducir al modelo de entrada mas apropiado.***

3. Una estadística resumen, como el valor-p, es simplemente eso, una medida resumen. *Ella dice muy poco o nada acerca de en donde existe la falta de ajuste (en el cuerpo de la distribución, en la cola derecha, o en la cola izquierda).* Una persona usando herramientas gráficas, puede observar donde la falta de ajuste está ocurriendo y decidir si esa situación es o no importante para la aplicación que tiene entre manos.

La recomendación de los autores (Banks, John S. Carson II, Barry L. Nelson and David Nicol) es que la selección automática de la distribución sea usada como una de varias maneras de sugerir distribuciones candidatas. Siempre inspeccione la selección automática usando métodos gráficos, y recuerde la escogencia final es suya.

Varias pruebas estadísticas están disponibles para determinar si las observaciones podrían representar una muestra independiente de la distribución ajustada. En otras palabras, las llamadas “pruebas de bondad de ajuste” pueden ser utilizadas para evaluar una hipótesis nula que establece que los valores observados son variables aleatorias independientes que tienen la función de distribución indicada. Aunque estas pruebas pueden omitir algunos desacuerdos sutiles entre los datos y la distribución, su utilidad para la determinación de cuál tipo de distribución se ajusta mejor a los datos ha sido bien establecida [Law y Kelton, 380].

5.4.1 Prueba Chi Cuadrada

Una **prueba Chi-Cuadrada** probablemente es la más comúnmente empleada para medir la bondad de ajuste. El resultado de la prueba está basado en un valor χ^2 calculado de los datos empíricos y en otro valor χ^2 crítico obtenido de una tabla Chi-cuadrada. Si el valor χ^2 calculado es menor que el valor crítico obtenido de la tabla, entonces la distribución teórica no puede ser rechazada como una buena representación de la distribución empírica.

El valor χ^2 derivado de los datos recogidos se basa en dos factores: 1) las frecuencias observadas en cada intervalo de clase, y 2) las frecuencias esperadas correspondientes a los mismos intervalos en una distribución teórica.

La ecuación se presenta enseguida:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

O_i = Frecuencia observada en el i-ésimo intervalo de clase.
 E_i = Frecuencia esperada en el i-ésimo intervalo de clase.
 k = Número total de intervalos de clase.

Observando el estadístico de prueba debe quedar intuitivamente claro que un valor pequeño de χ^2 es un indicio de que no hay mucha diferencia entre lo observado y lo esperado, lo cual apoya la decisión de no rechazar la hipótesis nula.

El primer paso para la realización de esta prueba es seleccionar un “nivel de significancia” (también a veces equivocadamente llamado como “nivel de confianza”). Este nivel asocia el riesgo involucrado con el rechazo de una hipótesis (H_0 : una distribución teórica es una buena representación de una distribución empírica) cuando realmente es cierta. En la jerga estadística, esto se conoce como el Error Tipo 1. Un nivel de significancia de 0.05 indica una probabilidad de 5% de incurrir en el Error Tipo 1. El nivel de significancia es uno de los dos ítems necesarios para determinar valores χ^2 críticos. El otro se conoce con el nombre de Grados de Libertad.

El número de grados de libertad en una prueba chi-cuadrada de bondad de ajuste es igual al número de celdas menos el número de cantidades calculadas a partir de los datos observados (por ejemplo los parámetros) que son usadas en los cálculos de las frecuencias esperadas. [Walpole y Meyers, 1972].

La frecuencia esperada se basa en el porcentaje del número total de observaciones. La determinación del factor de porcentaje puede requerir cosas tales como la media y la desviación estándar de los datos empíricos. Si esto es verdad, el número de grados de libertad es igual al total del número de intervalos de clase menos tres (tres factores: el total de las observaciones, la media y la desviación estándar). Si la frecuencia esperada está basada solamente en el número total de observaciones, entonces el valor de los grados de libertad es igual a $n-1$.

EJEMPLO de una prueba de bondad de ajuste

A continuación aparecen 100 observaciones del tiempo entre llegadas de artículos a una bodega de almacenamiento (tiempos en minutos):

18	13	3	40	9	29	10	3	8	10
1	17	29	2	22	1	22	1	4	32
20	5	8	6	10	3	1	11	13	2
15	8	1	23	29	9	34	17	10	4
15	2	1	1	40	8	6	6	8	1
3	24	14	24	8	14	28	12	18	7
1	5	6	10	54	12	13	1	22	45


5	12	2	14	12	1	33	23	7	5
12	5	46	18	2	2	6	2	39	7
4	4	2	19	1	25	12	3	5	1

Antes de la construcción del histograma de frecuencias, se debe decidir sobre cuántos intervalos de clase (o celdas) se van a utilizar. El número de intervalos usualmente está entre 5 y 20, dependiendo de la cantidad de datos recolectados. Con pocos datos se requerirán pocos intervalos. En la siguiente tabla aparece la clasificación de los datos anteriores en 11 intervalos de clase (celdas). En esta tabla, la columna “Frecuencia” refleja la cantidad de puntos de datos que caen en cada intervalo de clase. La columna de “Probabilidad” realmente es una columna de frecuencias relativas. Simplemente corresponde al porcentaje de todos los puntos de datos encontrados en cada intervalo.

INTERVALO DE CLASE	FRECUENCIA	PROBABILIDAD
0 - 5	36	0.36
6 - 10	21	0.21
11 - 15	15	0.15
16 - 20	7	0.07
21 - 25	8	0.08
26 - 30	4	0.04
31 - 35	3	0.03
36 - 40	3	0.03
41 - 45	1	0.01
46 - 50	1	0.01
>50	1	0.01

	100	

En el gráfico siguiente se presenta un histograma de probabilidad para los datos de la tabla anterior. Allí se presenta la distribución de los datos a través de todos los intervalos de clase:



La forma del histograma anterior indica que es muy probable que la distribución Exponencial sea la candidata para representar la distribución de los datos observados. Como se expuso anteriormente, la distribución Exponencial tiene una función de densidad de probabilidad en la cual el parámetro β (beta) es un parámetro de escala, correspondiente a la media de la distribución.

El valor calculado del promedio para los 100 datos de tiempo entre llegadas de este ejemplo es 12.41 minutos (recuerde que en la sección 5.3, debió haber encontrado el **estimador máximo verosímil** del parámetro beta de la exponencial, como: $\hat{\beta} = \bar{x} = \sum \frac{x_i}{n}$, que significa promedio del tiempo entre llegadas) . El

siguiente gráfico presenta una distribución exponencial con un beta igual a 12.41. Columnas obtenidas en una hoja Excel:


Fórmula:

$$f(x) = \left(\frac{1}{12.41} \right) e^{(-x/12.41)}$$

X	f(x)
---	------

0	0.080580
10	0.035997
20	0.016081
30	0.007183
40	0.003209
50	0.001433
60	6.40467E

Gráfico resultante en la hoja Excel:



A pesar de que todo parece “a la vista” andar bien, vamos a realizar la prueba de bondad de ajuste chi-cuadrada. Como la distribución Exponencial supone que la variable es continua, debemos trabajar con los intervalos de clase en tal forma que no haya discontinuidad entre ellos. Por tanto, elaboramos la siguiente tabla:

INTERVALO DE CLASE	FRECUENCIA OBSERVADA O_i	PROBABILIDAD DEL INTERVALO (*)	FRECUENCIA ESPERADA E_i	$\frac{(O_i - E_i)^2}{E_i}$
0 - 5	36	0.332	33.2	0.236
5 - 10	21	0.222	22.2	0.065
10 - 15	15	0.148	14.8	0.003
15 - 20	7	0.099	9.9	0.849
20 - 25	8	0.066	6.6	0.297
25 - 30	4	0.044	4.4	0.036
30 - 35	3	0.030	3.0	0.000
35 - 40	3	0.020	2.0	0.500
40 - 45	1	0.013	1.3	0.069
45 - 50	1	0.009	0.9	0.011
>50	1	0.018	1.8	0.356
Valor chi-cuadrado calculado =				2.422

* La probabilidad del intervalo se calcula así:

$$P(\text{intervalo } 15-20) = P(X \leq 20) - P(X \leq 15)$$

(Utilizando área bajo la curva exponencial, por integrales)

Pero, mejor, recordemos la fórmula de la Función de Distribución Acumulativa de la Exponencial (esta acumulada fue obtenida en la sección 4.3.2):

$$P(X \leq x) = F(x) = 1 - e^{(-x/\beta)}$$

Así, el cálculo de la probabilidad para el intervalo entre 15 y 20 de una distribución exponencial con un valor estimado de beta de 12.41 es como sigue:

$$\text{Así, que } P(\text{intervalo } 15-20) = P(X \leq 20) - P(X \leq 15) =$$

$$= \left[1 - e^{-\left(\frac{20}{12.41}\right)} \right] - \left[1 - e^{-\left(\frac{15}{12.41}\right)} \right] = 0.099$$

Esta probabilidad para el intervalo entre 15 y 20 corresponde a una frecuencia teórica esperada de 9.9 (la frecuencia esperada para el intervalo es el producto de su probabilidad por el número total de observaciones).

Con este valor podemos calcular para el intervalo $i = 4$, el factor $\frac{(O_i - E_i)}{E_i} = 0.849$, donde

O_i = Frecuencia observada en el i -ésimo intervalo de clase.

E_i = Frecuencia esperada en el i -ésimo intervalo de clase.

k = Número total de intervalos de clase.

Volvamos a nuestro ejemplo: Después de tener el valor chi-cuadrado calculado debemos encontrar el valor chi-cuadrado de tabla (o sea, el valor crítico chi-cuadrado).

Entonces la hipótesis nula, H_0 , es: la distribución hipotetizada que siguen los datos observados es una exponencial con un beta de 12.41. El número de grados de libertad es 9 (11 intervalos de clase menos dos factores: el total de observaciones y el valor medio)⁵.

Mirando la Tabla Chi-Cuadrado abajo vemos que, con 9 grados de libertad y nivel de significancia de 0.05 el valor chi-cuadrado crítico es 16.919.

⁵ El test mas conservativo es el que tiene $(n-1)$ grados de libertad (el que menos tiende a rechazar la hipótesis nula. Observe, que para un nivel de significancia dado, a mayor número de grados de libertad, mayor es el valor chi cuadrado ($\chi^2_{0.05} = 16.92$ con $n=9$ y $\chi^2_{0.05} = 18.31$ con $n=10$).

TABLA 3-Distribución Chi Cuadrado χ^2

P = Probabilidad de encontrar un valor mayor o igual que el chi cuadrado tabulado, v = Grados de Libertad

v/p	0,001	0,0025	0,005	0,01	0,025	0,05	0,1	0,15	0,2	0,25	0,3
1	10,8274	9,1404	7,8794	6,6349	5,0239	3,8415	2,7055	2,0722	1,6424	1,3233	1,0742
2	13,8150	11,9827	10,5965	9,2104	7,3778	5,9915	4,6052	3,7942	3,2189	2,7726	2,4079
3	16,2660	14,3202	12,8381	11,3449	9,3484	7,8147	6,2514	5,3170	4,6416	4,1083	3,6649
4	18,4662	16,4238	14,8602	13,2767	11,1433	9,4877	7,7794	6,7449	5,9886	5,3853	4,8784
5	20,5147	18,3854	16,7496	15,0863	12,8325	11,0705	9,2363	8,1152	7,2893	6,6257	6,0644
6	22,4575	20,2491	18,5475	16,8119	14,4494	12,5916	10,6446	9,4461	8,5581	7,8408	7,2311
7	24,3213	22,0402	20,2777	18,4753	16,0128	14,0671	12,0170	10,7479	9,8032	9,0371	8,3834
8	26,1239	23,7742	21,9549	20,0902	17,5345	15,5073	13,3616	12,0271	11,0301	10,2189	9,5245
9	27,8767	25,4625	23,5893	21,6660	19,0228	16,9190	14,6837	13,2880	12,2421	11,3887	10,6564
10	29,5879	27,1119	25,1881	23,2093	20,4832	18,3070	15,9872	14,5339	13,4420	12,5489	11,7807
11	31,2635	28,7291	26,7569	24,7250	21,9200	19,6752	17,2750	15,7671	14,6314	13,7007	12,8987
12	32,9092	30,3182	28,2997	26,2170	23,3367	21,0261	18,5493	16,9893	15,8120	14,8454	14,0111
13	34,5274	31,8830	29,8193	27,6882	24,7356	22,3620	19,8119	18,2020	16,9848	15,9839	15,1187
14	36,1239	33,4262	31,3194	29,1412	26,1189	23,6848	21,0641	19,4062	18,1508	17,1169	16,2221
15	37,6978	34,9494	32,8015	30,5780	27,4884	24,9958	22,3071	20,6030	19,3107	18,2451	17,3217
16	39,2518	36,4555	34,2671	31,9999	28,8453	26,2962	23,5418	21,7931	20,4651	19,3689	18,4179
17	40,7911	37,9462	35,7184	33,4087	30,1910	27,5871	24,7690	22,9770	21,6146	20,4887	19,5110
18	42,3119	39,4220	37,1564	34,8052	31,5264	28,8693	25,9894	24,1555	22,7595	21,6049	20,6014
19	43,8194	40,8847	38,5821	36,1908	32,8523	30,1435	27,2036	25,3289	23,9004	22,7178	21,6891
20	45,3142	42,3358	39,9969	37,5663	34,1696	31,4104	28,4120	26,4976	25,0375	23,8277	22,7745
21	46,7963	43,7749	41,4009	38,9322	35,4789	32,6706	29,6151	27,6620	26,1711	24,9348	23,8578
22	48,2676	45,2041	42,7957	40,2894	36,7807	33,9245	30,8133	28,8224	27,3015	26,0393	24,9390
23	49,7276	46,6231	44,1814	41,6383	38,0756	35,1725	32,0069	29,9792	28,4288	27,1413	26,0184
24	51,1790	48,0336	45,5584	42,9798	39,3641	36,4150	33,1962	31,1325	29,5533	28,2412	27,0960
25	52,6187	49,4351	46,9280	44,3140	40,6465	37,6525	34,3816	32,2825	30,6752	29,3388	28,1719
26	54,0511	50,8291	48,2898	45,6416	41,9231	38,8851	35,5632	33,4295	31,7946	30,4346	29,2463
27	55,4751	52,2152	49,6450	46,9628	43,1945	40,1133	36,7412	34,5736	32,9117	31,5284	30,3193
28	56,8918	53,5939	50,9936	48,2782	44,4608	41,3372	37,9159	35,7150	34,0266	32,6205	31,3909
29	58,3006	54,9662	52,3355	49,5878	45,7223	42,5569	39,0875	36,8538	35,1394	33,7109	32,4612

Puesto que el valor calculado es menor que el valor crítico ($2.422 < 16.919$), no hay suficiente evidencia para declarar que la distribución hipotetizada no es una buena representación estadística de la distribución empírica.

Otra medida útil de bondad de ajuste es la **Prueba de Kolmogorov-Smirnov**. A menudo simplemente llamado el Test KS, esta técnica envuelve la comparación de la función de distribución, de la distribución ajustada, con la función de distribución de los datos empíricos. El test KS es más útil en la evaluación de distribucio-

nes continuas, porque no requiere la agrupación de datos en intervalos discretos. El uso de éste test con distribuciones discretas, ha sido limitado por la necesidad de cálculos complejos para los valores críticos.

El **Test de Anderson-Darling**, es útil cuando más de una distribución posible puede representar los datos empíricos y la selección necesita basarse en la habilidad de la función de distribución de acertadamente incluir los valores extremos ("las colas").

Es importante usar las distribuciones de probabilidad que realmente representen el proceso estocástico que están imitando. La inferencia estadística no es una ciencia de precisión. El análisis de sensibilidad puede ayudar a seleccionar aquellas distribuciones de entrada que tendrán el impacto más grande sobre el desempeño del sistema. Y sobre estas distribuciones debe enfocarse mejor la atención.

UNIDAD VI

Algunos Aspectos Importantes en la Realización de Experimentos de Simulación

6.1 Introducción.

Uno de los pasos en un estudio de simulación es la realización de los experimentos de simulación con el modelo. La simulación, es básicamente la aplicación del método científico. En simulación se comienza con una teoría del porque ciertas reglas de diseño o estrategias administrativas son mejores que otras. Basado en esas teorías el diseñador desarrolla una hipótesis que luego prueba a través de la simulación. Basado en los resultados de la simulación el diseñador saca conclusiones acerca de la validez de sus hipótesis. En un experimento de simulación hay variables de entrada que definen el modelo, las cuales son independientes y pueden ser manipuladas o cambiadas. Los efectos de esas manipulaciones sobre otras **variables dependientes o de respuesta** pueden ser medidos y correlacionados.

Simulación de estado estable o no terminante

En algunos experimentos estamos interesados en el comportamiento del **Estado Estable** del modelo. *El comportamiento del Estado Estable no quiere decir que la simulación produzca una salida estable, sino que la distribución estadística (o variación) en las salidas (variables dependientes o de respuesta) no cambia con el tiempo.* Por ejemplo, la producción de una fábrica puede fluctuar entre 200 y 220 partes por hora bajo condiciones normales, y en ese sentido estaría en el estado estable. Se dice que estamos en una **simulación no terminante** o lo que es lo mismo de Estado Estable.

Simulación terminante

En muchas otras simulaciones podríamos estar solo interesados en un período de tiempo particular, tal como un día de trabajo en una fábrica. Se dice que estamos en una **simulación terminante**. Para este tipo de estudios la simulación podría nunca alcanzar el *Estado Estable*.

El problema del número de corridas y de la longitud de una corrida

Como con cualquier experimento que envuelva un sistema con características aleatorias, el resultado de una simulación también será por naturaleza aleatorio. Los resultados de una *sola corrida* de simulación representan solamente uno de varios posibles resultados. **Esto requiere que múltiples replicaciones sean corridas para probar la reproducibilidad de los resultados.** De otra manera, la decisión puede tomarse basada en una salida de “chiripa”, o una salida que no es representativa de lo que normalmente podría ser esperado. Ya que la simulación utiliza un generador de números pseudo-aleatorios, el correr la simulación varias veces simplemente reproduce la misma muestra. Para obtener una muestra independiente, el valor inicial de la semilla para cada flujo aleatorio (*stream*), debe ser diferente en cada replicación, de esa manera se asegura que los números aleatorios generados en cada replicación sean independientes.

Dependiendo del grado de precisión requerido en las salidas, puede ser deseable determinar un intervalo de confianza para las salidas. Un intervalo de confianza es un rango dentro del cual podemos tener cierto nivel de confianza de que la verdadera media se encuentra.

ProModel, provee facilidades para conducir experimentos con múltiples replicaciones y automáticamente calcula los intervalos de confianza. El modelador de todas maneras debe decidir que tipo de experimentación es el apropiado.

Cuando se conduce un experimento de simulación las siguientes preguntas deben ser hechas:

- Estoy interesado en el comportamiento de *Estado Estable* (**simulación no terminante**) del sistema o de un período específico de operación (**simulación terminante**) ?
- Cual es el mejor método para obtener las observaciones muestrales que puedan ser usadas para estimar el verdadero comportamiento esperado del modelo? (hay varias formas: múltiples replicaciones ó una larga replicación particionada en lotes (segmentos).
- Cuanta replicaciones deben ser realizadas?
- Cual es una longitud de corrida apropiada para el modelo que voy a simular?

La respuesta a estas preguntas está principalmente determinada por los siguientes factores:

- La naturaleza de la simulación (Terminante o no Terminante).
- El objetivo de la simulación (análisis de la capacidad de un sistema en particular o la comparación de varios sistemas alternativos).
- La precisión requerida (estimadores puntuales v.s. estimaciones de intervalos de confianza).

6.2 Simulaciones Terminantes versus No Terminantes (de estado estable)

Una parte de la configuración del experimento de simulación consiste en decidir que tipo de simulación se va a correr. Como ya se mencionó usualmente se distinguen dos tipos de simulaciones:

- Terminantes y,
- No Terminantes (de estado estable)

La diferencia entre las dos tiene que ver con el hecho de si nosotros estamos interesados en:

1. El comportamiento del sistema sobre **un período particular de tiempo**; ó en,
2. El comportamiento de **Estado Estable** del sistema

Lo anterior no tiene nada que ver, necesariamente, con el hecho de que el sistema termine o no termine. La decisión de realizar una simulación Terminal o no Terminal **tiene menos que ver con la naturaleza del sistema que con el comportamiento de interés para el experimentador.**

Una **simulación Terminante**, es la que *comienza en un estado determinado o un tiempo determinado y termina cuando alcanza un estado o tiempo definido*. Un estado inicial podría ser el número de partes en un sistema al inicio de un día de trabajo. Un estado terminante podría estar asociado con completar un número particular de trabajos. Considere por ejemplo, una fábrica que recibe una orden de manufactura de 200 artículos específicos. La compañía podría estar interesada en saber que tanto tiempo tomará producir los artículos con las actuales cargas de trabajo. La corrida de simulación inicia con el sistema vacío y termina cuando los 200 artículos estén listos, ya que eso cubre el período de interés. Como otro

ejemplo, un punto en el tiempo que llevaría a finalizar una simulación Terminante, sería la hora de cierre de un almacén. Otro caso podría ser, cuando se conoce por ejemplo, que el programa de producción para determinado artículo cambia semanalmente. Al final de un ciclo de 40 horas, el sistema es “vaciado” y un nuevo ciclo de producción comienza. En esta situación una simulación terminante debe ejecutarse, en la cual la longitud de la corrida sea de 40 horas.

Las simulaciones Terminantes no pretenden medir el comportamiento de Estado Estable del sistema. En una simulación Terminante las medidas promedio son de poco significado. Ya que la simulación terminante siempre contiene períodos de transición que son parte del análisis, la utilización de figuras tiene más significado si ellas se refieren a intervalos de tiempo sucesivos dentro de la simulación (en ProModel este análisis se realiza a través de los “History plot”.

La simulación no Terminante o la simulación de Estado Estable es aquella en la cual el comportamiento del sistema en el *Estado Estable* está siendo analizado.

Una simulación no Terminante no quiere decir que la simulación nunca termina, tampoco quiere decir que el sistema que está siendo simulado no tendrá eventualmente una terminación. Simplemente, quiere decir que teóricamente la simulación continuará indefinidamente sin cambios estadísticos en su comportamiento.

Para las **simulaciones no Terminantes**, el modelador **debe determinar una longitud apropiada de tiempo para correr el modelo**. Un ejemplo de una simulación no terminante es un modelo de una operación de manufactura en la cual se producen filtros de aceite de manera continua a la misma tasa. La operación utiliza dos turnos, con una hora de descanso en cada turno durante la cual todo para. Los descansos y los tiempos del tercer turno son excluidos del modelo ya que el trabajos siempre continúa exactamente donde fue dejando antes del descanso o del cambio de turno. La longitud de la simulación esta determinada por el tiempo que toma en obtener una lectura representativa del Estado Estable del comportamiento del sistema.

6.3 Corriendo simulaciones Terminantes.

Los experimentos que envuelven las simulaciones terminantes son realizados usualmente **realizando varias corridas** de simulación (conocidas como **replicaciones**), del período de interés, usando diferentes semillas aleatorias para cada corrida. Este procedimiento garantiza, que las observaciones realizadas sobre la respuesta del sistema, en el período simulado, sean estadísticamente independiente e insesgadas. Las estadísticas que, con frecuencia, se recogen son medi-

das de desempeño para intervalos sucesivos de tiempo sobre el período simulado.

Pregunta de reflexión: ¿ las prácticas de simulación 1-6 adelantadas corresponden a que tipo de simulación?

En las simulaciones Terminantes, estamos usualmente interesados *en las cuentas finales de producción* y en **los patrones de como cambia el comportamiento del sistema en el tiempo, mas que en el comportamiento general del sistema.**

Sería absurdo concluir, por ejemplo, que por el hecho de estar dos maquinistas (operadores) solamente ocupados el 40%, en promedio durante el día, solo se necesita un solo maquinista. *Esta medida promedio no nos revela nada acerca de la utilización de los maquinistas durante los períodos picos del día.* Un reporte mas detallado de los tiempos de espera durante todo el día de trabajo, podría revelar que son necesarios tres maquinistas durante las horas pico, mientras que solo un maquinista es necesario para trabajar fuera de la horas pico. En este sentido, Hoover y Perry⁶ anotaron lo siguiente:

“A menudo se sugiere en la literatura de simulación que el desempeño general sea acumulado a lo largo del curso de cada replicación de la simulación, ignorando el comportamiento de los sistemas en puntos intermedios de la simulación. Creemos que es un enfoque demasiado simple para recoger las estadísticas cuando se esta simulando un sistema terminante. Eso, nos recuerda, es estadístico que tenía su cabeza dentro de la nevera, y sus pies dentro del horno, y que comentaba que en promedio se sentía bastante confortable”.

Para las **simulaciones terminantes**, las **preguntas importantes** a responder cuando se realiza la simulación son:

1. Cual debería ser el estado inicial del sistema?
2. Cual es el punto en el tiempo o el evento terminante?
3. Cuantas replicas deben realizarse?

El **número de replicas** debería determinarse de acuerdo con la precisión requerida para las salidas. Si solo, se requiere una estimación burda del desempeño, de tres a cinco replicas son suficientes. Para precisiones mayores de-

⁶ Hoover, Steward V. y Ronald F. Perry. *Simulation: A Problem Solving Approach*, Addison-Wesley, Reading Massachusetts, 1990.

ben hacerse mas replicaciones hasta alcanzar un intervalo de confianza con el cual el experimentador se sienta confortable.

6.4 Corriendo simulaciones no Terminantes (o de estado estable)

El cálculo detallado del período de calentamiento se presenta en la siguiente unidad VII

Los asuntos asociados con la generación de estadísticas confiables de salida para simulaciones no terminantes, son diferentes de aquellos asociados con la generación de estadísticas para los sistemas Terminantes. En los sistemas de *Estado Estable*, debemos tratar con los siguientes asuntos:


- 6.4.1 Determinación del período inicial de calentamiento.
- 6.4.2 La selección de la manera de obtener las observaciones muestrales (de entre varias maneras alternativas: múltiples replicaciones o loteo por intervalos).
- 6.4.3 Determinación de la longitud de la corrida de la simulación.

6.4.1 Determinación del período de calentamiento⁷.

En una simulación de *Estado Estable*, estamos interesados en el comportamiento de estado estable del modelo. Ya que el modelo comienza vacío, toma algún tiempo mientras el modelo alcanza el estado estable. En las condiciones de estado estable, las variables de respuesta del sistema (por ejemplo, tasas de procesamiento, de utilización etc.) exhiben regularidad estadística (es decir, la distribución de esta variables es aproximadamente la misma de un período al siguiente).

La figura de abajo ilustra el comportamiento típico de una variable, Y , de respuesta del sistema, a medida que la simulación progresa a través de N períodos de simulación.

⁷ El calculo detallado del período de calentamiento se presenta en la siguiente unidad VII




Comportamiento de la variable de respuesta Y , para periodos sucesivos durante una simulación

El tiempo que toma alcanzar el estado estable es una función de los tiempos de las actividades y de la cantidad de actividad que ocurre dentro del sistema. Para algunos modelos, alcanzar el estado estable puede ser cosa de algunas horas de tiempo de simulación. Para otros modelos puede tomar varios cientos de horas de simulación alcanzar el estado estable. Entonces, cuando se modela el comportamiento de estado estable, tenemos el problema de la determinación del momento en que se alcanza el estado estable. Este período de inicio (arranque) es conocido usualmente como **período de calentamiento (warm-up period)**. Debemos esperar hasta el período de calentamiento y solo después de él comenzar a recolectar las estadísticas. De esta manera eliminamos el sesgo debido a las observaciones tomadas durante el estado transitorio del modelo.

Mientras varios métodos han sido presentados para determinar el período de calentamiento [ver en Law and Kelton (2000) páginas 520 a 525, los gráficos de Welsh], la forma mas fácil y el enfoque mas directo, aunque no necesariamente el mas confiable, es correr una simulación preliminar del sistema, preferiblemente con tres a cinco replicaciones, y observar (visualmente) en que momento el sistema alcanza la estabilidad estadística. La longitud de cada replicación debe ser relativamente larga para permitir que ocurran eventos raros, tales como, tiempos

de inactividad por paradas de estaciones de servicio (*downtimes*), al menos dos o tres veces durante la simulación.

Para determinar el período de calentamiento usando este método, una o mas variables claves de respuesta deben ser monitoreadas por períodos a lo largo del tiempo, como por ejemplo, el número promedio de entidades en una cola, o la utilización promedio de un equipo o recurso. Este enfoque asume que, el valor medio de la variable de respuesta monitoreada, es el indicador primario de convergencia en vez de la varianza como es usualmente el caso. Si es posible, es preferible reiniciar la variable de respuesta después de cada período a hacerle seguimiento al valor acumulado de la variable, ya que los gráficos acumulativos tienden a promediar la inestabilidad de los datos. Una vez que estas variables comiencen a exhibir estado estable, podemos agregar un factor de seguridad del 20% al 30% y estar razonablemente seguros en usar tal período como período de calentamiento. Recuerde, que el peligro está en subestimar el período de calentamiento y no en sobreestimarlos. Relativamente, es necesario poco tiempo y gasto para rodar un período de calentamiento mas largo del realmente requerido. La figura de abajo ilustra el promedio del número de entidades procesadas cada hora para varias replicaciones. Ya que la estabilidad estadística se alcanza aproximadamente 10 horas después de iniciada la simulación, entonces de 12 a 15 horas es probablemente un período seguro de calentamiento para usar en esa simulación.



6.4.2 Obtención de observaciones muestrales en simulación no terminante.

En una simulación Terminante, las observaciones muestrales son simplemente hechas corriendo múltiples replicaciones. En las **simulaciones de Estado Estable**, existen **varias opciones para obtener las observaciones muestrales**.

Dos enfoques ampliamente usados son:

1. correr múltiples replicaciones y
2. loteo de intervalos (*interval batching*).

Correr múltiples replicaciones para simulaciones no Terminantes es bastante similar a correr múltiples replicaciones para simulaciones Terminantes. La única diferencia es que en las simulaciones no Terminantes:

1. El período inicial de calentamiento debe ser determinado, y
2. Una longitud apropiada de corrida debe ser también determinada

Una vez las replicaciones han sido realizadas, los intervalos de confianza pueden ser calculados.

Corriendo múltiples replicaciones

Una ventaja de correr replicaciones independientes es que las muestras son independientes. De otro lado (desde el punto de vista negativo), correr la simulación a través del período de calentamiento ligeramente extiende la longitud del tiempo para realizar las replicaciones. Además, existe la posibilidad de que la longitud del período de calentamiento sea subestimada, causando sesgo en los resultados.

Corriendo loteo de intervalos

El loteo de intervalos (*interval batching*), también conocido como la técnica de las medias agrupadas (*batch means technique*), es un método en el cual una sola corrida larga es realizada, con las estadísticas reiniciadas a intervalos específicos de tiempo. Esto permite que sean recogidas estadísticas para cada intervalo de tiempo, con la media siendo calculada para cada intervalo de loteo “tanda” (*batch*). Ya que cada intervalo está correlacionado con el intervalo previo y el siguiente (la llamada correlación serial o autocorrelación), las tandas no son completamente independientes. La manera de ganar una mayor independencia es usar tamaños grandes de loteo y usar los valores medios para cada tanda. Cuando se usa el loteo por intervalos, se pueden realizar los cálculos para determinar intervalos de confianza. El número de intervalos de loteo a ser creado debe ser al menos de 5 a 10.

6.4.3 Determinación de la longitud de la corrida de simulación

La determinación de la longitud para una simulación *Terminante* es bastante simple ya que hay un evento natural o punto en el tiempo que lo define por nosotros.

La determinación de la longitud de corrida para una simulación de *Estado Estable* es más difícil ya que la simulación puede correr indefinidamente. El beneficio de esto último, sin embargo, es que podemos producir buenas muestras representativas. Obviamente, correr simulaciones extremadamente largas no es práctico, y así el asunto consiste en determinar una longitud apropiada que asegure una muestra representativa suficiente, de la respuesta en el estado estable. La longitud recomendada de la corrida de simulación para una simulación de Estado Estable depende de:

1. El intervalo entre el evento que ocurre con menos frecuencia, y
2. El tipo del método de muestreo usado (replicaciones independientes o loteo de intervalos).

Si se están corriendo replicaciones independientes, usualmente es buena idea correr la simulación tiempo suficiente para que cada tipo de evento ocurra (inclusi-ve los raros) al menos algunas veces. Recuerde que mientras mas tiempo corra el modelo, mas confianza podemos tener de que los resultados representen el comportamiento de *Estado Estable*. Si se están recolectando las observaciones de medias de los lotes (*batch mean*), se recomienda que el tiempo de corrida sea tan largo como sea posible para incluir al menos 1000 ocurrencias de cada tipo de evento (Thesen, Arne and Laurel E. Travis, *Simulation for Decision Making*, West Publishing Company, 1992.).

6.5 Comparando Sistemas Alternativos

Las simulaciones a menudo son realizadas para comparar dos o mas diseños alternativos. La comparación puede estar basada en una o mas variables de decisión, tales como capacidad de holgura, disponibilidad de recursos, etc. La comparación de diseños alternativos requiere un análisis cuidadoso, para garantizar que las diferencias que están siendo observadas, sean atribuibles a las verdaderas diferencias en el desempeño de los sistemas y no a variaciones estadísticas. Aquí, es donde es importante de nuevo correr múltiples replicaciones. Suponga, por ejemplo, que el *método A* de asignación de recursos, conduce a una producción de 100 entidades para un período dado de tiempo, mientras que el *método B* resulta en 110 entidades para el mismo período de tiempo. *Es válido concluir que el método B es mejor que el método A, o podrían replicaciones adicionales realmente conducir a una conclusión opuesta?*

La evaluación de configuraciones alternativas o políticas de operación puede, algunas veces, hacerse comparando el resultado promedio de varias replicaciones. Cuando las salidas son muy parecidas (cercanas) o donde la decisión requiere de

mayor precisión, debe usarse el método conocido como prueba de hipótesis. En este método, primero se formula una hipótesis (como por ejemplo que los métodos A y B conducen a la misma producción) y luego una prueba es realizada para ver si los resultados de la simulación nos conducen a rechazar la hipótesis. Las salidas de las corridas de la simulación puede conducirnos a rechazar la hipótesis de que los métodos A y B conducen a la misma producción y concluir consecuentemente que la cantidad de producción depende del método que está siendo usado.

Algunas veces puede haber evidencia insuficiente para rechazar la hipótesis establecida de tal manera que el análisis no resulta conclusivo. Esa falla de no obtener evidencia suficiente para rechazar la hipótesis puede deberse al hecho de realmente no existir diferencia en el desempeño, o podría ser el resultado de una variación muy alta en las salidas observadas dado el número de replicaciones. Si este es el caso, deben rodarse replicaciones adicionales del modelo o emplearse una de las varias técnicas de reducción de varianza (vea Law and Kelton, 2000).

6.6 *Diseño Factorial*

En los experimentos de simulación a menudo estamos interesados en averiguar la manera como la configuración (*settings*) de diferentes variables de entrada impactan la respuesta del sistema. En vez de correr cientos de experimentos para cada posible configuración (*setting*) de las variables, las técnicas del diseño experimental pueden ser usadas para averiguar aquellas variables de entrada de mayor importancia. Usando la terminología del ***Diseño de Experimentos***, las variables de entrada son conocidas como *factores*, y las medidas de salidas son conocidas como *respuestas*. Una vez haya sido identificada la respuesta de interés y hayan sido definidos los factores que se supone tienen influencia sobre esta respuesta, podemos utilizar los métodos del *diseño factorial* que prescribe el número de corridas que deben ser realizadas y que nivel o valor debe ser usado para cada factor. Como en todo experimento de simulación, es deseable correr replicaciones múltiples para cada factor y usar intervalos de confianza para garantizar la significancia estadística de los resultados.

Una inclinación natural cuando se experimenta con factores múltiples es probar el impacto que cada factor tiene sobre la respuesta del sistema. Este es un enfoque simple y directo, pero no da al experimentador información sobre como los factores interactúan entre ellos. Debe quedar claro, que la experimentación simultánea con dos o más factores puede afectar la respuesta del sistema de manera diferente a la experimentación con solo un factor a la vez, y mantener todos los demás factores sin cambio.

Un tipo de experimento que estudia el efecto combinado de múltiple factores en la respuesta del sistema es conocido como *diseño factorial completo con dos niveles*. En este tipo de experimento, simplemente definimos un valor de nivel alto y un valor de nivel bajo para cada factor y ya que estamos tratando de un experimento factorial completo, debemos experimentar con cada una de las combinaciones con los valores (*settings*) de los factores. Lo anterior quiere decir que si hay 5 factores y estamos probando dos niveles por cada factor, debemos probar cada una de las 2^5 posibles combinaciones de los niveles alto y bajo de los factores.


Para los factores que no tengan un rango de valores, del cual puedan ser seleccionados un valor alto y un bajo, el valor alto y bajo es arbitrariamente seleccionado. Por ejemplo, si uno de los factores que está siendo investigado es una política operativa para realizar un trabajo (ejemplo, primero en llegar, primero en ser atendido, o último en llegar, último en ser atendido), arbitrariamente seleccionamos una de las alternativas de política como el valor (*setting*) de nivel alto, y la otra como el valor de nivel bajo.

Para experimentos en el cual se estén considerando un número grande de factores, el diseño factorial completo de dos niveles, resultará en un número muy grande de combinaciones a ser probadas. En este tipo de situación, se usa un *diseño factorial fraccional* para estratégicamente seleccionar un subconjunto de combinaciones a ser probadas, para “enmascarar” los factores con poco o ningún impacto en el desempeño del sistema. Con el número reducido de factores que quedan se pueden realizar luego experimentos factoriales completos de una manera mas manejable.

6.7 Uso de Flujos Aleatorios (Random Streams)

Una de las características mas valiosas de la simulación es la habilidad para reproducir y aleatorizar las replicaciones de un modelo en particular. La simulación permite que los fenómenos probabilísticos dentro de un sistema sean controlados o aleatorizados como se desee, para realizar experimentos controlados. Este control es realizado a través del uso de flujos aleatorios (*random streams*).

Un flujo es una secuencia de números aleatorios únicos (independientemente ciclando) y que **están uniformemente distribuidos entre 0 y 1**. Vea la siguiente figura.



Ejemplo de un ciclo de Flujo Aleatorio con un período muy corto

Los flujos de números aleatorios son usados para generar números aleatorios adicionales a partir de otras distribuciones de probabilidad⁸ (exponencial, Binomial, Normal, Beta, Gamma, etc.). Después de secuenciar a través de todos los números del ciclo, el ciclo comienza de nuevo con la misma secuencia. La longitud del ciclo antes de que se repita es llamada **período del ciclo** y usualmente es bastante largo.

Un flujo aleatorio es generado usando un generador de números aleatorios o ecuación⁹. El generador de números aleatorios comienza con un valor inicial (semilla) después del cual, cada valor subsiguiente usa el valor previo como entrada al generador. Cada flujo que se usa en una simulación tiene su propia semilla independiente y guarda el registro de sus valores propios para usarlos como entradas subsiguientes del generador. El comienzo de la secuencia del ciclo depende del valor inicial (semilla) usado por el generador.

Cada vez que es usada la misma semilla para inicializar el flujo se obtendrá la misma secuencia de números. Esto significa que varios elementos del modelo pueden mantenerse constantes con respecto a su desempeño mientras otros pueden variar libremente. Simplemente especifique un flujo determinado de números aleatorios para un conjunto dado de actividades y otro flujo de números aleatorios para el resto de las actividades.

Ya que la misma semilla produce la misma secuencia de valores cada vez que es usada, **las funciones completamente independientes dentro del modelo**, deben tener desde un principio sus flujos propios. Por ejemplo, las distribuciones de llegada deben tener un flujo de números aleatorios que no se use en ninguna otra parte del modelo. De tal manera, que las actividades que se agregan a un modelo

⁸ Conocidos como generadores de proceso, asunto tratado en la unidad IV de ésta guía.

⁹ En la sección 3.3.1, se presentó el generador congruencial multiplicativo

y que muestren (tomen valores) de un flujo dado de números aleatorios, no alteren inadvertidamente el patrón de llegadas ya que no están afectando el muestreo de los valores de las llegadas generados a partir de la distribución de llegadas.

Para mostrar un ejemplo de cómo flujos múltiples pueden ser útiles, considere dos máquinas, Maquina_1 y Maquina_2, las cuales salen de operación cada 4 horas para reparación. Para modelar esto, suponga que la frecuencia o tiempo entre fallas se define a través de una distribución normal con una media de 240 minutos y una desviación estándar de 15 minutos, $N(240,15)$. Sea el tiempo de la reparación de 10 minutos. Si no se especifica un flujo en la distribución normal, el mismo flujo será usado para generar valores muestrales para ambas máquinas. Así, que si los siguientes dos números en el flujo son .21837 y .86469, la Maquina_1, obtendrá un valor muestral de la distribución normal que es diferente del de la Maquina_2. Y de esa manera las dos máquinas saldrán de operación (fallarán) en momentos diferentes.

Suponga, sin embargo, que los recursos que sirven a éstas máquinas, deben servirles al mismo tiempo, así que nos gustaría **que ambas máquinas fallen al mismo tiempo**. El uso de un mismo flujo, para determinar ambos tiempos de falla, **no nos** permitirá sacarlas de operación al mismo tiempo, ya que con cada llamada para la generación de un valor aleatorio normal, se obtendrá un número aleatorio diferente. Si se usan **dos flujos diferentes**, cada uno dedicado al tiempo de salida de operación (falla) de cada máquina y cada uno **teniendo la misma semilla**, nos aseguramos que ambas máquinas saldrán de operación al mismo tiempo todas las veces. Ya que ambos flujos utilizan el mismo valor de semilla, ellos producirán exactamente la misma secuencia de valores aleatorios.

UNIDAD VII

ALGUNOS ASPECTOS PRÁCTICOS RELACIONADOS CON ESTADÍSTICAS DE LA SIMULACIÓN

7.1 Introducción

Una parte crítica de un estudio de simulación está relacionada con la calidad de los datos que alimentan el modelo de simulación y con el uso apropiado e interpretación de las estadísticas.

Usted puede encontrarse bastante atareado con la responsabilidad de construir el modelo de simulación y colocarlo a correr, y parecerle algunas veces una segunda prioridad el analizar el uso apropiado y la calidad de los datos de entrada al modelo. Debe tener presente que:

- La exactitud de los datos usados por el modelo (datos de entrada al modelo) puede tener un impacto grande en los resultados obtenidos. Por ejemplo, el considerar en un proceso los tiempos de servicio y los tiempos entre llegadas como si fuesen constantes (exclusión de la varianza) **en el caso de** un sistema no constante (con llegadas y tiempos de proceso aleatorios) conduce a resultados totalmente errados.
- Otro error común es asumir que los datos que alimentan un modelo de simulación pueden ser representados por un determinado tipo de distribución cuando en realidad, deberían ser representados por otro tipo de distribución.
- La determinación correcta del período de calentamiento en una simulación no terminante es clave para una acertada estimación de las características operativas de un sistema.

Esta unidad está orientada a describir algunos aspectos estadísticos fundamentales y comunes que deben tenerse presente para un modelado apropiado de los sistemas a ser simulados. Donde sea apropiado se hará referencia a su uso dentro del contexto del software de simulación ProModel.

7.2 Aspectos Estadísticos

Algunos de los aspectos estadísticos críticos cuando se adelantan estudios de simulación tienen que ver con:

- 7.2.1. Estadísticas de las llegadas (Modelado de las llegadas).
- 7.2.2 Estadísticas de los procesos (modelado de los tiempos de proceso)
- 7.2.3 Uso de flujos <Streams> de números aleatorios.
- 7.2.4 Estadísticas de salida.

7.2.1 Estadísticas de llegadas (Modelado de llegadas)

De acuerdo con el sistema real que se este modelando, las llegadas se pueden modelar las llegadas como:

- Llegadas cíclicas.
- Llegadas periódicas
- Llegadas iniciadas internamente.

Llegadas cíclicas.

Las llegadas cíclicas son llegadas que ocurren con un patrón que fluctúa con el tiempo. Ejemplos de ciclo de llegadas que exhiben un patrón son las llegadas de aviones a un aeropuerto, los clientes a un almacén o a un restaurante. Por ejemplo, al comienzo del día las llegadas pueden ser escasas; a medida que el día progresa ellas aumentan en uno o más períodos pico y luego disminuyen. Mientras la cantidad total de llegadas durante un ciclo dado puede variar, el patrón o distribución de las llegadas en cada ciclo se asume que es el mismo.

A manera de ejemplo práctico, y usando el paquete de simulación ProModel, antes de registrar en ProModel las llegadas cíclicas, debe crearse un ciclo de llegadas usando la tabla de edición de los ciclos de llegada que se accesa a través del menú principal por *Build / More Elements / Arrival Cycles*. Los campos de la tabla de edición de llegadas son:

ID:	El nombre del ciclo.
Qty /%:	Seleccione ya sea <i>Percent</i> ya <i>Quantity</i> como base para registrar el número total de llegadas durante la ocurrencia del ciclo.
Table:	Click en éste campo permite abrir la tabla de edición para especificar los parámetros del ciclo. A manera de ejemplo de un ciclo de llegadas que modela las llegadas a un sistema de manufactura, suponga que conocemos que los paquetes llegan durante el día (9:00 AM a 5:00 PM) siguiendo aproximadamente los siguientes porcentajes:

De	A	Porcentaje
9:00 am	10:30 am	10
10:30 am	11:30 am	15
11:30 am	1.00 pm	30
1:00 pm	4:00 pm	15
4:00 pm	5:00 pm	30

La tabla dice que el 10% de los paquetes diarios llegan en las primeras 1.5 HR, 15% de los paquetes llegan en el período entre 1.5 y 2.5 HR de comenzado el ciclo de llegadas y así sucesivamente. Las llegadas están distribuidas aleatoriamente durante el intervalo de tiempo durante el cual llegan.

Para registrar en ProModel el ciclo de llegadas debe entrarse a la caja de diálogo de llegadas (*Arrivals*) por la barra del menú principal *Build / Arrivals*.

Hacer *click* izquierdo en la entidad cuya llegada va a procesarse y que debe aparecer en el <<Cuadro de herramientas>> y hacer *click* izquierdo en la estación a donde “llegará” la entidad.

En el <<Cuadro de edición de llegadas>> (*Arrivals*) aparece:

Entity (Entidad): La entidad que llega.

Location (Estación): La estación a la que se llega.

Qty Each (Cantidad por llegada): El número de entidades (en un grupo) que llegan en un momento específico cada vez que una llegada (*arrival*) sucede. Si se tiene previamente creado un ciclo de llegadas y desea usarse como llegadas debe entrarse en éste campo el nombre del ciclo de llegadas a ser usado, opcionalmente seguido por la cantidad de entidades a llegar. Por ejemplo, en éste campo puede ir una distribución de Poisson o una distribución normal con sus respectivos parámetros. Cuando no se ha definido un ciclo de llegadas todas las entidades llegarán al comienzo de la simulación. Un **ciclo de llegadas lo que hace es dividir la cantidad especificada de llegadas**, en el campo *Qty Each*, **en varios grupos** que llegarán durante todo el día de acuerdo con lo definido en el ciclo.

First Time (Primera Ocasión): La primera vez (en tiempo de reloj de simulación) que ocurrirá la llegada.

Occurrences (Ocurrencias): El número de repeticiones de esta llegada, en llegadas periódicas (o de ciclos de llegada) que habrá durante la simulación. Si un ciclo de llegadas está siendo usado, éste es el número de veces que el ciclo será repetido. Por ejemplo, 20 en éste campo significa que el ciclo se repetirá 20 días (veces).

Frequency (Frecuencia): El tiempo entre las llegadas. Si un ciclo de llegadas ha sido previamente definido para la cantidad de llegadas (*Qty Each*), éste es el tiempo entre el comienzo de un ciclo y el comienzo del siguiente. Por ejemplo, 24 significa que cada ciclo se repite cada 24 HR. La frecuencia de las llegadas debe definirse en las mismas unidades de tiempo que el ciclo de llegadas. Por supuesto, no puede ser inferior a la longitud del ciclo definido en *Qty Each*. Aquí puede introducirse también, una distribución de probabilidad como la exponencial o la uniforme, por ejemplo.

Llegadas periódicas

Las llegadas periódicas son llegadas que ocurren a intervalos regulares. Por ejemplo, las primeras 6 horas que un parqueadero está abierto, unos buses (las llegadas) llegan exponencialmente, aproximadamente cada 60 minutos. Contienen un número variable de pasajeros (aprox. 50) basado en una distribución de Poisson. El primer bus llega cada día aleatoriamente. En el campo *Qty Each* (Cantidad por llegadas) va P(50), que especifica el número de entidades que llegan cada vez (todas llegan al mismo tiempo) de acuerdo con una distribución de Poisson con media 50. En el campo *Occurrences* (Ocurrencias) que registra el número total de llegadas, va 6 que ocurrirán. En el campo *Frequency* (Frecuencia) va E(60) min. que especifica el tiempo entre llegadas (exponencialmente distribuidos con una media 60 minutos). En el campo *First Time* (Primera Ocasión), debe colocarse la hora del comienzo del día.

Llegadas iniciadas internamente

Las llegadas iniciadas internamente están relacionadas con entidades que son introducidas en el sistema por algún evento interno (disparador), tal como la iniciación de una orden de pedido.

Resumen de algunas distribuciones de Probabilidad usadas en las llegadas (ver detalles de su formulación analítica en la Unidad V de ésta guía).

La distribución de Poisson

La distribución de Poisson está usualmente asociada con las *cantidades de llegadas* (campo *Qty Each*). Esta distribución refleja la probabilidad asociada con un número finito de éxitos que ocurren en un intervalo de tiempo de llegadas. Por ejemplo, si 24 entidades llegan en un período de tiempo de 4 horas, la cantidad promedio por hora es de 6. La distribución de Poisson es una distribución discreta. Los valores generados por ésta distribución son mayores que o iguales a cero.

Características de la distribución de Poisson:

- ❑ Llegadas aleatorias discretas.
- ❑ Períodos de tiempo fijo.
- ❑ El muestreo de la distribución retorna valores enteros.
- ❑ Apropiaada para la cantidad de llegadas pero no para la frecuencia.

La distribución Exponencial

La distribución exponencial es utilizada para generar valores de variables aleatorias relacionadas con el tiempo entre llegadas de entidades. Ejemplos de entidades incluyen las llegadas de paquetes a una estación de despacho o la llegada de solicitudes de trabajo a un sistema de cómputo.

Una parte del modelaje de ***llegadas periódicas*** es el uso de una distribución exponencial como intervalo de llegadas (*campo Frequency*).

Características de la distribución exponencial:

- ❑ Llegadas aleatorias continuas.
- ❑ Períodos de tiempo variable.
- ❑ El muestreo de la distribución retorna valores reales.
- ❑ Apropiaada para frecuencias (es decir para tiempo entre llegadas) pero no para cantidad de llegadas.

7.2.2 Estadísticas de los procesos

Algunas organizaciones tienen información muy detallada sobre algunos aspectos de sus operaciones tales como los tiempos de servicio o los tiempos de mantenimiento. En tales casos, las estadísticas pueden ser estimadas. Si están disponibles los datos completos, ellos pueden ser analizados y comparados con los patrones de curvas estadísticas estándares (asunto tratado en las secciones 5.3- Estimadores sugeridos para parámetros de algunas distribuciones y 5.4- Pruebas de bondad de ajuste).

Estimación de los parámetros de Entrada cuando no existen datos

Deben realizarse entrevistas:

- Prepárese observando personalmente las operaciones.
- Siempre pregunte si las respuestas dadas son hechos u opiniones.
- Siempre pregunte por Números y Unidades.
- Siempre pida datos formateados (archivos de bases de datos, hojas de cálculo).
- Nunca sugiera las respuestas.
- Siempre busque las excepciones.

Muchas veces, los datos necesarios para construir un modelo son escasos o totalmente inexistentes. En este caso, parámetros críticos para el modelo tales como tiempos de proceso y tasas de llegada deben ser estimados a través de las distribuciones genéricas. Debe tenerse en consideración:

- Normal: $N(\text{media}, \text{desviación estándar})$, puede ser una mala elección ya que sus valores pueden ser negativos.
- Uniforme: $U(\text{media}, \text{rango})$, si las condiciones apropiadas existen puede ser una buena elección.
- Triangular: $T(\text{min}, \text{moda}, \text{max})$, puede también ser una buena elección, pero los procesos humanos son raramente lineales.
- Beta: $B(\text{forma1}, \text{forma2}, \text{min}, \text{max})$, es mejor que la triangular pero se necesita el promedio.

Ocasionalmente, ninguna de las distribuciones standard disponibles puede representar adecuadamente los patrones estocásticos de los sistemas reales a ser modelados. En estos casos, puede definirse una distribución del usuario para representar el conjunto de datos

Buscando la mejor distribución para representar un conjunto de datos

La elección de una distribución estándar sobre otra depende totalmente de los datos empíricos que se pretende representar. Existen paquetes de software disponibles que pueden rápidamente analizar los datos empíricos y sugerir la curva mas apropiada (ver sección 5.4 de ésta guía y en el modulo de prácticas el **laboratorio #13** con Stat::FitTM).

7.2.3 Flujos <Streams> de números aleatorios

Una de las características mas valiosas de la simulación es la habilidad tanto de reproducir como también de aislar funciones probabilísticas dentro de un sistema con el objeto de realizar estudios específicos. En el mundo real, los eventos tienden a ocurrir aleatoriamente de acuerdo con ciertos patrones estadísticos o distribuciones.

ProModel usa los números generados por un generador de números aleatorios para determinar los valores muestrales arrojados por una distribución particular (Normal, Beta, Gamma, etc.). El generador de números aleatorios produce una secuencia de números aleatorios entre 0 y 1 que se repiten después de un ciclo bastante largo. En que número comienza la secuencia en el ciclo depende del valor inicial usado como semilla por el generador.

ProModel proporciona 100 flujos (*streams*¹⁰) independientes para usar cuando un evento aleatorio ocurre en el modelo. Pueden ser usados para tiempos de proceso, tiempos de mantenimiento (*downtimes*), frecuencias de llegadas, etc. Por ejemplo, usar stream 1 (asociado con semilla 1) para generar los tiempos de operación y stream 2 (asociado con semilla 2) para generar las llegadas. Los stream que tengan la misma semilla generaran la misma secuencia de números aleatorios. La tabla de edición de *stream* se accesa por *Build /More Elements / Streams*.

Al usar *streams* se sugiere:

- Siempre coloque las llegadas (*Arrivals*) en un *stream* separado del resto del modelo (por ejemplo de las operaciones, *downtimes*, etc.).
- Reinicie ciertos *streams* cuando corra replicaciones múltiples para aislar los efectos de fuentes específicas de aleatoriedad.
- Coloque dos o mas recursos o estaciones (*locations*) en *streams* separados pero usando semillas idénticas para duplicar *downtimes* aleatorios

7.2.4 Estadísticas de salida

La **simulación por si misma no optimiza** un sistema. Ella simplemente evalúa soluciones proporcionando estimaciones de cómo un dado sistema se comportaría.

Para sacar conclusiones útiles y correctas de los resultados de la simulación se requiere que datos relevantes y confiables sean generados por la simulación, y que los datos sean correctamente analizados. Para lo anterior es necesario considerar:

- Si el sistema es terminante o no lo es.
- El intervalo de confianza.
- La determinación de número de corridas de la simulación (ver sección 7.3).
- La determinación del período de calentamiento, en ingles "*warm-up period*" (ver sección 7.3).

Sistema Terminal

Cuando las características del sistema indican que el modelo debe correr por cierto tiempo y luego parar. Es el caso cuando los sistemas se llenan y desocupan dentro de un horizonte de tiempo fijo. O cuando el sistema opera durante un período fijo de tiempo el cual es determinado por un evento. Por ejemplo, la simulación de la mayoría de sistemas de servicio institucional como las entidades bancarias, restaurantes, centros de servicio al usuario, etc.

¹⁰ Stream: secuencia de un ciclo de números aleatorios independientes los cuales son usados en conjunto con los generadores de las distribuciones de probabilidad

Sistemas no Terminales

Cuando las características del sistema no indican que el modelo deba correr por cierto tiempo o parar a determinada hora. Es el caso cuando el sistema opera a lo largo de un horizonte de tiempo fijo pero el trabajo es adelantado entre los horizontes de tiempo. O cuando el sistema opera continuamente mientras existan entidades disponibles. Ejemplos de sistemas no terminales incluyen la simulación de aeropuertos, y la simulación del procesamiento de documentos.

Se pueden tener elementos de ambos sistemas (terminales y no terminales). En tales casos, se necesita considerar los objetivos del estudio de simulación y determinar las variables de decisión (que tanto tiempo?; Cuando?; Cuanto?; Quien?; Cuantos?

Por ejemplo, si se está modelando una oficina y la variable de interés es el número de clientes que aparecen durante el curso del día (8 AM – 5 PM) debe tratarse el modelo como una simulación terminante. De otro lado, si la variable de interés tiene que ver con el proceso de las cuentas en trámite, y el trabajo dejado al final del día es automáticamente transferido al siguiente día, entonces el modelo debe tratarse como una simulación no terminante.

Análisis de las salidas

(Tomado de BATEMAN, Robert, Charles HARRELL, y Otros. *System Improvement Using Simulation*. 1995, Capítulo 10, págs 63-79)

Las personas de un equipo envuelto en un estudio de simulación a menudo se sorprenderán con lo que son capaces de aprender acerca del sistema que están estudiando solamente al adelantar los pasos relacionados con la construcción del modelo. Aunque buena parte del esfuerzo dedicado a un proyecto de simulación está asociado con la recolección de los datos de entrada y la construcción del modelo mismo, como mínimo igual atención debería dedicársele al examen cuidadoso de los resultados de salida.

El enfoque a ser tomado en el análisis de las salidas a menudo dependerá de varios factores, que dependen de si la simulación es *Terminante* o de *Estado Estable* y de si el objetivo es el análisis de un solo sistema o la comparación de dos sistemas alternativamente competitivos.

Tipos de salida.

Aunque cada industria tiene sus propias medidas, algunas categorías de resultados de salida son comunes en un amplio rango de aplicaciones. La terminología puede variar, pero las razones para aplicar estas mediciones patrón son los factores comunes en casi todos los negocios. Cuatro de las categorías mas amplia-

mente usadas están relacionadas con el **throughput**, **makespan**, **utilización** y **colas (queuing)**.

La cantidad de productos vendibles manufacturados o el número de clientes servidos son medidas de salida directamente relacionadas con la habilidad de una organización para generar ingresos. Cuando se van hacer cambios a un sistema existente, el impacto sobre el **throughput** casi siempre es tomado en consideración. Como también, la habilidad de producir a algún nivel mínimo establecido es un requerimiento para la implementación de un sistema no existente. El impacto de las medidas de mejoramiento de la calidad sobre las salidas también es de interés, y la habilidad que tiene la simulación para manejar factores probabilísticos asociados con tolerancias, tasas de falla, etc., ha hecho el modelaje dinámico una parte indispensable en muchos programas de mejoramiento continuo de la calidad.

Las medidas relacionadas con el **makespan** o el tiempo total del ciclo (*total cycle time*) son útiles para rastrear y minimizar el tiempo que una entidad gasta en el sistema. Ya que la mayoría de los factores que conllevan costos están directamente o indirectamente ligados a la cantidad de tiempo que una organización tiene un artículo, el esfuerzo por minimizar el tiempo normalmente reduce los costos.

La reducción de inventarios, tamaños menores y sistemas “pull” son algunos de los cambios en los sistemas que son típicamente modelados. Aunque el tiempo total que una entidad toma en viajar a través del sistema es el resultado, sobre el cual lo cambios pueden ser evaluados, estadísticas detalladas mostrando las relaciones entre los tiempos productivos y los tiempos que no agregan valor, son los mas útiles para identificar las áreas en las cuales son necesarias las mejoras. Las empresas de servicios tienen corolarios sobre el tiempo requerido para completar las transacciones de sus clientes.

Aunque el costo y el **throughput** han recibido, en los últimos años, creciente énfasis, la **tasa de utilización** del personal y de los equipos continúa siendo relevante como herramienta para localizar áreas en las cuales la adición o “redireccionamiento” de recursos podría conducir al mejoramiento del desempeño general. Un cuidadoso examen de los valores de utilización ha ahorrado a las compañías millones, resaltando maneras para una utilización mejor de los recursos existentes, envés de buscar compras costosas de nuevos equipos.

Las **colas**, como los inventarios a menudo tienden a esconder los problemas permitiendo que algunas ineficiencias no sean notadas. El “rastreamiento” tanto del promedio como del máximo nivel de cola puede develar problemas que podr-

ían pasar inadvertidos usando estadísticas generales de utilización para un área de trabajo particular, especialmente si más de un tipo de entidad está utilizando el recurso.

7.3 Cálculo del Período de calentamiento (warm-up period) para simulaciones de Estado Estable

Antes de comenzar el análisis de los datos de salida, el modelador debe hacer todos los esfuerzos para asegurarse que las salidas representen una estimación acertada de los verdaderos valores del sistema. Una técnica útil para mejorar la confianza de los resultados de salida para las simulaciones de Estado Estable es dar un período de inicialización para el cual las estadísticas no son tenidas en cuenta (básicamente, se desea determinar cuando reiniciar las estadísticas y comenzar a coleccionar las salidas válidas que no reflejen sesgo influenciadas por las condiciones iniciales).

La condición de Estado Estable implica que la simulación ha alcanzado un punto en el tiempo en el cual el estado del modelo es independiente de las condiciones iniciales de arranque. La cantidad de tiempo requerida para alcanzar las condiciones de Estado Estable es conocida como período de calentamiento (*warm-up period*). La recolección de los datos comienza después de que se haya completado el período de calentamiento.

Determinación del período de calentamiento (warm-up period).

Básicamente, se desea determinar cuando reiniciar las estadísticas y comenzar a coleccionar las salidas válidas que no reflejen sesgo influenciadas por las condiciones iniciales. La determinación de éste período puede ser lograda utilizando la **técnica de los promedios móviles** calculados a **partir de las salidas** producidas por múltiples replicaciones del modelo. Uno de tales procedimientos para lograr esto es conocido como el método gráfico de Welch [Law and Kelton (2000) páginas 520 a 525]

Suponga que un modelo de simulación ha sido construido para analizar los costos mensuales del trabajo en proceso (WIP-Work in Process) asociado con el diseño de un sistema dado. Se han realizado cinco replicaciones independientes del modelo, cada una con flujo de números aleatorios diferente. Cada corrida registra los costos mensuales del WIP ocasionados cada mes durante un período de 39 meses. El promedio de los costos del WIP para el *i*-ésimo período es luego calculado a lo largo de todas las ($J=5$) replicaciones del modelo. La séptima columna de

la Tabla 7.1 muestra los resultados promedio. Estos resultados están luego trazados en la gráfica 10A.

La condición del estado estable ocurre en el punto en el cual la curva de la media transitoria se suaviza. El gráfico 10A mencionado no muestra éste tipo de información. Los gráficos que muestran el promedio móvil para cada período tienden a suavizarse con mayor facilidad. Un costo promedio móvil para cada período puede obtenerse de acuerdo con la siguiente ecuación donde $\bar{Y}_i(w)$ representa el costo promedio móvil calculado para el i -ésimo período:

$$\bar{Y}_i(w) = \sum_{s=-(i-1)}^{i-1} \frac{\bar{Y}_{i+s}}{2i-1} \quad \text{para } i = 1, \dots, w$$

$$\bar{Y}_i(w) = \sum_{s=-w}^w \frac{\bar{Y}_{i+s}}{2w+1} \quad \text{para } i = w+1, \dots, m-w$$

m es el número total de períodos en cada replicación del modelo.

w representa la “ventana” del promedio móvil.

i representa el período al cual se le ha de calcular el promedio móvil


Si $i \leq w$, entonces el valor del actual período, $\bar{Y}_i$, es promediado con los valores de los w **precedentes** periodos conjuntamente con los w períodos **siguientes** para obtener $\bar{Y}_i(w)$. Note que el valor de m debe escogerse grande, que w debe ser menor que o igual a $m/2$.

Y_{ij} Costo observado durante i-ésimo período y j-ésima replicación (en miles de dólares)						$\bar{y}_i(w)$ Costo promedio móvil durante el i-ésimo Período			
Periodo -iésimo	Promedio Período					$\bar{y}_i = \bar{x}(5)$	w =5	w=10	w=19
Period	Rep 1	Rep 2	Rep 3	Rep 4	Rep 5				
1	465.18	224.24	279.99	596.05	544.54	422	422	422	422
2	521.58	357.41	358.01	872.99	230.81	468.16	522.2	522.2	522.2
3	663.02	407.14	532.68	244.39	1535	676.45	502.72	502.72	502.72
4	389.93	495.02	296.21	240.45	1442.82	572.88	568.92	568.92	568.92
5	240.74	737.54	318.34	286.13	287.77	374.1	571.26	571.26	571.26
6	461.24	1085.2	776.97	565.59	1325.52	842.9	560.94	560.94	560.94
7	461.64	352.09	241.88	1051.51	1022.49	625.92	587.72	563.86	563.86
8	1184.1	308.75	263.12	286.97	322.46	473.08	585.46	574.53	574.53
9	1276.8	202.8	727.63	643.93	578.21	685.88	568.25	569.68	569.68
10	473.76	460.59	325.86	906.02	477.74	528.79	588.95	578.06	578.06
11	405.5	405.23	503.67	697.96	488.75	500.22	611.93	565.67	565.67
12	1161.5	284.69	352.24	867.54	916.62	716.52	575.28	568.46	558.81
13	376.81	500.97	192.96	509	636.92	443.33	546.57	569.65	561.05
14	352.05	329.3	587.45	336.11	530.74	487.13	593.43	564.58	563.82
15	518.96	634.81	716.81	533.05	1899.13	800.55	588.58	566.04	560.68
16	673.88	853.97	563.86	179.72	864.17	626.92	564.45	582.64	558.51
17	376.99	1098.7	290.92	205.43	276.93	439.79	562.67	565.07	567.4
18	139.26	339.08	563.49	319.1	189.2	310.03	542.35	557.7	563.35
19	199.54	4032.4	355.94	138.88	215.99	988.54	553.87	562.11	560.86
20	542.79	908.48	633.9	349.55	727.93	632.52	564.45	552.18	561.87
21	383.47	317.29	165.11	345.11	106.2	263.44	557.38	554.46	
22	276.26	387.05	336.19	789.89	613.58	480.59	543.47	554.19	
23	336.39	388.63	605.87	315.2	818.9	493	546.31	563.67	
24	562.06	323.83	1311.94	339.76	312.95	570.11	569.55	559.6	
25	931.46	236.8	706.43	484.3	658.11	603.42	523.1	566.66	
26	182.82	352.79	991.44	271.73	1815.32	722.82	518.01	549.41	
27	589.21	649.52	54464	296.36	289.96	473.94	539.02	547.96	
28	103.42	936.04	393.21	771.45	151.18	471.06	578.57	567.48	
29	219.14	1338.3	163.15	169.59	938.19	565.67	566.28	567.54	
30	169.36	841.89	651.41	492.09	232.72	477.5	572.21		
31	791.25	137.11	734.38	807.81	401.16	576.54	577.21		
32	1361	274.57	457.19	148.87	231.46	184.62	545.72		
33	530.04	1259.5	497.51	1300.9	990.27	915.64	579.87		
34	198.98	275.2	177.6	723.29	414.02	357.82	565.35		
35	523.28	1012.5	904.77	212.75	523.06	635.23			


36	633.3	723.07	431.72	245.69	58.22	438.4			
37	631.47	455.12	1256.28	287.57	351.78	596.44			
38	807.24	1627.8	994.93	215.5	603.36	849.67			
39	271.41	138.54	352.43	441.73	352.38	311.3			

Tabla 7.1 Determinación del período de calentamiento para una simulación de Estado Estable.


Los gráficos 10B a 10D muestran el promedio móvil para los costos de los trabajos en proceso (WIP) para $w=5$, $w=10$, y $w=19$ respectivamente. La curva para $w=19$ se seleccionó para estimar el período de calentamiento p porque es la mas suavizada de los tres gráficos. Un período de calentamiento con $p=12$ es escogido como período de calentamiento.




Graph 10A: Average Monthly Cost



Graph 10B: Moving Average for $w=5$



Graph 10C: Moving Average for $w=10$



Graph 10D: Moving Average for $w=19$

ProModel ofrece dos alternativas para fijar el tiempo de calentamiento:
Usar la expresión Warmup conjuntamente con el tiempo de calentamiento, como por ejemplo: *If clock(hr)=53 Then Warmup*; o usar la caja de diálogo de opciones

de simulación a la cual se accede por *Simulation /Options* y establecer los parámetros para fijar el período de calentamiento.

7.4 Número de Replicaciones

Un método esencial para mejorar la confiabilidad de los resultados de salida es correr más de una replicación independiente de la simulación. Replicaciones múltiples e independientes del modelo siempre son necesarias en las simulaciones estocásticas. El análisis estadístico de las salidas generadas es un prerequisite crítico para realizar conclusiones válidas.

Los procesos estocásticos (o procesos compuestos por eventos ocurriendo aleatoriamente) existen en la mayoría de los sistemas. La simulación estocástica/dinámica evalúa el impacto de estos procesos a medida que ellos interactúan en el tiempo. Las distribuciones de probabilidad conjuntamente con los generadores de números aleatorios son usados para crear los valores representativos del comportamiento estocástico de un sistema. Los números aleatorios creados son producidos a partir de un número inicial conocido como semilla aleatoria. Cada valor de semilla del número aleatorio produce un único flujo (*stream*) de valores de números decimales entre 0 y 1. Los números aleatorios decimales son luego trasladados a valores aleatorios asociados con una distribución de probabilidad. Cuando la semilla aleatoria cambia, un conjunto diferente de valores aleatorios es creado.

Números de semilla individuales son asignados a cada uno de los procesos estocástico. Los resultados obtenidos de una sola replicación del modelo están directamente relacionados con los números de las semillas seleccionadas. El cambio de los valores de la semilla puede cambiar la secuencia de los eventos que ocurren en la simulación. Los datos generados por una simulación estocástica son en si mismos estocásticos. Las decisiones con base solo en las salidas generadas por una sola replicación del modelo son malas recomendaciones. Las salidas de replicaciones múltiples del modelo deben ser analizadas con los principios de la inferencia estadística para que lleven a conclusiones válidas.

Hay procedimientos estadísticos para calcular el número necesario de replicaciones del modelo para establecer un *nivel de confianza* asociado con el error estadístico entre $\bar{X}$ (estimador puntual de la media) y μ (la verdadera media teórica-poblacional). El parámetro α es usado para definir la probabilidad de que el error entre $\bar{X}$ y μ exceda una cantidad especificada (la cantidad del error es denotada

como **e**). Si $\alpha = 0.10$ (10% de probabilidad de que la diferencia entre $\bar{X}$ y μ exceda a la cantidad **e**), entonces podemos tener una confianza de $(1-\alpha)$ por ciento de que la diferencia no excederá la cantidad especificada **e**.

Un enfoque para calcular el número de replicaciones requeridas para acertar un seleccionado grado de exactitud en los términos arriba descritos es como sigue:

$$N = \left[\frac{t_{n-1, 1-\alpha/2} s(n)}{e} \right]^2$$

N denota el número de replicaciones del modelo necesarias para alcanzar el nivel necesario de exactitud.

s(n) es el estimador puntual de σ basado en **n** replicaciones del modelo.

e denota la cantidad de error entre la media estimada y el verdadero valor de la media.

$t_{n-1, 1-\alpha/2}$ es el valor crítico para una distribución t, con (n-1) grados de libertad.

La Tabla 7.2 contiene los datos de 10 corridas independientes de simulación. Y luego es calculada una estimación puntual para el número promedio de partes observadas en la antesala de espera de una cola.

Suponga que deseamos determinar el número necesario de replicaciones del modelo para estar 95 por ciento “confiantes” de que nuestra estimación puntual de la longitud promedio de partes en la cola no varíe de la verdadera media en mas de una parte (**e=1**). A continuación de la tabla 7.2 se muestra como esto es calculado, donde la ecuación anteriormente presentada es aplicada y los resultados indican que un total de 29 replicaciones se requieren para obtener la exactitud especificada.

iésima replicación	Número promedio de partes observadas en la antesala de la cola	$[x_i - \bar{x}(10)]^2$
1	1.96	10.16334
2	8.66	12.33414
3	6.37	1.49328
4	2.12	9.16878
5	5.16	0.00014
6	5.63	0.23232
7	2.2	8.6907
8	5.67	0.27248
9	8.01	8.19104
10	5.7	0.3047
total=51.48		total= 50.85

Tabla 7.2. Para estimaciones puntuales de μ y σ^2

$$\bar{x}(10) = 51.48 / 10 = 5.148$$

$$s^2(10) = 50.85 / 9 = 5.65$$

$$\text{Estimación de } \sigma \approx s(10) = \sqrt{5.65} = 2.38$$

$$N = \left[\frac{(2.262)(2.38)}{1} \right]^2 = 28.9$$

$$t_{9,0.9750} = 2.262$$

Los resultados pueden ser interpretados como sigue: “Si el anterior experimento se repite 100 veces, entonces podemos esperar que 95 de los experimentos producirán una estimación de la longitud promedio de la cola de partes que no difiere de la verdadera media en más de una parte”. Darse cuenta que un experimento consiste en **hacer 29 replicaciones** del modelo **para calcular una sola** estimación puntual para la longitud promedio de partes en la cola.

7.5 Inferencia Estadística

Una inferencia esta definida como el proceso de llegar a una conclusión, la cual, aunque no es lógicamente derivable a partir de las premisas asumidas, posee algún grado de probabilidad con respecto a las premisas. “La teoría de la inferencia estadística puede ser definida como aquellos métodos mediante los cuales se hacen inferencias o generalizaciones acerca de la población” [Walpole and Meyers (1978)]. Los principios de la inferencia estadística son usados para analizar los datos de salida creados por los modelos de simulación estocástica.

Hay dos grande áreas de inferencia estadística: 1) Una es la **estimación** y la otra 2) es la **prueba de hipótesis**. La estimación involucra el establecimiento de un grado de exactitud asociado con un estimador puntual. Por ejemplo, cual es la diferencia entre μ (la verdadera media teórica) y $\bar{x}$ (una estimación puntual de la verdadera media de la distribución).

La prueba de hipótesis tiene que ver con tratar de tomar una decisión correcta con referencia a una suposición preestablecida. El análisis estadístico provee información para aceptar o rechazar una hipótesis. La prueba Chi-cuadrado descrita antes en la unidad V es un ejemplo. Allí, se hipotetizó, una distribución exponencial como la mejor representación de una distribución empírica y la evidencia estadística soportó esa hipótesis.

7.5.1 Teorema Central del Límite

El teorema central del límite juega un importante papel en la inferencia estadística. Se define como sigue: “La función de distribución de las medias aritméticas de un número grande de mediciones aleatorias independientes (en muestreo repetitivo) tienden a poseer una distribución aproximadamente normal”.

Asuma que la verdadera media de una distribución es μ y su varianza es σ^2 . Suponga que realizamos miles de estimaciones de μ , y **para cada** estimación calculamos un valor para C_n , el cual se define como:

$$C_n = \frac{(\bar{x}(n) - \mu)}{\sqrt{\sigma^2/n}}$$

El teorema central de límite nos dice que los valores derivados de C_n , estarán distribuidos como una distribución normal, cuando el tamaño de la muestra, n , es grande.

Este teorema se aplica para analizar los resultados de la simulación. Una respuesta de desempeño producida a partir de una sola replicación de una simulación estocástica puede ser considerada como una muestra simple de la distribución de todas las posibles respuestas. Cada replicación independiente del modelo (replicación realizada con un flujo único de números aleatorios) hecha posteriormente produce otra muestra de la distribución de las respuestas.

No conocemos la distribución de probabilidad que representa todas las posibles salidas. Sin embargo, podemos hacer estimaciones de la verdadera μ de la distribución tomando muestras aleatorias (respuestas producidas por replicaciones independientes del modelo) de la distribución. El Teorema Central de Límite nos dice que cuando nuestro tamaño de muestra n es grande, $\bar{x}(n)$, será una variable aleatoria normalmente distribuida con una media μ (la media teórica verdadera de la distribución de todas las posibles salidas). Con esta información, podemos usar una función de densidad normal de probabilidad standard para definir los intervalos de confianza para la estimación puntual de μ .

El valor de α determina el nivel de confianza. Un valor de $\alpha = 0.10$ significa un chance del 10% de que el intervalo calculado no contendrá la verdadera media, μ , de la población.

La ecuación para derivar el intervalo de confianza es como sigue:

$$\bar{x}(n) \pm t_{n-1, 1-\alpha/2} \sqrt{\frac{s^2(n)}{n}}; \quad t_{n-1, 1-\alpha/2} \text{ es un valor de la distribución t, con } n-1 \text{ grados de libertad y } 100(1-\alpha) \text{ por ciento de confianza.}$$

A continuación de la siguiente Tabla 7.3, se aplica esta ecuación a los datos de la longitud promedio de una cola. El intervalo de confianza resultante del 90% para la longitud media de la cola (numero **promedio de partes** en la cola) es: $(3.77 \leq \mu \leq 6.53)$. Lo que nos dice que podemos estar 90% seguros de que el ver-

El verdadero valor medio está contenido dentro del intervalo [8.5, 6.53]. El intervalo de confianza para el **número máximo de entidades** observadas en la cola es de [8.5, 13.5] donde $\bar{x}(10) = 11$ y $s^2(10) = 19.33$.

i-ésima replicación	Semilla de número aleatorio para la i-ésima replicación de la distribución del tiempo de llegada de las partes	Semilla de número aleatorio para la i-ésima replicación de la distribución del tiempo de ciclo de la máquina	Número promedio observado de partes en el "buffer" de entrada a la cola [3.77 , 6.53]	Máximo número de partes observadas en el "buffer" de entrada a la cola [8.5 , 13.5]
1	597608073	1508045409	1.96	4
2	1973272912	877722890	8.66	17
3	119025595	2079249579	6.37	14
4	264907697	498067494	2.12	6
5	1494667770	1004818771	5.16	11
6	927711160	2049576050	5.63	15
7	493157915	403188473	2.2	6
8	1433700034	1244184613	5.67	13
9	1663153658	855503735	8.01	14
10	1911216000	2122378830	5.7	10

Tabla 7.3 Datos de Salida de un Modelo de Simulación Terminante

Estimador puntual de la media μ es: $\bar{x}(n) = \frac{\sum_{i=1}^n x_i}{n}$

Estimador puntual insesgado de la varianza σ^2 es: $s_2^2(n) = \frac{\sum_{i=1}^n (x_i - \bar{x}(n))^2}{n-1}$

El valor de la distribución t para un nivel de confianza del 90% con 9 grados de libertad (10 repeticiones menos 1) es $t_{9,0.05} = 1.833$.

El intervalo de confianza del 90% para el promedio de partes en la cola es como sigue:

$$5.148 - 1.833(0.752) \leq \mu \leq 5.148 + 1.833(0.752)$$

$$3.77 \leq \mu \leq 6.53$$

Cualquiera de los intervalos de confianza mencionados arriba puede ser interpretado como sigue. Si 100 intervalos de confianza son construidos de la manera

descrita anteriormente (diez replicaciones independientes del modelo para producir un intervalo) podemos esperar que 90% de los intervalos contendrán el verdadero parámetro. El intervalo construido en el ejemplo presentado es solamente uno de cualquiera de esos 100 intervalos de confianza.

Intervalos de confianza en simulaciones de Estado Estable

Los intervalos de confianza para las simulaciones de Estado Estable pueden ser producidos de igual manera. En una simulación de Estado Estable, la salida generada a partir de una simple replicación del modelo consiste de valores de respuesta seleccionados, observados sobre períodos de tiempo repetitivos. Una respuesta promedio general para cada replicación debe primero ser determinada para poder establecer un valor para $\bar{x}(n)$. Esto se logra sumando todas las respuestas que ocurren en una replicación que comienza en el período **p+1** (**p** es el período de calentamiento- *warm-up period*) y termina en el período **m** (el número total de períodos en una replicación). El resultado es luego dividido por el número total de períodos (**m-p**) para obtener la respuesta promedio por cada replicación del modelo. La ecuación matemática para realizar esto puede ser descrita como sigue:

$$\bar{Y}_i(m, p) = \frac{\sum_{j=p+1}^m Y_{ij}}{m - p}$$

m representa el número total de períodos en una replicación del modelo
p es la longitud del período de calentamiento.

$\bar{Y}_i(m, p)$ es la respuesta promedio en la i-ésima replicación del modelo, del período **p+1** al **m**.

Los cálculos que siguen a la Tabla 7.4 son los datos mensuales del costo de trabajos en proceso obtenidos en $i=5$ replicaciones, y utilizan la ecuación arriba presentada para calcular un intervalo de confianza. Los datos del período 13 al 39 son usados en los cálculos dado que un intervalo de $p=12$ períodos fue escogido como calentamiento.

Las respuestas promedio, $\bar{Y}_i(m, p)$, para cada replicación del modelo son mostradas debajo de la columna correspondiente.

Considerando solo el los períodos del estado estable del sistema, la estimación

puntual, para la respuesta media, $\bar{X}(n) = \sum_{i=1}^n \frac{\bar{Y}_i(m, p)}{n} = \frac{\sum_{j=p+1}^m Y_{ij}}{n(m-p)}$ del costo mensual del trabajo en proceso (WIP) es de \$556,520 (donde **n** es el número de replicaciones). Y un intervalo de confianza del 95% sería [\$400,646 a \$712,392].

Veamos las formulas de cálculo:

1. Estimación puntual de la media del Estado Estable teniendo en consideración todas las replicaciones del modelo.

$$\bar{X}(n) = \sum_{i=1}^n \frac{\bar{Y}_i(m, p)}{n}$$

$$\bar{X}(5) = 556.52$$

2. Estimación puntual de la varianza para todas las replicaciones del modelo.

$$s^2(n) = \sum_{i=1}^n \frac{[\bar{Y}_i(m, p) - \bar{X}(n)]^2}{n-1}$$

$$s^2(5) = 15752.76$$

<i>i</i> th Period	Y_{ij} Observed Cost during <i>i</i> th Period and <i>j</i> th Replication (in thousands of dollars)				
Period	Rep 1	Rep 2	Rep 3	Rep 4	Rep 5
13	376.81	500.97	192.96	509.00	636.92
14	352.05	329.30	587.45	336.11	530.74
15	518.96	634.81	716.81	533.05	1899.13
16	673.88	853.97	563.86	179.72	864.17
17	376.99	1098.67	290.92	205.43	276.93
18	139.26	339.08	563.49	319.10	189.20
19	199.54	4032.35	355.94	138.88	215.99
20	542.79	908.48	633.90	349.55	727.93
21	383.47	317.29	165.11	345.11	106.20
22	276.26	387.05	336.19	789.89	613.58
23	336.39	388.63	605.87	315.20	818.90
24	562.06	323.83	1311.94	339.76	312.95
25	931.46	236.80	706.43	484.30	658.11
26	182.82	352.79	991.44	271.73	1815.32
27	589.21	649.52	544.64	296.36	289.96
28	103.42	936.04	393.21	771.45	151.18
29	219.14	1338.29	163.15	169.59	938.19
30	169.36	841.89	651.41	492.09	232.72
31	791.25	137.11	734.38	807.81	401.16
32	1360.99	274.57	457.19	148.87	231.46
33	530.04	1259.50	497.51	1300.90	990.27
34	198.498	275.20	177.60	723.29	414.02
35	523.28	1012.45	904.77	212.75	523.06
36	633.30	723.07	431.72	245.69	158.22
37	631.47	455.12	1256.28	287.57	351.78
38	807.24	1627.84	994.93	215.50	603.36
39	271.41	138.54	352.43	441.73	352.38

$$\bar{Y}_i(m, p) = \frac{\sum_{j=p+1}^m Y_{ij}}{m-p} = \begin{matrix} \downarrow & \downarrow & \downarrow & \downarrow & \downarrow \\ 469.70 & 752.74 & 565.96 & 427.05 & 567.14 \end{matrix}$$

Tabla 7.4. Datos mensuales del costo de trabajos en proceso para la determinación de un intervalo de confianza para una respuesta media de un Estado Estable.

3. Selección de un nivel de confianza y del valor correspondiente de la distribución

t. $t_{4,0.975} = 2.776$

4. Cálculo del intervalo de confianza

$$\begin{aligned} \bar{X}(5) \pm t_{4,0.975} \sqrt{\frac{s^2(5)}{n}} \\ 556.52 \pm 2.776 * 56.129 = \\ [400.646, 712.392] \end{aligned}$$

Nota: En la **práctica #11**- “Número de Corridas y Período de Calentamiento”- del modulo de prácticas se implementa este enfoque para calcular el intervalo de confianza de una simulación de Estado Estable. El otro enfoque conocido como intervalos de lote (“batch intervals”) es discutido y presentado en la **práctica #12** – “Replicaciones o intervalos de loteo”- del mismo modulo de prácticas.

7.5.2 Comparando y Evaluando Alternativas

El análisis de la simulación con frecuencia envuelve la comparación de dos alternativas, tales como dos configuraciones de diseño que compiten, o dos posibles niveles de recursos. El objetivo es determinar 1) si una de las configuraciones es mejor que la otra con respecto a un criterio de desempeño seleccionado y 2) si una es superior a la otra, que tanto mejor es. Hay dos pruebas estadísticas que ayudan a responder a ésta pregunta, el **Test t Apareado** (Prueba para Diferencias apareadas) y el **Test para Dos Muestras** (Prueba para la diferencia entre dos medias). Ambos se enfocan a hacer estimaciones puntuales de la diferencia promedio entre las respuestas promedio para ambas configuraciones.

Test t Apareado

El **Test t Apareado** requiere que el número de replicaciones del modelo realizadas para cada configuración sea **igual**. Es también empleado cuando **flujos comunes** de números aleatorios son usados en las respectivas replicaciones de los modelos. La ecuación para calcular el intervalo de confianza bajo estas condiciones es como sigue:

$$\begin{aligned} \bar{d} - t_{n-1, 1-\alpha/2} \frac{s_d}{\sqrt{n}} \leq \mu_d \leq \bar{d} + t_{n-1, 1-\alpha/2} \frac{s_d}{\sqrt{n}} \\ s_d = \sqrt{s_d^2} \\ s_d^2 = \frac{n \sum d_i^2 - (\sum d_i)^2}{n(n-1)} \end{aligned}$$

n representa el número de observaciones apareadas (replicaciones del modelo)

d_i es la diferencia entre X_{1i} y X_{2i} en la i -ésima replicación del modelo (X_{1i} representa la respuesta observada para la configuración de diseño 1 en la i -ésima replicación del modelo).

$\bar{d}$ es un estimador puntual de la diferencia media entre todas las observaciones apareadas. Es calculado sumando las diferencias entre X_{1i} y X_{2i} , y dividiendo la suma por el número total de replicaciones del modelo.

$t_{n-1, 1-\alpha/2}$ es un valor de la **distribución t** con **$n-1$** grados de libertad.

s_d^2 es la varianza estimada de las diferencias.

Suponga que *simulaciones terminantes* están siendo usadas para analizar la utilización de trabajo para dos alternativas. Llamemos las dos alternativas como Método #1 y Método #2. Para cada alternativa son realizadas diez (10) replicaciones del modelo. Un flujo común de números aleatorios es usado para cada conjunto de replicaciones. La Tabla 7.5, siguiente, contiene los datos generados sobre la utilización de trabajo por cada replicación del modelo (expresada como porcentaje del tiempo total de trabajo).

Tabla 7.5

Observaciones aparejadas	utilización del trabajo (%) en la i-ésima replicación para Método #1	utilización del trabajo (%) en la i-ésima replicación para Metodo #2	Diferencia entre métodos #1 y #2 en la i- ésima replicación	Cuadrado de la diferencia en la i-ésima replicación
Replicación i				2
1	75	67	8	64
2	76	85	-9	81
3	73	68	5	25
4	74	62	12	144
5	76	71	5	25
6	91	87	4	16
7	55	63	-8	64
8	67	55	12	144
9	85	90	-5	25
10	89	85	4	16
	804			
			$\sum d_i = 28$	$\sum d_i^2 = 604$

Un intervalo de confianza para la diferencia en la utilización de trabajo para los dos métodos es **[-1.63, 7.23]**. En otras palabras, podemos tener una confianza del 90%, de que la verdadera diferencia entre la utilización de trabajo, entre los Método #1 y Método #2 esta dentro del intervalo que va de -1.63 a 7.23

$$s_d^2 = \frac{n \sum d_i^2 - (\sum d_i)^2}{n(n-1)}$$

$$\bar{d}_i = \frac{28}{10} = 2.8; s_d^2 = \frac{10(604) - (28)^2}{10(9)}; t_{9,0.95} = 1.833$$

$$\bar{d} - t_{n-1,1-\alpha/2} \frac{s_d}{\sqrt{n}} \leq \mu_d \leq \bar{d} + t_{n-1,1-\alpha/2} \frac{s_d}{\sqrt{n}}$$

$$2.8 - 1.833 \frac{7.64}{\sqrt{10}} \leq \mu_d \leq 2.8 + 1.833 \frac{7.64}{\sqrt{10}}$$

$$-1.632 \leq \mu_d \leq 7.23$$

Tabla 7.6. Intervalo de confianza para estimar la diferencia entre dos medias usando el Test t Apareado.

Para éste ejemplo, la verdadera diferencia tiene la posibilidad de ser igual a cero (0). Un valor igual a 0 implica que no hay diferencia entre los Método #1 y Método #2 . Por lo tanto, no podemos concluir que uno sea superior al otro en términos de utilización de trabajo.

TEST “ T “ NO APAREADO

El **Test para Dos Muestras** es otro método para probar la diferencia entre dos medias. Es empleado cuando una o ambas de las siguientes condiciones existe: **1)** el número de replicaciones del modelo para las dos alternativas siendo comparadas no es igual, y **2)** no se está usando un flujo común de números aleatorios cuando se simulan ambas alternativas. La ecuación para construir un intervalo de confianza para este *test* es como sigue:

$$(\bar{x}_1 - \bar{x}_2) - t_{n,1-\alpha/2} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \leq \mu_1 - \mu_2 \leq (\bar{x}_1 - \bar{x}_2) + t_{n,1-\alpha/2} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Donde:

n_1 , y n_2 es el número de replicaciones del modelo en las respectivas alternativas #1 y #2.

x_{1i} y x_{2i} son las respectivas respuestas de la i-ésima replicación (la primera, x_{1i} representa la respuesta observada para la configuración de diseño #1 en la i-ésima replicación del modelo).

s_1^2 y s_2^2 son las estimaciones de las varianzas para las respuestas respectivas de las configuraciones #1 y #2.

$t_{n-1,1-\frac{\alpha}{2}}$ es el valor de una distribución t con un nivel de confianza $(1-\alpha)$ y n grados de libertad, donde los grados de libertad , n , se estima como sigue:

$$n \approx \frac{\left(s_1^2/n_1 + s_2^2/n_2 \right)^2}{\frac{\left(s_1^2/n_1 \right)^2}{n_1 - 1} + \frac{\left(s_2^2/n_2 \right)^2}{n_2 - 1}}$$

Suponga que en el ejemplo anterior son realizadas 15 replicas del modelo para una tercera alternativa (un Método #3, y que no es usado un flujo común de números aleatorios para ambas alternativas).

La siguiente Tabla 7.7, muestra los datos de la utilización de trabajo para éste escenario. El intervalo de confianza para la diferencia de utilización de trabajo entre método #1 y método #3 es: [-12.25, -5.41].

Tabla 7.7. Datos para la prueba de estimación de la diferencia entre dos medias

Método #1 (%) de Utilización por el método #1 para cada replicación i-ésima de las simulación				Método #3 (%) de Utilización por el método #3 para cada replicación i-ésima de las simulación		
	x_{1i}	$x_{1i} - \bar{x}_1$	$(x_{1i} - \bar{x}_1)^2$	x_{2i}	$x_{2i} - \bar{x}_2$	$(x_{2i} - \bar{x}_2)^2$
1	77	-3,7	13,69	89	-0,53	0,28
2	82	1,3	1,69	91	1,47	2,16
3	89	8,3	68,89	91	1,47	2,16
4	76	-4,7	22,09	88	-1,53	2,34
5	86	5,3	28,09	88	-1,53	2,34
6	76	-4,7	22,09	87	-2,53	6,4
7	77	-3,7	13,69	88	-1,53	2,34
8	84	3,3	10,89	89	-0,53	0,28
9	88	7,3	53,29	90	-0,47	0,22
10	72	-8,7	75,69	91	1,47	2,16
12				90	0,47	0,22
13				91	1,47	2,16
14				89	-0,53	0,28
15				91	1,47	2,16
				90	0,47	0,22
	$\sum x_1 = 807$		$\sum (x_{1i} - \bar{x}_1)^2 = 310.1$	$\sum x_2 = 1343$		$\sum (x_{2i} - \bar{x}_2)^2 = 25.72$

$$\begin{aligned}
 1. \bar{x}(n) &= \frac{\sum_{i=1}^n x_i}{n}; \quad 2. s_2^2(n) = \frac{\sum_{i=1}^n (x_i - \bar{x}(n))^2}{n-1}; \quad 3. t_{n-1, 1-\frac{\alpha}{2}}; \\
 4. n &\approx \frac{\left(s_1^2/n_1 + s_2^2/n_2 \right)^2}{\frac{\left(s_1^2/n_1 \right)^2}{n_1-1} + \frac{\left(s_2^2/n_2 \right)^2}{n_2-1}} \\
 \bar{x}_1 &= \frac{807}{10}; \quad \bar{x}_2 = \frac{1343}{15}; \quad s_1^2 = \frac{310.1}{9}; \quad s_2^2 = \frac{25.72}{14}; \quad n \approx \frac{\left(34.45/10 + 1.837/15 \right)^2}{\frac{\left(34.45/10 \right)^2}{9} + \frac{\left(1.837/15 \right)^2}{14}} \\
 (\bar{x}_1 - \bar{x}_2) - t_{n, 1-\alpha/2} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} &\leq \mu_1 - \mu_2 \leq (\bar{x}_1 - \bar{x}_2) + t_{n, 1-\alpha/2} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} \\
 -8.83 - 1.81 \sqrt{\frac{34.45}{10} + \frac{1.837}{15}} &\leq \mu_1 - \mu_2 \leq -8.83 + 1.81 \sqrt{\frac{34.45}{10} + \frac{1.837}{15}} \\
 -12.25 &\leq \mu_1 - \mu_2 \leq -5.41
 \end{aligned}$$

7.5.3 Técnicas para la Reducción de Varianza

Dado que realizar el análisis estadístico de muchas replicaciones de uno o más modelos puede llegar a ser tedioso y costoso, deben hacerse esfuerzos para incrementar la precisión de las salidas sin sesgar los resultados. La reducción de las varianzas de las salidas resultará en intervalos de confianza más ajustados para el mismo número de replicaciones o, alternativamente, menor número de replicaciones para alcanzar una amplitud deseada del intervalo. Aunque éstas técnicas no son presentadas con profundidad aquí, el modelador de simulaciones debe entender su propósito y considerar en usarlas para ahorrarse tiempo y costos cuando va a generarse gran cantidad de datos para el análisis. Una completa explicación de varias técnicas de éste tipo se puede encontrar en [Law and Kelton] libro citado en la bibliografía (Ver su Capítulo 11, Variante Reduction Techniques, pag. 581 a 616).

La técnica mas ampliamente usada como método para la reducción de la varianza para un solo sistema es probablemente el de las variables antitéticas. Esta técnica usa números aleatorios complementarios para generar un par de corridas del modelo, una usando un valor aleatorio x , y la otra utilizando el valor aleatorio $1-x$. Teóricamente una de las corridas retornará un resultado con “altos” valores y la otra proveerá valores bajos. El promedio es luego usado como dato. Es importante darse cuenta que cada valor del par debe ser usado para la misma función en el mismo instante de tiempo dentro de su respectiva corrida del modelo.

Cuando se comparan dos sistemas, una técnica bastante útil es la de **Números Aleatorios Comunes**. Esto implica comparar las alternativas bajo las mismas condiciones. Una de las posibles condiciones experimentales que podemos hacer comunes a varias alternativas es la selección del flujo de números aleatorios. Si ambas alternativas están usando los mismos valores aleatorios, podemos tener mas seguridad de que las diferencias en los resultados estén realmente relacionadas con las reales diferencias en el desempeño de los sistemas, y no en “la suerte” de uno de los sistemas haber tenido un flujo de valores aleatorios que le sea favorable.

Es claro, que debemos sincronizar los flujos, de tal manera que el mismo valor sea usado para exactamente el mismo propósito en cada una de las dos corridas que están siendo comparadas. Típicamente esto se logra asignando un único flujo (usando una misma semilla) a cada evento en el modelo que requiera un valor aleatorio. Este flujo común, es posteriormente asignado con el mismo propósito en la simulación del sistema alternativo.

7.5.4 Administrando las Replicaciones de Modelo y las Salidas

Las ecuaciones matemática usadas en el análisis estadístico descrito previamente puede parecer intimidatorio a aquellos no familiarizados con la notación estadística. En realidad, la matemática allí empleada es realmente sencilla. Sin embargo, la realización de los cálculos manualmente puede ser una tarea muy tediosa (la computadora hace los cálculos mucho mas rápido y de manera mas eficiente).

El paquete ProModel incluye una característica llamada “Resumen de Replicaciones Múltiples” (*Multiple Replication Summary*), que automáticamente realiza el análisis estadístico básico sobre las salidas replicadas de la simulación, incluyendo la generación de estimaciones puntuales y el cálculo de intervalos de confianza. Esto simplifica el trabajo, tanto del modelador como del tomador de decisiones, quien usará los resultados del estudio de simulación.

Sin embargo, la comprensión de las diferentes técnicas de análisis estadístico y su propósito es aún requerida para poder hacer uso efectivo de la simulación.

UNIDAD VIII

8.1 TERMINOLOGÍA DE SIMULACIÓN *(Traducido de Bateman)*

El arte y la ciencia de la simulación tienen un único vocabulario de términos que ayudan a los simulacionistas a comunicar conceptos específicos. Aunque no todo está, la siguiente lista contiene las palabras y los conceptos clave que cada modelador debería conocer.

8.1.1 Sistema y Estado del Sistema

Un **sistema**, como se definió antes, es un grupo organizado de entes tales como gente, equipo, métodos y partes que trabajan juntos hacia un objetivo específico. Un modelo de simulación caracteriza a un sistema por la descripción matemática de las respuestas que pueden resultar de la interacción de las entidades.

Un **estado del sistema** es el conjunto de variables, estocásticas (pueden cambiar aleatoriamente) y determinísticas (no influenciadas por la probabilidad), que contienen toda la información necesaria para describir un sistema en cualquier punto del tiempo. [Smith 1989]

8.1.2 Modelos de Eventos Discretos y Continuos

Como se presentó en la unidad anterior, un **evento discreto** es una acción instantánea que ocurre en un punto único en el tiempo. El aterrizaje de un aeroplano en un aeropuerto, la llegada de una parte a una bodega, la entrada de un cliente a un banco y la finalización del tiempo de ciclo de una máquina son ejemplos de eventos discretos. La ocurrencia de estos eventos puede causar que el estado del sistema cambie.

En la simulación de modelos de eventos discretos el computador mantiene un instrumento de tiempo conocido como el **reloj de simulación** que avanza a medida que cada evento toma lugar en un punto fijo en el tiempo. Si un evento representa la iniciación de una actividad que concluirá en el futuro, la simulación agregará el tiempo de finalización a la lista de eventos futuros y avanzará el reloj al siguiente tiempo en que debe ocurrir otro evento.

Un **evento continuo** es una acción que no termina. Esta acción continúa ininterrumpida con respecto al tiempo. La temperatura del agua en un lago subiendo y bajando durante el día, el flujo de aceite dentro de un tanque y varias conversio-

nes químicas son ejemplos simples. Los eventos continuos involucran tasas de cambio en el tiempo, a menudo representadas por ecuaciones diferenciales.

La simulación continua permite a las variables del modelo cambiar continuamente en el tiempo, con una rata definida de cambio ligada al reloj de simulación. Debido a que muchos procesos continuos pueden ser aproximados muy cercanamente dividiendo grandes lotes en elementos menores, se pueden emplear métodos de modelación de eventos discretos para muchos (ciertamente no todos) estudios de simulación de procesos continuos.

8.1.3 Modelos Estáticos y Dinámicos

Un **modelo estático** es aquel que no es influenciado por el tiempo. No hay involucrado ningún reloj de simulación. Los segundos, las horas o los días no juegan ningún papel en el modelo. El estado de un modelo no cambia con respecto al tiempo. Un modelo de simulación que imite el lanzamiento de un dado es un ejemplo. La salida del modelo (1,2,3,4,5 o 6) no es afectada por el tiempo.

Un **modelo dinámico** es una representación que está influenciada por el tiempo. El estado del modelo evoluciona sobre segundos, horas días y meses simulados en el reloj de simulación. Los procesos de manufactura y muchos sistemas de servicio se modelan generalmente utilizando una aproximación dinámica. Niveles en las colas, tasas de llegada y utilización del equipo son ejemplos de variables dinámicas.

8.1.4 Modelos de Ciclo Abierto y Ciclo Cerrado

Una simulación en la cual la salida abandona el sistema sin suministrar ninguna retroalimentación al sistema se llama un **modelo de ciclo abierto**.

Si, por otro lado, los resultados de la operación del sistema son devueltos a la simulación por la modificación de operaciones sucesivas, el modelo será de la variedad de **ciclo cerrado**.


La retroalimentación en un modelo de ciclo cerrado puede hacer impacto nada más que en decisiones menores de enrutamiento o pueden crear cambios lógicos significativos en la operación del sistema completo.

8.1.5 Simulaciones de Estado Estable y Terminantes

Una **simulación de estado estable** implica que el sistema es independiente de sus condiciones iniciales de arranque. El análisis de estos modelos se basa en los datos de salida generados después de que se han alcanzado las condiciones de estado estable. El promedio acumulado de múltiples lanzamientos de un dado puede ser utilizado para demostrar este principio. Después de un cierto número

de lanzamientos, el promedio acumulado de todos los lanzamientos permanecerá aproximadamente en 3.5. El punto en el cual esto ocurre ejemplifica una condición de estado estable. Este concepto es ilustrado en la gráfica 4A. Allí se muestra el promedio acumulado de 1000 lanzamientos de un dado. Una condición de estado estable para el valor promedio del lanzamiento del dado ocurre aproximadamente después del lanzamiento número 500.

Una simulación terminante corre para una longitud predeterminada de tiempo o hasta que ocurra algún evento específico. El análisis y las conclusiones se basan en los valores de salida producidos en el punto de parada. Los resultados de las simulaciones terminantes usualmente son dependientes de los valores y cantidades iniciales usadas al comienzo del modelo. Por esta razón, las condiciones de arranque en los modelos terminantes deberían reflejar muy precisamente las circunstancias de arranque exhibidas en el sistema del mundo real bajo estudio.



La decisión de emplear simulación de estado estable o terminante se hace durante las etapas preliminares de planeación del proyecto de simulación. La escogencia es dependiente del tipo de sistema que se esté modelando. Una facilidad que opera 24 horas diarias sería mejor analizada con una simulación de estado estable. Para otros tipos de sistemas, esto puede no ser aplicable.

Muchos sistemas del mundo real pueden no llegar nunca a una condición de estado estable. Considere un sistema de almacenaje y entrega automatizado que consiste en seis carruseles que funcionan independientemente. Los carruseles contienen recipientes de carga que almacenan partes para un proceso de producción. Cada carrusel está sujeto a requisiciones aleatorias de almacenaje y entrega durante las horas de producción. Todos los recipientes de carga se devuelven al carrusel al final de cada turno de producción, en tal forma que cada carrusel comienza un nuevo turno con cero requisiciones pendientes.

Supongamos que el objetivo de un estudio de simulación es el de determinar el promedio de tiempo gastado por una orden de requisición experimentado en un carrusel durante un solo turno de producción. (Note que muchos sistemas terminantes, tales como bancos y fábricas, pueden ser modelados y simulados como sistemas no-terminantes asumiendo que las condiciones finales de un día o de un turno representan las condiciones de comienzo del siguiente día o turno). Condiciones de estado estable para longitudes de colas de órdenes pueden no ocurrir durante esta duración de tiempo. Dadas estas circunstancias, una simulación terminante probablemente sería usada para analizar el sistema.

8.1.6 Período de Calentamiento

Un **período de calentamiento** es la cantidad de tiempo que un modelo necesita correr para eliminar el sesgo de iniciación antes de que comience la recolección de datos estadísticos. La longitud del período es dependiente del tipo de modelo que está siendo usado.

Períodos de calentamiento para simulaciones de estado estable pueden ser encontrados a través de la experimentación con promedios móviles y otras técnicas. Un modelo terminante puede usar un período de calentamiento igual al tiempo requerido para que el modelo alcance un estado del sistema equivalente a condiciones de arranque predeterminadas. Estas condiciones de arranque representan el estado inicial del sistema que está siendo estudiado (por ejemplo, la máquina A comienza la simulación con 10 partes haciendo cola frente a ella, la máquina B con 30, y así sucesivamente).

8.1.7 Flujos y Semillas de Números Aleatorios

Un **flujo de números aleatorios** es una secuencia de números aleatorios en el cual cada número que aparece en el flujo se calcula a partir del valor previo derivado. El número inicial se conoce como la **semilla de números aleatorios** y determina el punto de comienzo del generador de números aleatorios en su algoritmo. Números aleatorios con valores entre cero y uno juegan un papel muy impor-

tante en la extracción de valores desde distribuciones de probabilidad utilizadas para generar comportamiento estocástico en la simulación.

8.1.8 Corridas del Modelo y Replicaciones Independientes del Modelo

Una **corrida de un modelo** involucra la operación de una simulación por un período de tiempo con un conjunto único de valores aleatorios. La longitud de una corrida de simulación es la cantidad de tiempo simulado durante la corrida de simulación. Una corrida de simulación muy corta puede generar estadísticas sesgadas, mientras que una corrida demasiado larga malgastará tiempo de computador.

Una **replicación independiente del modelo** (o simplemente una “replicación”) vincula la operación del mismo modelo por el mismo período de tiempo con uno o más valores diferentes de semillas aleatorias. Las replicaciones múltiples del modelo son esenciales cuando se analizan los resultados de simulaciones terminantes y son frecuentemente usadas también en simulaciones de estado estable. Es vital comprender lo siguiente: Los resultados de una sola replicación del modelo de una simulación estocástica en sí mismos son estocásticos. El siguiente ejemplo puede ilustrar este punto. Imagine una bolsa que contiene cien bolas de ping pong, cada una marcada con un número diferente. Suponga que alguien extrae la bola marcada con el número 35. Obviamente nosotros no podemos concluir que todas las bolas en la bolsa están marcadas con el número 35. Los resultados de una replicación independiente del modelo son representativos de una sola bola de ping pong dentro de la bolsa.

UNIDAD IX

APÉNDICE

9.1 SOBRE EL CONCEPTO Y LA DEFINICIÓN DE SISTEMAS

Notas de la Profesión

Por:
EDUARDO ZULUAGA RUIZ
Director Ingeniería de Sistemas
Universidad EAFIT

1. Introducción.

Pocas palabras más utilizadas en nuestro lenguaje actual que la palabra sistema. El vocablo ha traspasado los linderos académicos y penetra el lenguaje cotidiano. En todo arte u oficio encuentra uno su presencia, el mecánico repara el sistema de frenos, los sistemas audiovisuales implantan novedosos sistemas de enseñanza, los sistemas de créditos permiten nuevos sistemas de ventas, nuestro sistema de gobierno garantiza el sistema democrático, los sistemas de comunicación aturden nuestro sistema nervioso, y ni aún los maravillosos sistemas de computación actual terminarían de listar los innumerables sistemas reales y posibles que constituyen y rodean nuestra existencia.

El uso indiscriminado de la palabra sistema no ha contribuido a clarificar su significado. Se ha intentado y se intenta renovar el significado de conceptos tradicionales anteponiéndoles la palabra sistema. La administración se torna en los Sistemas Administrativos, la contabilidad en Sistemas Contables, nuestras costumbres pasan a ser el Sistema de Vida y hasta el simple alquiler de autos se convierte en el Sistema de Alquiler de Autos.

¿Qué exactamente entendemos por Sistema? ¿Cuál es su significado preciso?
¿Cuál su definición?

Se impone una explicación o definición del concepto de Sistema.

2. Definición de Sistema.

La definición tradicional de conceptos encierra una engañosa claridad lógica. Una palabra o concepto debe ser definido por medio de otras palabras dentro de las cuales no debe incluirse el término definido.

Si fuésemos rigurosos, lógicamente tendríamos que definir cada una de las palabras usadas en la definición del concepto original. La aplicación de la exigencia anterior nos conduciría a un proceso recursivo lingüístico cuyo criterio de terminación sería la suposición de un subconjunto limitado de palabras cuyo significado asumimos conocido y aceptado por todos. Un subconjunto equivalente a los axiomas de la geometría tradicional. La peculiar definición de axioma: "Una verdad evidente por sí misma que no requiere demostración", contradice abiertamente la marcada preocupación de demostraciones y pruebas de la geometría. Análogamente en nuestro caso caeríamos en un subconjunto de palabras evidentes por sí mismas que no requieren definición.

No en vano afirma Ferdinand de Saussure en su Curso de Lingüística General:

"... Toda definición hecha a base de una palabra es vana; es mal método el partir de las palabras para definir las cosas".

Despreciando un tanto los rigores lógicos y desde un punto de vista práctico, propio de la ingeniería, presentamos varias definiciones de Sistema que ayuden a dilucidar su significado:

1. Conjunto de elementos interactuantes.
2. Agrupamiento de partes que operan conjuntamente.
3. Ensamblaje de componentes que ordenadamente relacionados contribuyen a un objetivo determinado.
4. Conjunto de partes coordinadas para lograr un conjunto de metas.
5. Integración de un conjunto de elementos en busca de un conjunto de objetivos.
6. Una parte del Universo real posible.

En las definiciones anteriores hemos usado adrede palabras sinónimas equivalentes que buscan clarificar la definición. Podemos agrupar las definiciones en varios subgrupos, el subgrupo A que comprende las definiciones 1 y 2; el subgrupo B que consta de las definiciones 3, 4 y 5 y el subgrupo C, definición 6.

Las definiciones del grupo A son equivalentes, y resaltan dos características importantes:

- Identificación de partes, elementos o subsistemas en el sistema. No es el sistema una sola unidad indivisible sino un conjunto de elementos.
- Interacción u operación conjunta que implica relación o interacción entre los elementos o partes del sistema.

Las definiciones agrupadas en B resaltan, adicionalmente a las características señaladas por las definiciones del grupo A, la presencia de un conjunto de objetivos que justifican o requieren las interacciones de los elementos.

La inclusión de objetivos en la definición de sistema ha sido cuestionada por varios autores aduciendo que existen sistemas naturales como el universo mismo, el dolor humano y otros cuyos objetivos escapan racionalmente a nuestro alcance. Para propósitos prácticos, en las distintas ramas de ingeniería siempre podemos identificar un conjunto de objetivos en los sistemas considerados.

La definición 6, un tanto más general y que no resalta las características mencionadas en los párrafos anteriores, hace énfasis en la posibilidad de mirar cualquier aspecto de la realidad como un sistema.

3. Cómo definir un Sistema.

Un tanto más práctico que la definición y mucho más útil a nivel operativo es la metodología de cómo definir un sistema que nos presenta la teoría de Sistemas.

En todo sistema debemos definir:

1. El sistema mismo, sus límites o fronteras.
2. El objetivo de estudio del sistema.
3. El medio-ambiente del sistema.
4. Las entradas.
5. Las salidas.
6. Sus elementos, partes o subsistemas.

7. Sus relaciones.

8. La función del sistema.

El orden de enumeración anterior no implica una secuencia lógica sino más bien un requerimiento de orden en la presentación del tema.

3.1 El Sistema mismo.

Cuando decidimos estudiar un sistema, el primer problema a resolver es la delimitación estricta de la parte del universo que vamos a analizar, la determinación de las fronteras del sistema, y la enumeración formal de los elementos o partes que consideramos dentro del sistema.

El problema anterior no es trivial y presenta serias dificultades. La identificación de cada elemento (subsistema) plantea un problema de delimitación similar al problema original. Por elemento entendemos objetos, hechos, procesos, conceptos, sucesos, actividades o entidades que pueden diferenciarse unas de otras; cada elemento o subsistema aislado puede ser estudiado como sistema en sí mismo. En la práctica se requiere de un "Buen Juicio" que permita delimitar hasta un cierto nivel de detalle operacional.

Otro problema frecuente en la delimitación es la inclusión de un elemento que introduce consigo al sistema elementos relacionados que no buscábamos incluir. La duda de si incluir o excluir ciertos elementos en nuestro sistema es frecuente en la delimitación de un sistema; mientras más elementos incluimos más complejo nuestro sistema a estudiar; si excluimos demasiados elementos sobre-simplificamos el sistema y se desdibuja la función de sistema de interés. La decisión de incluir o excluir un elemento en el sistema repercute en la definición de relaciones, entradas y salidas. Cuando un elemento interno al sistema decide excluirse por razones válidas, hay que determinar qué relaciones pasan a ser entradas o salidas; consideración análoga hay que realizar cuando se decide incluir un elemento que inicialmente se consideró fuera del sistema.

3.2 El objetivo del estudio del Sistema.

Nunca es suficiente el énfasis en la importancia y claridad de los objetivos. Toda acción humana es realizada no por sí misma sino porque con su realización buscamos algo diferente. Este algo diferente que perseguimos a través de

nuestras acciones es el objetivo. Casi siempre existe más de un objetivo como motivación de una acción.

Cuando nos planteamos el estudio de un sistema particular - de una parte del universo - buscamos con ese estudio un objetivo específico. Estudiamos una asignatura en la universidad no por estudiar por sí misma la asignatura, sino para aprobar un requisito que exige el plan de estudios para obtener un título profesional. Queremos un título profesional no por tener un título en sí mismo sino porque con él logramos mejores oportunidades de trabajo, y nuestro interés de un trabajo no es el trabajo en sí sino el dinero y la posición de influencia que por medio de él conseguimos. Así podríamos continuar recorriendo una sucesión jerárquica de objetivos intermedios hasta culminar en un objetivo final y efímero que llamamos felicidad.

En nuestros estudios diarios de sistemas concretos podemos siempre identificar un objetivo práctico e inmediato que nos motiva a analizar cierta parte del universo.

La definición explícita del objetivo del estudio del sistema es fundamental y suministra guías valiosas para la delimitación del sistema, sus elementos, relaciones y medio-ambiente.

Se puede estudiar un automóvil con diferentes objetivos. El interés de disminuir el consumo de gasolina, una mayor facilidad para su manejo, un diseño de su perfil exterior que oponga poca resistencia al aire, mayor seguridad de los pasajeros en los choques, o un mejor aprovechamiento de la corriente eléctrica generada son algunos de los múltiples objetivos posibles cuando se analiza un automóvil como sistema. Dependiendo de uno u otro objetivo, la delimitación del sistema varía.

Es importante anotar la diferencia existente entre objetivo del estudio del sistema y el objetivo del sistema. En el presente contexto al objetivo del sistema nos referimos como la función del sistema y se explica en el numeral 3.8

Uno de los errores más frecuentes en la identificación del objetivo es confundir la acción misma con su objetivo. Expresar que una acción está justificada por sí misma, o que el objetivo de un sistema es el sistema mismo. Ejemplo típico de ello es cuando se planea diseñar un sistema de información de personal, se incluye como objetivo el diseñar un sistema de información de personal. El objetivo no es el diseño del sistema sino el suministrar una herramienta que per-

mita a una organización ejercer ciertas funciones de control, planeación y pago con sus empleados de una manera eficiente, ordenada y ajustada a las leyes.

Otra de las tendencias en la fijación de objetivos es la determinación de objetivos aparentes, supremamente elegantes y "bellos" pero poco reales. Un ejemplo simple pero diciente se presencia cuando el profesor en los cursos de universidad pregunta a los estudiantes sus objetivos en el curso; la respuesta inmediata general es el aprendizaje de la materia. El objetivo real no confesado pero que sí condiciona todas las acciones es aprobar el curso con un mínimo de esfuerzo.

Desafortunadamente nuestra educación hace más énfasis en los objetivos aparentes que en los reales. La labor de descubrir los verdaderos objetivos, punto central de la teoría de Sistemas, no es una labor fácil.

3.3 Medio-Ambiente.

Varias son las definiciones que de medio-ambiente se encuentran en la literatura de sistemas. Churchman describe el medio-ambiente como todo lo que consideramos fuera o exterior al sistema, y sobre lo cual el sistema no posee influencia alguna. Además de la parte del universo a que dedicamos nuestra atención existe todo lo demás que rodea nuestro sistema y dentro de lo cual funciona el sistema. El universo es medio-ambiente de cualquier sistema. La definición 6 de sistema incluida en la sección 2 resalta esta concepción de medio-ambiente.

En nuestros propósitos prácticos de la vida diaria es de gran utilidad considerar un medio-ambiente un tanto más limitado que el universo. Estrictamente hablando el universo es siempre medio-ambiente de todo sistema. Sin embargo, una definición de un subsistema más restringido y cercano al sistema en estudio como medio-ambiente es de gran conveniencia.

El objetivo fundamental del concepto de medio-ambiente es hacer énfasis no en el sistema aislado sino en su comportamiento y relaciones con otro sistema más amplio, dentro del cual el sistema estudiado es solo un subsistema, y cuya interacción mutua es fundamental para su funcionamiento. De ahí nace otra definición más limitada de medio-ambiente. Consideraremos como medio-ambiente de un sistema otro sistema más amplio dentro del cual el sistema estudiado es un subsistema y con respecto al cual queremos estudiar el comportamiento del sistema.

El énfasis en considerar un medio-ambiente para todo sistema se basa en el hecho de que ningún sistema funciona aislado y que cualquier análisis racional de la realidad no puede ignorar las interacciones entre el medio que rodea al sistema y el sistema mismo, más aún, el comportamiento de un sistema puede variar radicalmente dependiendo del medio-ambiente que lo rodea.

La preocupación excesiva por aislar y estudiar los objetos subdividiéndolos hasta los límites tecnológicamente alcanzables fueron unas de las tendencias de las ciencias en tiempos pasados. Los esfuerzos por obtener el vacío y estudiar en este los elementos son ejemplos de tal preocupación.

El concepto de medio-ambiente busca resaltar la importancia de no estudiar los sistemas aislados.

La expresión misma medio-ambiente incluye una abierta redundancia. Medio y Ambiente son palabras que en el significado usado en el contexto simbolizan la misma idea. A pesar de ello, el uso del término medio-ambiente se encuentra ampliamente difundido en la literatura de sistemas.

Según nuestra definición de medio-ambiente, dado un sistema se nos presentan innumerables medio-ambientes posibles.

La selección apropiada del medio-ambiente de un sistema repercute en la definición de otros componentes y en el éxito de la consecución de los objetivos del estudio del sistema.

3.4 Entradas.

Las entradas son las acciones del medio-ambiente sobre el sistema, son relaciones entre el exterior y la parte del universo que se busca estudiar. La delimitación conceptual de un sistema conduce a plantear un cierto aislamiento del sistema con lo que lo rodea. En la realidad ningún sistema funciona aislado, por eso la importancia de estudiar su comportamiento no desconectado totalmente de influencias externas sino afectadas por las acciones a que está expuesto en la vida real. Las acciones del universo o mundo exterior sobre un sistema pueden ser innumerables. De ahí la conveniencia de definir un medio-ambiente un tanto más limitado que el universo que nos guíe en la identificación de las entradas. Las acciones del universo sobre el sistema se analizan así a través del medio-ambiente.

Es importante considerar no solo las entradas convenientes o deseadas a un sistema sino también las inconvenientes o indeseadas. La tendencia a mirar únicamente lo que nos conviene ha llevado muchas veces a despreciar acciones del medio-ambiente sobre el sistema que aunque no buscadas, afectan inevitablemente su comportamiento.

3.5 Salidas.

Son las acciones del sistema sobre el medio-ambiente. Así como el exterior afecta al sistema, el sistema de alguna manera influye o actúa sobre el medio-ambiente. Son las relaciones entre el sistema y el medio-ambiente. Igualmente conviene resaltar aquí la ayuda que suministra una delimitación más estricta del medio-ambiente o un subsistema del universo. Ello nos permite resaltar e identificar las salidas más fácilmente que si consideramos el universo total como el medio-ambiente.

En la identificación de salidas es importante también el no pasar por alto las salidas no deseadas o no buscadas explícitamente por el sistema. La polución, las basuras, el calor, son salidas inevitables de muchos de nuestros sistemas que antiguamente se ignoraban. La Ecología estudia hoy en día con cuidado los efectos malignos que muchas de estas salidas ejercen sobre nuestro medio-ambiente.

La definición y estudio de las entradas y salidas de un sistema permiten corregir parcialmente el aislamiento o delimitación inicial del sistema. Asumimos que el medio-ambiente del estudio particular de un sistema resume apropiadamente las acciones del universo que más importan para el estudio.

Vale la pena notar una contradicción implícita en la metodología para definir un sistema. Primero la delimitación del sistema o determinación de la parte del universo que se va a estudiar, un proceso de aislamiento y fijación de fronteras. Luego la preocupación por corregir así sea parcialmente el aislamiento anterior, consideración del medio-ambiente e identificación de entradas y salidas. La complejidad del mundo que nos rodea y nuestra capacidad limitada de entendimiento imponen el indeseado aislamiento inicial. Nuestra mente requiere de una visión restringida y particular inicial que facilite la comprensión, la riqueza y complejidad de la naturaleza.

3.6 Elementos o Subsistemas.

Las varias definiciones de sistema presentadas en la sección 2 resaltan como característica del concepto de sistema la identificación de distintas partes que se interrelacionan coherentemente. Casi nunca existe en un sistema una monolítica unidad indivisible sino que por el contrario podemos detectar entidades u objetos menos complejos que el sistema original, que se agrupan o conectan de determinada manera y a propósito para constituir un sistema específico. Estas entidades o unidades menores que componen un sistema son llamadas elementos o subsistemas. Cada subsistema integrante del sistema es, a su vez, un sistema y puede ser analizado por sí mismo como un sistema independiente y un medio-ambiente posible para su estudio sería el sistema inicial en el cual dicho subsistema es un elemento.

Una de las definiciones halladas en la literatura que además de presentar una explicación ofrece un criterio guía en el proceso de dividir un sistema en subsistemas es: “Subsistema es un conjunto o parte del sistema que posee más relaciones consigo mismo que con el resto del sistema”. En la sección 3.7 se elaborará más detenidamente el concepto de relación. Por ello conviene releer la definición anterior luego de haber comprendido la sección 3.7 que explica el concepto de relación.

En todo subsistema considerado como sistema puedo distinguir también elementos o partes. Podríamos continuar así en una cadena jerárquica hasta detenernos en algún subsistema elemental indivisible. En una época anterior se creyó haber descubierto ese elemento básico indivisible: el átomo. Experiencias posteriores comprobaron que el átomo estaba constituido por elementos más sencillos aún. En la práctica la división de un sistema en subsistemas se realiza no buscando elementos indivisibles sino a un cierto nivel de agregación apropiado para los objetivos que pretende el estudio del sistema estudiado.

Dado un sistema se presentan innumerables posibilidades de identificación de elementos o de división en subsistemas. Es este un problema no trivial y descuidado que no ha sido estudiado suficientemente, la selección de los subsistemas se ha dejado a inspiración del analista y no existe actualmente una metodología concreta que oriente ni criterios de ayuda. La repercusión que una acertada selección de subsistemas tiene para el estudio de un sistema es obvia. Los subsistemas escogidos condicionan las relaciones o interacciones entre los elementos y es en el estudio de las relaciones donde mayor énfasis y esfuerzo requiere la metodología de sistema.

Existe una tendencia general a identificar como subsistemas a objetos o partes materiales que ofrecen visualmente un contorno físico limitado. Otro criterio un tanto más abstracto es clasificar el comportamiento del sistema en diferentes funciones específicas y asociar a cada función el subconjunto de partes del sistema que contribuyen a dicha función. El criterio de funciones puede sugerir que un elemento que contribuye a varias funciones quede incluido en distintos subsistemas.

La teoría de sistemas empieza a estudiar con cuidado criterios que guíen en esta subdivisión.

3.7 Relaciones.

Son las acciones que existen entre los elementos de un sistema, la manera particular como se ensamblan, conectan o comunican las distintas partes o subsistemas del sistema. El énfasis en las relaciones es una característica básica de la metodología del sistema. Tan importante como los elementos son las relaciones cuando se pretende conocer a fondo un sistema.

Entre dos elementos existe la posibilidad de varios tipos de relaciones.

Un subsistema A puede afectar a un subsistema B de varias formas. El subsistema B, a su vez, puede influir en el subsistema A, de varias maneras. Por eso usualmente en las relaciones entre los elementos debe indicarse claramente cual es el elemento que afecta y cual el afectado; no es lo mismo una relación de A hacia B que la relación inversa de B hacia A. Otro tipo de relación importante es la acción de un elemento sobre sí mismo a medida que transcurre el tiempo, esta relación llamada auto-relación, y que en el lenguaje común se conoce como característica o propiedad de un elemento, permite a veces representar al elemento más que por su contexto material por alguna representación simbólica o matemática de sus características o auto-relaciones.

El conocimiento de las relaciones y elementos de un sistema constituyen el objeto de estudio de las distintas áreas de las ciencias, las profesiones y los oficios.

Una relación en un sistema material casi siempre se puede identificar como una conexión física, una unión o contacto real entre dos elementos. En sistemas humanos, la relación puede consistir en un flujo de información.

En un sistema la manera como están ensamblados los elementos determinan su comportamiento. Las reparaciones de artefactos y muchos de los esfuerzos de la medicina buscan sólo reconstruir una relación rota o alterada que está distorsionando o paralizando el funcionamiento del sistema.

Para hacer énfasis en la importancia de las relaciones se consideran componentes del sistema no solo a sus elementos sino al conjunto de elementos y relaciones de un sistema. En algunos textos el término componente es sinónimo de elemento o subsistema. En este contexto tomamos el significado de componente como aquel que incluye las relaciones y elementos.

Las relaciones dependerán de cómo se dividió el sistema, de qué elementos o partes consideraremos como subsistemas. Si cambia la división, cambian las relaciones. De ahí la importancia de una apropiada división de sistema.

3.8 Función del Sistema.

La costumbre de esquematizar un sistema dibujando una caja negra que recibe ciertas entradas del exterior y produce algunas salidas representa gráficamente el concepto de función. La caja negra o sistema realiza una transformación en las entradas para obtener determinadas salidas. Podríamos pues definir la función de un sistema como la transformación específica que el sistema realiza sobre las entradas para obtener sus salidas. La función de un reloj es transformar una determinada cantidad de energía en un movimiento periódico y ordenado que nos sirve para medir el transcurrir del tiempo. La función podría considerarse como una macro-relación dominante que caracteriza globalmente al sistema. Podemos identificar en todo sistema una función primaria que lo caracteriza esencialmente, y soportando esta función primaria clasificar varias funciones secundarias soportes o subfunciones de la función primaria. Un ejemplo sencillo nos ayuda a visualizar lo anterior. La función primaria característica de un automóvil es transformar energía en un desplazamiento controlado que sirve de alguna manera de transporte. Como subfunciones soportes existe una subfunción de combustión y explosión de gasolina que genere cierta fuerza controlable, una subfunción de transferencia de movimientos mecánicos de un elemento a otro que permite transformar la fuerza producida en el movimiento de las ruedas, una subfunción de lubricación que minimice los rozamientos en la transferencia de movimientos, una subfunción de refrigeración que mantenga la temperatura del motor dentro de ciertos límites aceptables y muchas otras subfunciones adicionales que requeriría demasiado espacio enumerar.

La función del sistema es llamada también en la literatura el objetivo del sistema. Hemos preferido en nuestro contexto llamarla función por reservar la palabra objetivo al objetivo del estudio y por la connotación de transformación que la palabra función posee en el lenguaje matemático.

3.9 Resumen.

Se han presentado en el presente artículo algunas definiciones de sistema resaltando los elementos indispensables del concepto de sistema. Adicionalmente desde un punto de vista práctico se ha explicado brevemente la metodología de cómo definir un sistema indicando qué constitutivos hay que identificar, buscando delimitar un mínimo lenguaje común y clarificar cada término y su significado dentro de la teoría general de sistemas. Sobre cada uno de los elementos que debemos identificar en un sistema se podría profundizar mucho más, lo que ofrecería tema para varios artículos más.

El objetivo primordial era presentar una visión global que pudiera servir de introducción a lecturas posteriores.

9.2 EL CONCEPTO DE MODELO EN LA TEORÍA DE SISTEMAS

Notas de la Profesión

Por:
EDUARDO ZULUAGA RUIZ
Director Ingeniería de Sistemas
Universidad EAFIT

1. INTRODUCCIÓN

Uno de los conceptos de más amplio uso en las diferentes disciplinas de estudio es el concepto de modelo, no sólo está presente en los más elementales procesos del pensamiento humano, sino también, es la herramienta básica de las investigaciones más complejas. La teoría de sistemas ha seleccionado el concepto de modelo, conjuntamente con el concepto de sistema, como abstracciones fundamentales, que permiten desarrollar una serie de principios guías comunes a varias metodologías de trabajo. No son los modelos un invento o creación de la teoría de sistemas. Los modelos han existido desde remotas épocas en toda elaboración del pensamiento y en los esfuerzos de los seres animales de mirar, comprender o manipular el mundo exterior. La teoría de sistemas ha resaltado la generalidad del concepto de modelo y su amplia presencia en diversos procesos, ha buscado clarificar su significado, ha desarrollado una conciencia saludable en el papel y uso de los modelos y plantea toda una metodología que ayuda en la elaboración, validación, experimentación y utilización de los modelos.

El presente artículo resume brevemente las ideas básicas sobre el concepto de modelo, sus características, funciones y usos dentro de la teoría de sistemas.

2. DEFINICIÓN DE MODELO

Comenzaremos intentando delimitar y clarificar un tanto el significado de la palabra modelo. Presentaremos varias definiciones de modelo con el objeto de ilustrar diversas explicaciones del concepto.

1. Ejemplar que uno se propone imitar.
2. El sustituto de un sistema.
3. La representación parcial de un sistema.
4. Dado un sistema, llamamos modelo del sistema dado a otro sistema, cuyos componentes se corresponden parcialmente con los componentes del sistema original.

Las cuatro definiciones anteriores incluyen todas las siguientes características:

- La existencia de un sistema o ejemplar que se quiere imitar, representar o sustituir.
- El propósito de crear otro sistema llamado modelo, que debe representar, imitar, sustituir o parecerse al sistema original.
- Adicionalmente, las definiciones 3 y 4 nos resaltan el hecho de que esta representación o imitación rara vez se logra totalmente o casi siempre es parcial o aproximada, lo que constituye la tercera característica del concepto de modelo.

La definición 1, más del lenguaje popular que académico, resalta la característica de un sistema - ejemplar - que se busca repetir o imitar en alguna forma.

En nuestro contexto de teoría de sistemas, la definición 4 resume y enfatiza las características fundamentales del concepto.

De la definición 4 podemos deducir las siguientes observaciones:

1. El modelo también es un sistema.
2. El modelo busca representar, imitar reproducir el sistema.
3. El sistema y el modelo son dos sistemas diferentes.

4. La representación del sistema en el modelo generalmente es parcial y no total.
5. Existen componentes del sistema que no están presentes en el modelo.
6. Existen componentes en el modelo que no están presentes en el sistema.
7. Aún, cuando un componente del sistema sea representado por un componente correspondiente en el modelo, la correspondencia no es exacta, sino aproximada o parcial.
8. La falta de coincidencia entre el sistema y el modelo requiere análisis cuidadoso, pues, da origen a errores e inexactitudes de predicción. De esta correspondencia parcialmente podemos deducir dos anotaciones importantes:
 - Dado un sistema, son posibles múltiples modelos de dicho sistema. Casi siempre cada modelo resalta algún punto de vista específico. De una fábrica podemos construir innumerables modelos. Algunos de los más estudiados son el modelo contable que enfatiza el flujo de dinero, el modelo de personal que representa las personas involucradas y sus relaciones en la empresa, el modelo de mercado que integra todas las acciones que se requieren para la comercialización del producto; podríamos mencionar también el modelo de producción y el modelo administrativo.
 - Un modelo puede aplicarse a varios sistemas. Debido a que el modelo es solo una abstracción, es decir, representa ciertos aspectos del sistema, es posible que diferentes sistemas compartan el mismo modelo. Ejemplos típicos de ello, son los modelos matemáticos, estadísticos y de programación que permiten ser utilizados en casi todas las disciplinas.

Las observaciones anteriores son de un incalculable valor práctico, cuando se trabaja con modelos. Todos ellos se desprenden de la definición 4. Tal vez, las menos obvias son las observaciones 5 y 6 que explicaremos un poco.

Cuando observamos un sistema e intentamos representarlo de alguna manera, rara vez logramos una representación perfecta del sistema. Limitaciones de apreciación, errores de interpretación, restricciones en los medios de representación, nuestra misma estructura sensorial y mental, hacen que en el modelo

omitamos elementos y relaciones que, aunque presentes en el sistema, o no percibimos, o no podemos o queremos representar en el modelo. De modo análogo podemos incluir en el modelo elementos o relaciones del sistema que, o percibimos erróneamente, o se nos entran irremediablemente al modelo cuando introducimos algún componente que sí está en el sistema.

La falta de coincidencia exacta entre sistema y modelo, es una fuente de error y de problemas en el trabajo con modelos. De ahí la importancia de su conciencia y la necesidad de su evaluación para una sana aplicación de los modelos en la vida real.

3. EJEMPLOS DE MODELOS

Los planos espaciales que de un edificio elabora un arquitecto, son ejemplos de modelos. Asimismo, las maquetas que en diferente escala pero ya en tres dimensiones nos permiten visualizar una futura construcción.

Los mapas son modelos de regiones geográficas que nos permiten una visión global a diferente escala de extensiones de tierra, océanos o espacios imposibles de abarcar físicamente con nuestros sentidos en un mismo instante dado.

Nuestro recuerdo de la casa de los abuelos es un modelo de su hogar remoto y distante.

Los carros, aviones y muñecos de los niños son modelos que buscan representar parcialmente sus correspondientes en la vida real.

Las estatuas, los retratos, las fotografías son ejemplos de modelos.

El organigrama de una empresa, un diagrama de flujo de computadora, los sistemas de información, los programas de computadora son todos ejemplos de modelos.

El alfabeto que utilizamos, el lenguaje con sus símbolos, frases, sonidos, es un modelo extraordinario que nos permite representar y comunicar nuestros modelos del mundo exterior.

Pensar es hacer modelos. Hablar es describir modelos. Actuar es comportarse de acuerdo a un modelo.

La construcción de modelos es una actividad normal del ser humano. El hombre intenta representar el mundo exterior por medio de representaciones abstractas aproximadas que le permitan su comprensión.

El esfuerzo de cada una de las áreas de la ciencia es desarrollar y validar modelos, cada vez más representativos de los sistemas naturales que sirvan de herramienta para el conocimiento de los sistemas y la predicción de su comportamiento, así como instrumentos para la construcción y diseño de sistemas similares.

El uso de modelos no es exclusivo del hombre. Experimentos con animales han comprobado cierta capacidad para asociar reacciones emocionales de dolor o alegría, con formas geométricas como círculos o elipses, lo que presupone la distinción de formas y alguna capacidad de reconocer y asociar imágenes a un patrón modelo.

4. RELACIÓN ENTRE SISTEMA Y MODELO.

Existe una cierta flexibilidad en la determinación de lo que consideramos sistema y lo que llamamos modelo. Dependiendo del punto de vista adoptado, podemos llamar modelo al sistema y sistema al modelo. Son en cierta manera, conceptos complementarios que de acuerdo al objetivo práctico de un estudio particular, pueden intercambiarse. Según la definición, el modelo también es un sistema.

En general, podemos pensar que los sistemas existen en el mundo exterior, fuera de nuestra mente; los modelos por su parte son construcciones humanas, realizadas por nuestra mente. Los modelos están condicionados por los sistemas naturales que buscan representar o por leyes de fenómenos naturales que intentan reproducir.

Un ejemplo puede ilustrarnos con claridad los puntos anteriores. Pensemos en ese sistema abstracto que llamamos tiempo. Un sistema que define relaciones de sucesión en los acontecimientos. El reloj es una invención del hombre que inicialmente pretende cuantificar y medir de alguna manera el transcurrir del tiempo. Desde el punto de vista de construir un sistema que permita representar este transcurrir, podemos afirmar que el reloj es un modelo de tiempo. Pensemos en el mismo reloj desde el punto de vista de un estudiante de relojería, que busca conocer internamente sus componentes y su funcionamiento. Desde un punto de vista práctico, el estudiante olvida que el sistema es un modelo

del tiempo y considera como su sistema de estudio el reloj mismo. Para comprender su funcionamiento, usará modelos gráficos o descriptivos que representen el conjunto de elementos y relaciones definidos en el reloj. Desde el primer punto de vista, se nos hace más lógico llamar modelo al reloj, según el punto de vista segundo, el reloj es el sistema.

El que llamemos a un objeto o proceso sistema o modelo, depende del punto de vista donde nos ubiquemos más que del objeto o proceso mismo.

En los procesos de diseño de nuevas máquinas o productos, se puede pensar en la existencia primero del modelo: el plano de diseño y en la construcción posterior del sistema: la maquinaria o producto. Un orden aparentemente diferente al sugerido por nuestra definición. Podríamos llamar también sistema al plano de diseño y modelo a la realización física resultante. En la implementación del plano, casi siempre se encuentran limitaciones de tecnología y contradicciones de diseño que obligan a modificar el diseño original y construir un artefacto aproximado al diseño original.

5. RAZONES PARA EL USO DE MODELOS.

Pensar es hacer modelos. Estudiar es adquirir modelos. Actuar es usar modelos. Los modelos intentan representar la realidad con grados variables de exactitud. Nuestra educación y nuestro raciocinio se basan en la construcción, depuración y utilización de modelos.

El auge del uso de modelos y su importancia conceptual dentro de la estructura básica de los procesos racionales, no son hechos gratuitos, sino consecuencias lógicas de ventajas que ofrecen los modelos para comprender y/o manipular el mundo exterior.

Algunas de las razones para el uso de modelos son:

5.1. Los modelos son una manera natural de la mente humana para representar y comprender la realidad.

La capacidad de abstraer y generalizar se fundamenta en la identificación de elementos y relaciones comunes a varias situaciones individuales que permiten elaborar una estructura común, presente siempre en las diversas situaciones. Los modelos matemáticos representan un aspecto cuantitativo presente en

diferentes sistemas y que puede aplicarse en fenómenos mecánicos, eléctricos, químicos, financieros y muchos otros más.

No solamente en la preocupación científica de comprender la realidad, se percibe la tendencia a representar los sistemas por medio de modelos, sino también en las artes se percibe la inclinación del hombre a representar la realidad. El retrato de un niño es un modelo, la fotografía de una anciana es un modelo, la estatua de un héroe es un modelo. La narración de una novela, la redacción de una historia son modelos que buscan representar o una situación posible o un hecho real.

5.2. Es más fácil de entender los modelos que los sistemas.

La maqueta de un edificio me permite apreciar más claramente el edificio que su descripción verbal. Un diagrama de flujo de un programa me visualiza gráficamente una secuencia lógica de operaciones de una forma más fácil de comprender y seguir que la descripción verbal del algoritmo.

La no identidad entre sistema y modelo permite construir modelos que centren la atención en un subconjunto particular de elementos y relaciones del sistema. Ello permite olvidar racional y conscientemente algunos elementos y relaciones del sistema que para el objetivo de un estudio particular no interesan. El plano arquitectónico de una construcción es un modelo gráfico que resalta los elementos y relaciones espaciales, pero que ignora parcialmente los elementos y relaciones de fuerzas y soportes que debe incluir necesariamente un ingeniero en su modelo. Igualmente el médico especialista en ortopedia representa el cuerpo humano por medio de un modelo muy diferente al modelo que utiliza un médico especialista en cardiología para representar el mismo cuerpo humano.

Los modelos buscan resaltar un subconjunto de elementos y relaciones de un sistema de acuerdo a un interés determinado, de manera que permita visualizar más claramente que en el sistema real una actividad o proceso del sistema.

5.3. El modelo es más fácil de manejar que el sistema.

En general, un modelo puede ser manipulado más fácilmente que el sistema. Un mapa, modelo de una región geográfica, puede doblarse y ser trasladado fácilmente de un sitio a otro sin ninguna dificultad. Cosa imposible de hacer con el sistema real. Igual sucede con los planos y maqueta de un edificio.

Realizar un cambio en un modelo es una labor relativamente sencilla que no implica repercusiones prácticas complicadas. Añadir un piso o cambiar la distribución de un edificio en un plano es una operación relativamente simple comparada con las acciones físicas requeridas para ejecutar igual cambio en la vida real.

Esta facilidad de operación se puede apreciar en la operación de modelos reducidos en escala de sistemas como aviones que permiten experimentar, sin mayores complicaciones, situaciones que exigiría una cantidad exagerada de precauciones y controles si fuera a experimentarse con el sistema mismo.

Experimentar las repercusiones de una medida económica en un modelo matemático de una nación, se puede hacer a través de las distintas operaciones y cálculos de las ecuaciones del modelo, operaciones más manejables que los complejos procesos económicos de una economía real.

5.4. El modelo es menos costoso que el sistema

Uno de los recursos de más cuidado en todo proyecto es el dinero. La disminución y/o control de los costos es una labor primordial en cualquier labor. La construcción de un modelo es mucho más económica que la construcción del sistema. No hay comparación entre el costo de construir un edificio y el costo de fabricar su maqueta. Igualmente, es mucho más barato construir un modelo a escala de un automóvil o de un avión, que construir el automóvil o el avión mismo. Requiere menores recursos siempre la construcción del modelo que la construcción del sistema, debido a la reducción de escala y complejidad en el modelo.

5.5. El experimentar con el modelo es menos riesgoso que el experimentar con el sistema.

Cuando desconocemos el comportamiento de un sistema en un medio ambiente particular, o nunca hemos observado su reacción ante algunas entradas particulares, una excelente manera de prever los posibles comportamientos es la experimentación con el modelo. El comportamiento del modelo nos orienta acerca del posible comportamiento del sistema. Lo anterior nos permite prever antes de experimentar con el sistema real, posibles reacciones y seleccionar entradas convenientes a nuestros objetivos o identificar medios ambientes indeseables para nuestro sistema.

La disminución del riesgo es importante cuando la vida humana está en juego o cuando la repercusión de un experimento puede conllevar la destrucción del sistema estudiado en el experimento. La caída de un pequeño avión, modelo reducido de cualquiera de los modernos *jets*, al ensayar ubicaciones diferentes de las turbinas implica un pequeño riesgo nunca comparable con la tragedia de que caiga un jet real.

Cuando se estudian las reacciones del cuerpo humano a nuevas drogas o sustancias extrañas, se experimentan antes las reacciones de algunos animales, modelos implícitos del hombre, a dichas sustancias. Del comportamiento del modelo podemos deducir si conviene o no exponer el hombre a las nuevas drogas. Antes de enviar al espacio al hombre, se envió una nave tripulada por un animal, modelo del hombre, buscando explorar los riesgos a los cuales sería sometido el primer astronauta.

5.6. Es más rápido operar un modelo que un sistema.

El transcurrir inevitable del tiempo escapa a todo control humano. Los cambios de un sistema a medida que pasa el tiempo exigen, a veces, períodos relativamente largos para poder ser apreciados por el hombre. La evolución de una especie es imperceptible en el período de vida de un hombre, el cambio de una región geográfica sólo puede ser apreciado luego de períodos de cientos de años. En muchos casos, la longitud de la vida humana no alcanza para poder percibir cambios en los sistemas. Los modelos permiten simular el transcurso del tiempo por medio de la computadora variando las escalas de duración de modo que períodos de minutos pueden equiparse simbólicamente al paso de miles de años. Este aparente transcurso del tiempo artificial logrado en los modelos permite prever de una manera aproximada los cambios operados lentamente en los sistemas durante extensas épocas. Esta posibilidad de simular el transcurso del tiempo en los modelos es una de las grandes conveniencias de los modelos. Aparece así una posible aunque artificial metodología de explorar el futuro y de probar las repercusiones o consecuencias que una u otra acción pueden desencadenar, disminuyendo, así sea parcialmente, la incertidumbre y suministrando información invaluable para la toma racional de decisiones.

6. IDEA BÁSICA DEL USO DE MODELOS.

La idea central en la construcción de modelos es diseñar modelos suficientemente cercanos al sistema que representan, de modo que, el modelo se comporte, dentro de ciertos límites, como el sistema representado. El modelo,

pues, busca reproducir algún comportamiento del sistema. Por lo tanto, la observación del sistema y su comportamiento son los primeros pasos para la elaboración de un modelo. El sistema determina el modelo. El investigador debe observar y registrar los diferentes comportamientos y reacciones del sistema al ser sometido a entradas y medios ambientes diferentes y a través de una serie de operaciones de análisis y experimentos ir construyendo el modelo. Es éste un proceso inductivo donde la mente de quien construye el modelo y sus objetivos, constituyen un filtro que determina muchas de las características del modelo.

Una vez logrado un modelo que simule adecuadamente cierto comportamiento del sistema, se puede pasar a experimentar no ya con el sistema mismo sino con el modelo, e inferir del comportamiento del modelo ciertos comportamientos del sistema en circunstancias iguales. Un proceso deductivo que puede suministrar normas e información valiosa para la operación del sistema.

Claro está que debido a que no existe una correspondencia exacta entre sistema y modelo, podemos llegar a conclusiones erróneas. De ahí la importancia del estudio de la exactitud y validez del modelo.

7. RESUMEN.

El concepto básico de modelo dentro de la teoría de sistemas, ha sido presentado en función del concepto de sistema. Los elementos fundamentales son indicados así como las características básicas implícitas en su definición, haciendo énfasis en la falta de coincidencia entre sistema y modelo y los peligros que esta no coincidencia conlleva en el uso de los modelos en las distintas ciencias. Se presentan, además, ejemplos sencillos y frecuentes de modelos. La relación entre sistema y modelo es analizada desde un punto de vista relativo que permite llamar, en la vida práctica, un mismo objeto, tanto sistema como modelo. Se exploran algunas de las razones para el uso de modelos y finalmente, se presenta la idea central para la construcción y uso de modelos.